

DocAI多人AI文档协作平台

DocAI：多人AI文档协作平台

[作者背景介绍](#)

[项目说明](#)

[项目简历描述](#)

[项目的安装与使用](#)

[学习步骤](#)

[背景与目标](#)

[JAVA后端八股](#)

[JVM](#)

[对象创建与布局](#)

[JVM内存区域](#)

[垃圾回收](#)

[类加载机制](#)

[JVM调优实战](#)

[【了解】执行引擎与JIT](#)

[JAVASE](#)

[集合](#)

[反射](#)

[深拷贝浅拷贝](#)

[异常机制](#)

[代理](#)

[Spring相关](#)

[迭代器](#)

[泛型](#)

[IO模型](#)

[JDK新特性](#)

[JUC](#)

[线程基础](#)

volatile关键字

ThreadLocal

线程池

AQS

CAS与原子类

synchronized与Lock

并发经典题

线程安全与JMM

微服务架构与拆分

RAG相关八股

01微服务架构设计

02RAG知识库设计

03AI Agent设计

04文件服务设计

05用户认证与安全设计

06API网关设计

07消息队列设计

08数据库与缓存设计

09容器化与部署设计

10监控与Alops运维设计

项目相关面经

字节一面

字节二面

字节三面

腾讯CSIG 后台开发

淘天 AI应用开发

项目的面试题

DocAI：多人AI文档协作平台

作者背景介绍

作者邱同学 厦大本 凭借此项目补全了简历上的AI相关技术栈

成功在四月中旬拿到字节offer

字

字节跳动 ByteDance

4月17日

欢迎你加入字节跳动!

...后端开发实习生-的面试。现邮件向你发出正式的录用通知。真诚地邀请你加...

字

字节跳动 ByteDance

4月13日

来自字节跳动的面试邀请

...感谢投递字节跳动。字节跳动诚邀你参加后端开发实习生-职位的面试，期...

字

字节跳动 ByteDance

4月9日

来自字节跳动的面试邀请

...感谢投递字节跳动。字节跳动诚邀你参加【ByteIntern】后端开发实习生-职位...

字

字节跳动 ByteDance

4月3日

来自字节跳动的面试邀请

...感谢投递字节跳动。字节跳动诚邀你参加【ByteIntern】后端开发实习生-职位...

字

字节跳动 ByteDance

3月24日

来自字节跳动的面试邀请

...感谢投递字节跳动。字节跳动诚邀你参加【ByteIntern】后端开发实习生-职位...



欢迎你加入字节跳动！

字节跳动 ByteDance

[详情](#)



你好，恭喜你顺利通过了 后端开发实习生  的面试。现邮件向你发出正式的录用通知，真诚地邀请你加入字节跳动。

新同学 入职指引

新同学，终于等到你~
欢迎加入字节跳动，成为 ByteDance 的一员。为帮助你更好的完成入职手续办理，我们为你准备了这份指引页，快快get它吧！

① 入职签到

报到安排：10:00 前台签到，等待HR统一指引至培训教室。
若签到不成功，可先登陆「候选人服务平台」，完成所有入职任务后再签到（仍有疑问，可咨询现场HR同学）。

② 培训安排

培训时间：10:05-12:00
培训地点：大钟寺广场2号楼F1-T1会议室（1层）

③ 入职完成

返回工位：12:00 入职办理结束，新同学返回工位开展工作。
如果办公工区不在大钟寺，培训结束后新同学可选择乘坐穿梭车返回工区，相关指引可参考背面

使用须知 Attention

临时工卡仅限本人使用
The temporary badge is for your use only.

激活临时工卡后，本人工卡将失效直至归还临时工卡
After you activate the temporary badge, your employee badge will be suspended until the temporary badge is returned.

请关注「新员工」获取更多临时工卡使用信息
Please refer to [NEW] for more details on temporary badges.

项目说明

适用性

此项目适用于想要学习微服务架构和RAG知识库项目的JAVA同学，在这里你会很好的了解到微服务架构的设计、Spring cloud全家桶、RAG相关的配置、SKILL相关的配置、Docker部署运维、网关的设计、JWT的统一认证。

项目的效果

此项目是完全由我本人+ai coding开发，用时接近三个月左右，中间是经过不断的迭代和升级。最终在四月份凭借这个项目成功拿到了字节的实习资格，并且入职后和面试官交流对于我的面试表现，大家都一致认可的是我关于微服务相关的设计，以及如何用已有的知识去尝试融合、结合ai的能力。

项目的学习时长

对于有java微服务开发经验的同学此项目在一周内完全可以学完并且尝试去面试；但是对于没有微服务相关开发经验的同学，需要多去学习微服务相关的架构知识，学习时长也可以把控在两周之内。

项目的申明

因为此项目由作者本人开发，可能会存在很多细节不足的问题，可以随时跟作者交流并且更改迭代。此项目会保证长期维护更新迭代，不做一锤子买卖。项目是我实际上部署到服务器上运行，但是因为去敏化的原因，会导致github中的配置需要根据自己的配置信息（如ip、镜像地址、API KEY）去修改项目中的代码。如果有条件的同学，可以尝试多服务器部署，掌握实际项目部署的流程，测试自己的具体参数，会使得自己在面试中更加得心应手。

项目简历描述

DocAI：文档智能处理平台（微服务）

核心技术栈：Java 17、Spring Boot 3.2.0、Spring Cloud 2023.0.3、Spring Cloud Alibaba、MyBatis-Plus、MySQL、Redis、RabbitMQ、Spring AI、Docker / Docker Swarm、AI Skills

项目描述：面向文档全流程管理与智能分析的微服务平台，覆盖用户、文件、文档与AI服务等能力。AI服务基于Spring AI构建，整合AI Skills组件，提供文档摘要、纠错、关键词提取与分析能力，并扩展 **AI Agent 架构**，支持 RAG 知识库问答、多范式对话代理等场景，通过微服务协同与容器化部署保障平台高可用。

核心职责与贡献：

- 主导多范式 AI Agent 体系的设计与实现：**基于 Spring AI 框架，结合 AI Skills 组件封装对话交互、逻辑规划、工具调用与知识检索等原子能力，构建了 **Knowledge Index**、**Chat ReAct**、**Plan-Execute** 等多种 Agent 结构；运用 Redis 实现多轮对话上下文管理、状态持久化与短期记忆存储，支撑知识索引、对话协作、规划执行等复杂场景，**多轮对话任务完成率达 89%**。通过spring ai统一调度底层大模型，保障 Agent 决策链路的高效与稳定。
- 设计并实现企业级 RAG 知识库问答系统：**运用 Spring AI、Redis 及AI Skills 组件，模块化封装向量生成、检索匹配、增量同步等核心能力；构建文档向量化存储与检索架构，支持知识库增量更新。在 1000 条业务问答样本上实现 **Top-5 召回率 93%**、**检索支撑回答准确率 82%**，优化向量检索性能后 **P95 响应时间降至 420ms**，服务可用性达 99.95%。
- 构建统一 AI 服务入口与 Skills 能力封装：**基于 Java 17、Spring Boot 3.2.0 与 Spring AI，封装文档摘要、纠错、关键词提取等 AI Skills 核心能力，依托AIOps实现异常管控与性能监控，对接外部大模型实现多模型兼容；支撑的文档智能任务**人工验收通过率达 91%**，单任务平均响应耗时控制在 1150ms 以内。
- 实现核心业务数据持久化与缓存优化：**运用 MyBatis-Plus、MySQL设计用户、文件、文档等数据表结构，保障一致性与查询性能；结合 Redis 实现热点数据缓存，提升系统响应速度，降低数据库压力。
- 异步解耦与文档存储：**基于 RabbitMQ 处理文档上传、AI 任务调度等异步场景，优化任务执行效率；整合 MinIO 实现文档文件的安全存储与高效访问，支撑全流程文档处理。

项目的安装与使用

项目地址：<https://github.com/oifi123666/docAI>

安装教程：[📎INSTALLATION_AND_USAGE.md](#)

学习步骤

梳理项目知识时，应对照简历中的项目描述，换位思考面试官可能提出的问题，再根据预判的问题完善自己对项目体系结构的理解。比较细节的问题，最好是对照相应的代码去回答，这样才会回答得有条理、有逻辑。

1、首先阅读项目简历描述，自问自答。

把你简历上的项目描述拿出来，逐句拆解，扮演面试官追问。如果自己不会提问，可以借助ai的帮助。

示例拆解：

“主导多范式 AI Agent 体系的设计与实现：基于 Spring AI，结合 AI Skills 组件，构建了 Knowledge Index、Chat ReAct、Plan-Execute 等多种 Agent 结构。”

追问清单（自己写下来，总结成自己的文档）：

- 什么是“多范式”？为什么需要多种 Agent，而不是一个通用 Agent？
- Knowledge Index、Chat ReAct、Plan-Execute 分别适合什么场景？能各举一个例子吗？
- AI Skills 和普通的函数调用有什么区别？为什么你要封装成 Skills？
- “多轮对话任务完成率达 89%”——这个指标怎么定义的？怎么测的？基线是多少？
- 你说“基于 Spring AI”，但 Spring AI 本身没有 Plan-Execute，你怎么实现的？
- 这些 Agent 之间能协作吗？比如 Plan-Execute 调用一个 ReAct Agent 作为子任务？

小技巧：如果你自己不会追问，就让 AI 根据你的简历生成 20 个追问。

可选加分：如果项目能跑起来，先跑一次。上传一个文档，触发摘要和 RAG 问答，感受主流程。

2、带着问题看模块文档+代码

把项目的模块进行拆分，按顺序吃透。每个模块你都要输出“三件事”（解决什么问题、怎么做、为什么这么选）。

例如：ai-service 模块拆分为 MCP、AI SKILLS、RAG 等模块，每个模块都需要去看对应的代码，并且输出三件事（解决什么问题、怎么做、为什么这么选）。对于 RAG 模块：① 文档检索增强生成 ② 分块 → Embedding → 存 Redis → 混合检索（向量+BM25）→ 重排序 ③ 用 Redis Stack 的向量检索能力，不引入 Milvus 是为了部署简单。

3、根据问题去理解项目的整体架构逻辑。

第二步是拆分，第三步是整合。也就是把你从简历追问中提炼出的 面试官关切点，和你从代码中拆解出的 模块三件事 串联起来，形成 一条能够自洽回答“为什么这样设计”的完整叙事。整体架构逻辑清楚才可以引导整个面试的进行，不至于被动被拷打。

4、完成第三步后，可以去阅读我给出的面经和我准备的答案，尝试回答这些问题。

完成对项目整体的理解之后，可以尝试不去借助资料和代码去回答问题，巩固和检验自己对项目的理解。最终的目标还是要脱离资料构建自己的一套面试方法。

5、可以根据自己的需求去修改和优化代码。

真正去掌握一个项目是需要将知识内化为自己的东西，根据自己的理解去调整和优化代码，更能体现你对于项目的理解。大厂对于优秀招聘者的画像一定是有自驱力的，愿意去接触新知识的，需要根据自己的理解去形成一套自身的体系。当你走出别人为你准备资料的那一刻，就是你体系构建的开始。

背景与目标

项目的背景

在当今企业数字化转型过程中，文档处理仍是大量业务流程中的关键环节。无论是合同、报告、政策文件还是业务问答记录，企业内部每天都会产生海量非结构化文档。传统人工处理方式存在效率低下、信息提取不全面、知识沉淀困难等痛点，尤其在高频业务问答、文档摘要、纠错与关键词提取等场景中，难以兼顾响应速度与处理质量。

同时，随着大语言模型（LLM）技术的快速发展，企业期望利用 AI 能力提升文档智能化水平，但直接集成大模型面临模型调度复杂、多模型切换困难、上下文管理缺失、知识库检索不精准等问题。此外，单一 AI 服务难以覆盖文档全生命周期（上传、存储、分析、问答等），且缺乏高可用、可扩展的架构支撑。

为此，DocAI 项目旨在基于微服务架构，结合 Spring AI、RAG、AI Agent 等前沿技术，构建一个面向文档全流程管理与智能分析的统一平台，解决企业文档处理效率低、智能化程度不足、系统扩展性差等核心挑战。

面试角度的背景

其实我个人一开始就是学的传统的java后端，自己在今年暑期实习开始之前的实习也是找的传统后端开发。但是随着ai热度的提高，几乎所有大厂都在对面试进行改革。在这个浪潮的席卷之下，就算是传统的后端岗位也需要掌握相关的ai知识，特别是像美团、阿里、蚂蚁这些厂，传统的后端开发岗位也需要考察ai coding以及对于agent的相关理解。所以我的这个DocAI项目中既体现了后端开发高性能、微服务的设计特点，也整合了AI相关的技术，有RAG知识库、Knowledge Index、Chat ReAct、Plan-Execute 等。所以这个项目特别适合那些像我一样从传统后端往java+ai路径转化的同学。

目标

1. 构建智能文档分析能力

基于 Spring AI 及 MCP（模型控制平面）统一调度底层大模型，封装文档摘要、纠错、关键词提取等 AI Skills，实现多模型兼容与高性能任务处理，目标单任务平均响应耗时 $\leq 1200\text{ms}$ ，人工验收通过率 $\geq 90\%$ 。

2. 打造多范式 AI Agent 体系

设计并实现 Knowledge Index、Chat ReAct、Plan-Execute 等多种 Agent 结构，利用 Redis 管理多轮对话上下文与短期记忆，支撑知识索引、对话协作、规划执行等复杂场景，多轮对话任务完成率达到 85% 以上。

3. 落地企业级 RAG 知识库问答系统

构建文档向量化存储与检索架构，支持知识库增量同步，实现高召回率与高准确率的问答服务。目标 Top-5 召回率 $\geq 90\%$ ，检索支撑回答准确率 $\geq 80\%$ ，P95 检索响应时间 $\leq 500\text{ms}$ ，服务可用性 $\geq 99.9\%$ 。

4. 实现全流程文档管理微服务协同

通过微服务架构（Spring Cloud Alibaba）解耦用户、文件、文档与 AI 服务，利用 RabbitMQ 异步处理文档上传与 AI 任务调度，整合 MinIO 实现安全存储，结合 Redis 缓存热点数据，保障系统高并发下的性能与一致性。

5. 保障平台高可用与可扩展性

采用 Docker / Docker Swarm 容器化部署，实现服务弹性伸缩与故障自愈，支撑业务量增长时系统平稳运行，整体服务可用性不低于 99.95%。

对象创建与布局

对象创建与内存布局

对象创建流程

Q：在 Java 代码中 new 一个对象，JVM 底层具体执行了哪些步骤？

A：

当虚拟机遇到一条 `new` 指令时，主要会经历以下 5 个步骤：

1. 类加载检查：

- 首先检查这个指令的参数（即类名）能不能在常量池中定位到一个类的符号引用。
- 并且检查这个类是不是已经被加载、解析和初始化过。如果没有，必须先执行类加载过程。

2. 分配内存：

- 类加载通过后，JVM 就在堆中划分一块内存给新对象。对象所需的内存大小在类加载完成后便可完全确定。
- 分配策略：如果内存规整，用**指针碰撞**；如果内存不规整，用**空闲列表**。

3. 初始化零值：

- 内存分配完后，JVM 需要将分配到的内存空间都初始化为零值（比如 `int` 设为 0，`boolean` 设为 false，引用设为 null）。
- 这就是为什么我们在 Java 代码中定义成员变量不需要赋初值就能直接用的原因。

4. 设置对象头：

- 初始化零值后，JVM 要对对象头进行设置。比如：这个对象是哪个类的实例？它的哈希码是多少？它的 GC 分代年龄是多少？

5. 执行 **** 方法****：

- 上面 4 步完成后，从 JVM 视角看对象已经产生了，但从 Java 程序视角看，对象创建才刚开始。
- 此时会执行构造函数（`<init>` 方法），按照程序员的意愿对对象进行真正的初始化赋值。

追问1：两个线程同时new对象，分配内存怎么保证线程安全

JVM 主要有两种方案来解决并发冲突：

1. **CAS + 失败重试**：这是最通用的方法。JVM 采用 CAS 机制配合失败重试的方式，保证更新操作的原子性。
2. **TLAB 【重点】**：
 - 这是 JVM 的默认优化方案。
 - **原理**：每个线程在 Java 堆中预先分配一小块私有内存，也就是 **本地线程分配缓冲（TLAB）**。
 - 当线程需要 `new` 对象时，优先在自己的 TLAB 上分配。只有当 TLAB 用完了，才需要通过 CAS 去锁住堆内存来分配。这样大大减少了并发冲突。

内存布局

Q：一个 Java 对象在内存中由哪几部分组成？对象头里都有什么？

A：

在 HotSpot 虚拟机中，对象在内存中的布局可以分为三块区域：

1. **对象头【核心】**：它包含两部分信息。
 - **Mark Word（标记字段）**：存储对象自身的运行时数据，如 **HashCode**、**GC 分代年龄**、**锁状态标志**（偏向锁/轻量级锁/重量级锁）、线程持有的锁等。
 - **Klass Pointer（类型指针）**：对象指向它的类元数据的指针，虚拟机通过这个指针来确定这个对象是哪个类的实例。
 - （如果是数组，还有一块用于记录数组长度）
2. **实例数据**：这是对象真正存储的有效信息，也就是我们在代码里定义的各种成员变量（字段）的内容。
3. **对齐填充**：这不是必须的，仅仅起占位符的作用。因为 HotSpot 规定对象的起始地址必须是 **8 字节的整数倍**。如果实例数据不够 8 字节，就需要填充对齐。

追问1：为什么对象的 GC 年龄最大是 15

这个限制是写死在对象头里的。在 **Mark Word** 中，用于存储 GC 分代年龄（GC Age）的区域只有 **4 个比特位（4 bit）**。二进制的 `1111` 换算成十进制就是 **15**。所以，一旦对象熬过了 15 次 GC，它的

年龄就会溢出这 4 位，JVM 规定它必须晋升到老年代。（注：CMS 默认为 6，但最大物理上限就是 15）

对象创建的完整过程

Q：new 一个对象时，JVM 里到底发生了什么？

A：

可以概括为下面几步：

1. 类加载检查

当执行 `new` 指令时，JVM 会先检查这个类是否已经被加载、链接和初始化。

如果还没有，就要先执行类加载。

2. 分配内存

类加载完成后，对象所需要的内存大小就确定了，JVM 会在堆中为对象分配一块连续的内存空间。

3. 处理并发安全问题

因为对象创建在高并发场景下可能有多个线程同时进行，所以 JVM 需要保证分配内存时线程安全。

常见做法是 **CAS + 失败重试**，或者通过 **TLAB** 让线程优先在自己的私有分配区中分配。

4. 初始化零值

内存分配完成后，JVM 会先把对象的实例字段都初始化为零值。

比如 `int` 为 `0`，引用类型为 `null`，这是为什么对象即使我们没手动赋值，也有默认值。

5. 设置对象头

JVM 会把对象头信息写进去，比如哈希码、GC分代年龄、锁状态、类型指针等。

6. 执行构造方法

最后再执行对象的构造方法，也就是 `init` 对应的逻辑，按程序员写的代码完成真正的初始化。

总结一下就是：先检查类，再分配内存，再设默认值和对象头，最后执行构造方法。

追问1：对象在堆里是怎么分配内存的？

答：

主要有两种方式：

1. 指针碰撞

如果堆内存是规整的，已用内存和空闲内存之间有明确边界，那么只需要把指针往空闲方向移动一段对象大小的距离即可。

2. 空闲列表

如果堆内存不是规整的，JVM 就需要维护一张空闲列表，记录哪些内存块可用，再从中找到合适空间分配给对象。

用哪种方式，取决于垃圾回收器是否会整理内存。

对象内存布局

Q：Java 对象在内存中的布局是怎样的？

A：

在 HotSpot 虚拟机里，一个普通对象在内存中一般分为三部分：

1. 对象头 (Header)

存储对象的运行时元数据，比如哈希码、GC分代年龄、锁状态、类型指针等。

2. 实例数据 (Instance Data)

也就是真正存储成员变量值的地方，包括当前类和父类继承下来的实例字段。

3. 对齐填充 (Padding)

HotSpot 要求对象大小通常按 **8 字节对齐**，所以如果前两部分加起来不是 8 的倍数，就需要补齐。

需要注意两点：

1. 静态变量不在对象实例里

静态变量属于类，不属于对象，它存放在方法区 / 元空间对应的类元数据中。

2. 成员变量的存储顺序不一定完全等于代码声明顺序

JVM 可能会为了对齐和节省空间，对字段顺序做一定调整。

追问1：对象头里都有什么？为什么 synchronized 会和对象头扯上关系？

答：

对象头里最核心的两部分是：

1. Mark Word

用来存对象运行时信息，比如哈希码、GC分代年龄、锁状态标志等。

2. Klass Pointer (类型指针)

指向这个对象所属类的元数据，JVM 通过它知道这个对象到底是哪个类的实例。

如果是数组对象，对象头里通常还会多一个数组长度字段。

之所以 `synchronized` 会和对象头扯上关系，是因为锁状态信息就记录在对象头的 Mark Word 里，所以我们常说 Java 里“锁是加在对象上的”，本质上和对象头是直接相关的。

追问2：一个空对象占多少字节？

答：

一般来说，在 64 位 HotSpot JVM 并开启压缩指针 的常见场景下，一个空的 `Object` 通常占 16 字节。

原因是：

1. 对象头通常占 12 字节
2. HotSpot 要求按 8 字节对齐
3. 所以最终会补齐到 16 字节

注意这是常见情况，不是绝对值，具体大小和 JVM 参数、是否开启指针压缩都有关系。

对象访问定位

Q：栈里的引用变量，是怎么定位到堆中的对象的？

A：

主要有两种方式：

1. 句柄访问

栈中的引用先指向句柄，句柄里再保存对象实例地址和类型数据地址。

2. 直接指针访问

栈中的引用直接保存对象地址，对象头里再通过类型指针找到类元数据。

HotSpot 虚拟机一般采用的是直接指针访问，因为这样少了一次间接寻址，访问速度更快。

对象分配的常见规则

Q：对象一般是怎么进入新生代、老年代的？

A：

一般有下面几种常见规则：

1. 大多数新对象优先分配在 Eden 区
这是最常见的情况。
2. 如果本线程的 TLAB 没满，会优先在 TLAB 中分配
这样可以减少多线程分配内存时的锁竞争。
3. 大对象有可能直接进入老年代
因为大对象如果频繁在新生代复制，成本会比较高。
4. 长期存活的对象会晋升到老年代
对象每熬过一次 Young GC，年龄会增加，到达阈值后就会晋升。
5. 如果 Survivor 放不下，也可能提前晋升到老年代
这本质上是空间分配担保的结果。

总结来说就是：新对象一般先进新生代，但大对象、长寿命对象或者 Survivor 放不下的对象，可能会更早进入老年代。

JVM内存区域

JVM内存区域

JVM运行时数据区

Q: 介绍一下 JVM 的运行时数据区（内存结构）？哪些是线程共享的，哪些是私有的？

A:

JVM 在运行 Java 程序时，会把内存划分为 5 个区域。

为了逻辑清晰，我习惯把它们按照生命周期和是否线程共享分为两类：

第一类是线程私有的，随线程生灭，**不需要垃圾回收（GC）**；**第二类是线程共享的**，也是 GC 重点关注的区域。

下面我具体展开说一下。

首先是**线程私有**的区域，包含三个部分：

1. **程序计数器**：它的作用是记录当前线程执行到哪一行字节码了。

- **为什么需要它？** 因为 CPU 会在不同线程间切换，当切回来的时候，线程得知道自己刚才执行到哪儿了。
- **特点：**这是 JVM 中唯一一个不会发生内存溢出（OOM）的区域。

2. **虚拟机栈**：这是我们平时最常说的栈，它是 Java 方法执行的内存模型。

- 每个方法在执行时都会创建一个**栈帧**，里面存了局部变量表、操作数栈等信息。方法调用入栈，执行完出栈。
- **异常：**如果递归太深，会爆出 `StackOverflowError`；如果申请不到内存，会爆出 `OOM`。

3. **本地方法栈（Native Method Stack）**：这个和虚拟机栈逻辑一样，只不过它是服务于 `Native` 方法（比如 C++ 写的底层方法）的。

- **注：**在 HotSpot 虚拟机中，其实直接把这两个栈合二为一了。”

接下来是**线程共享**的区域，这也是出现问题最多的地方

1. **堆**：这是 JVM 内存中最大的一块。**几乎所有的对象实例和数组**都在这里分配内存。

- **关注点：**它是垃圾回收器（GC）的主要工作场所。我们常说的‘新生代’、‘老年代’划分，就是指在这里。
- **异常：**如果对象太多塞满了，就会报 `OutOfMemoryError: Java heap space`。

2. **方法区**：它存储了已被虚拟机加载的**类信息、常量、静态变量**等数据。

- **版本差异（亮点）：**在 **JDK 1.7 及以前**，它在实现上叫‘永久代’（PermGen），且位于堆内存中，容易导致 OOM。而在 **JDK 1.8 及以后**，JVM 移除了永久代，改用在本地内存（Native Memory）中实现的**元空间（Metaspace）**。这样做的好处是方法区不再受堆内存大小的限制，减少了 OOM 的风险。”

总结一下：**栈管运行，堆管存储**。栈是线程私有的，堆和方法区是线程共享的。

追问1： 这些区域里，哪些会发生 OOM（内存溢出）

除了程序计数器以外，其他 4 个区域都有可能发生 OOM。

1. 堆：最常见。对象太多且无法回收时，报 `OutOfMemoryError: Java heap space`。
2. 方法区：加载的类太多（比如 Spring 动态代理生成太多类），报 `OutOfMemoryError: Metaspace`。
3. 栈：虽然平时更多报的是 `StackOverflowError`（递归太深），但如果线程请求的栈深度大于允许深度，或者创建太多线程导致内存耗尽，也会报 OOM。

栈与堆的区别

Q：简单说一下JVM里栈和堆的区别是什么？

A：

可以从三个维度来区分：

1. 存储内容：

- 栈主要存储局部变量（基本数据类型、对象的引用）和方法调用的上下文。
- 堆存储的是实际的对象实例（`new` 出来的东西）。

2. 内存管理：

- 栈是自动管理的，方法结束了自动出栈释放，不需要 GC。
- 堆是手动管理（C++）或 GC 管理（Java）的，是垃圾回收的主要场所。

3. 物理地址：

- 栈通常是连续的内存空间（速度快）。
- 堆是不连续的内存空间，通过链表等方式维护（灵活但稍慢）。

追问1： 什么是栈溢出（StackOverflow）？什么情况下会发生

`StackOverflowError` 是指线程请求的栈深度超过了虚拟机允许的深度。最典型的场景就是死递归（递归方法没有出口），或者递归层级过深。每一次方法调用都会压入一个栈帧，如果一直压栈不弹栈，内存很快就爆了。

JDK1.8的变化

Q: JDK 1.8 在内存区域上有什么重大变化? 为什么要用元空间替代永久代

A:

最大的变化是: 移除了永久代, 引入了元空间。在 JDK 1.7 及之前, 方法区是堆内存的一部分 (永久代)。而在 JDK 1.8 中, 元空间使用的是本地内存, 不再占用 JVM 的堆内存。


为什么要替换? 主要有两个原因:

1. **避免 OOM**: 永久代的大小是启动时固定的, 很难调整。现在的应用 (尤其是 Spring 这种大量使用动态代理的框架) 会动态生成很多类, 很容易把永久代撑爆。而元空间直接使用服务器的物理内存, 上限大得多。
2. **合并 HotSpot 和 JRockit**: 当年 Oracle 收购了 JRockit, JRockit 里面就没有永久代, 为了代码统一, 就把 HotSpot 的永久代也去掉了。

追问1: 元空间既然用的是本地内存, 是不是就永远不会 OOM 了

不是的, 依然会 OOM。虽然本地内存很大, 但不是无限的。如果在生产环境中, 我们没有限制元空间大小 (默认是无限), 且程序有 Bug 导致动态疯狂生成类, 可能会把服务器所有的物理内存吃光, 导致整个服务器宕机 (被系统 Kill 掉)。所以线上环境我们通常还是会配置 `-XX:MaxMetaspaceSize` 来兜底。

图解补充: 运行时数据区总览



对比补充：哪些区域会 OOM

区域	是否线程共享	主要存什么	是否 GC 重点区域	典型异常
程序计数器	否	当前线程字节码位置	否	基本不会 OOM
虚拟机栈	否	栈帧、局部变量、操作数栈	否	<code>StackOverflowError</code> / OOM
本地方法栈	否	Native 方法调用信息	否	OOM
堆	是	对象实例、数组	是	<code>Java heap space</code>
方法区/元空间	是	类元数据、常量、静态变量	重点但不如堆常见	<code>Metaspace</code>

高频追问补充

追问补充1：为什么说“栈管运行，堆管存储”？

因为方法执行过程中的上下文信息主要在栈里，比如局部变量、操作数栈、方法调用链；而真正 `new` 出来的对象通常在堆里。这样回答能快速把栈和堆的职责区分开。

追问补充2：元空间移到本地内存之后，线上就不用管了吗？

不是。元空间虽然不再占用堆，但依然吃机器内存。如果动态生成类很多，比如代理类暴涨、类加载器泄漏，照样会把机器内存打满，所以线上一般还是会限制 `MaxMetaspaceSize`。

速记版

内存区域建议按这条线记：

- 三私有：程序计数器、虚拟机栈、本地方法栈
- 两共享：堆、方法区/元空间
- 堆是 GC 主战场
- JDK8 之后永久代换成元空间

一句话面试版：

JVM 运行时内存区域可以先按线程私有和线程共享来分，私有区偏执行上下文，共享区偏对象和类元数据存储。

垃圾回收

垃圾回收

垃圾回收是 JVM 面试里非常核心的一条线，常见考法一般会从“对象什么时候会被回收”开始，再追问到垃圾回收算法、垃圾回收器、三色标记和根可达性。

如何判断对象是否可回收

Q: JVM 如何判断一个对象是否可以被回收?

现在主流 JVM 采用的是 **可达性分析算法**，而不是单纯的引用计数。

它的思路是：从一组称为 **GC Roots** 的根对象出发，沿着引用关系向下搜索。

如果一个对象从 GC Roots 出发不可达，那么这个对象就可以被判定为垃圾对象。

常见的 GC Roots 包括：

- 虚拟机栈中引用的对象
- 方法区中类静态属性引用的对象
- 方法区中常量引用的对象
- 本地方法栈 JNI 引用的对象

之所以不用引用计数，核心原因是 **它无法解决循环引用问题**。

常见的垃圾回收算法

Q: 常见的垃圾回收算法有哪些?

常见垃圾回收算法主要有四种：

第一种，标记-清除。

先标记存活对象，再清理未标记对象。优点是实现简单；缺点是会产生内存碎片。

第二种，复制算法。

把内存分成两块，每次只使用一块；回收时把存活对象复制到另一块。优点是不会有内存碎片；缺点是浪费一半空间。

第三种，标记-整理。

先标记存活对象，再把存活对象向一端移动，最后直接清理边界外内存。优点是不会有碎片；缺点是整理对象成本较高。

第四种，分代收集。

这不是一种具体算法，而是一种组合思想：年轻代和老年代的对象特点不同，所以采用不同算法更合适。

分代回收思想

Q：为什么 JVM 要做分代回收？

因为不同区域的对象生命周期分布非常不一样。

年轻代的对象特点是：**创建多、死亡快、存活率低。**

所以年轻代更适合复制算法，回收效率高。

老年代的对象特点是：**存活率高、对象体积更大。**

如果还用复制算法，成本就太高了，所以老年代通常更适合标记-清除或标记-整理。

所以分代回收的本质是：

针对不同对象生命周期，采用更匹配的回收策略。

三色标记法

Q：什么是三色标记法？

三色标记法是并发标记过程中常用的一种抽象模型，用来描述对象的扫描状态。

- **白色**：还没被标记，理论上可能是垃圾
- **灰色**：已经被标记，但它引用的对象还没扫描完
- **黑色**：已经被标记，而且它引用的对象也都扫描完成

并发标记时，GC 线程和用户线程可能同时修改对象引用关系。

如果处理不好，就可能出现“本来应该存活的对象被漏标”的问题。

因此现代垃圾回收器通常会配合：

- **增量更新**
- **SATB（原始快照）**

来修正并发标记带来的问题。

常见垃圾回收器

Q：常见的垃圾回收器有哪些？怎么选？

常见垃圾回收器可以按代际来看：

年轻代 常见有：

- Serial
- ParNew
- Parallel Scavenge

老年代 常见有：

- Serial Old
- CMS
- Parallel Old

整堆/区域化回收器 常见有：

- G1
- ZGC
- Shenandoah

如果是 JDK8 时代的常见答案，面试最常问的是 **CMS** 和 **G1**；

如果是更新一点的版本，也可能会问 **ZGC**。

追问1：G1 的特点是什么？

G1 的核心特点是把整个堆划分成很多 Region，不再机械区分连续的年轻代和老年代空间。

它会优先回收“垃圾最多、收益最高”的 Region，因此叫 Garbage First。

它的优势是：

- 更适合大堆
- 可预测停顿时间
- 整体吞吐和停顿之间比较均衡

CMS 和 G1 的区别

Q：CMS 和 G1 有什么区别？


CMS 更强调低停顿，它的老年代回收流程里大量使用并发标记和并发清理。
缺点是会产生内存碎片，而且对 CPU 资源比较敏感。

G1 是区域化回收器，兼顾吞吐和停顿，更适合大堆和需要可控停顿的场景。
它可以通过目标停顿时间来做一定程度的回收调度。

所以工程里如果让我给面试官一个简短判断：

- JDK8 以前很多系统会选 CMS
- 现在更常见的默认方案是 G1

图解补充：GC Roots 与可达性分析



对比补充：回收算法怎么区分

算法	核心动作	优点	缺点	适合场景
标记-清除	标记后直接清理	实现简单	有碎片	老年代早期方案
复制	存活对象复制到新区域	无碎片、效率高	浪费空间	年轻代
标记-整理	标记后压缩存活对象	无碎片	移动对象成本高	老年代
分代收集	不同代组合不同算法	更贴合对象生命周期	实现更复杂	现代 JVM

对比补充：常见回收器怎么答

回收器	关键词	优势	典型短板
CMS	低停顿	老年代并发回收	碎片、多核依赖强
G1	Region、可预测停顿	大堆更友好	调优理解成本更高
ZGC	超低停顿、染色指针	超大堆场景优秀	版本要求更高

高频追问补充

追问补充1：为什么引用计数不适合作为主流回收方案？

因为它很难处理循环引用。两个对象互相引用时，即使业务上已经没人能访问它们了，引用计数也不为 0，无法回收。

追问补充2：三色标记为什么会漏标？

因为并发标记期间，用户线程可能同时改引用关系。如果一个黑对象新增了对白对象的引用，而灰对象到白对象的旧引用又被删掉，就可能让白对象被漏标。所以才需要 SATB 或增量更新这类补偿机制。

追问补充3：面试里 CMS 和 G1 怎么快速选型？

如果是老系统背景，可以说 CMS 曾经因为低停顿用得很多；如果是新系统或新版本，通常优先考虑 G1，因为它已经是更主流、更稳妥的默认方案。答题重点不是“背历史”，而是讲清楚停顿、碎片和大堆场景的权衡。

速记版

垃圾回收建议按这条线记：

- 先讲怎么判断垃圾：可达性分析
- 再讲算法：标记清除、复制、整理、分代
- 再讲并发标记：三色标记、SATB、增量更新
- 最后讲回收器：CMS、G1、ZGC

一句话面试版：

JVM 垃圾回收的本质，是先判断对象是否还可达，再根据对象生命周期和停顿目标选择合适的回收算法和回收器。

类加载机制

类加载机制

类加载的生命周期

Q：Java 类是从哪里来的？讲一下类加载的整个流程？

A：

Java 的类加载机制是指把 `.class` 文件加载到内存，并进行校验、解析和初始化，最终形成可以被虚拟机直接使用的 Java 类型。整个过程分为 5 个阶段：

1. 加载：通过类的全限定名（包名+类名）找到 `.class` 二进制流，把它读进内存，并在堆中生成一个 `java.lang.Class` 对象作为访问入口。
2. 验证：检查这个字节码是不是合法的（比如文件头是不是 `0xCAFEFABE`），防止恶意代码破坏 JVM。
3. 准备【重点】：为类的静态变量（static）分配内存，并设置默认初始值。
 - 注意：这里是设置默认值（比如 `int` 为 0，`Object` 为 null），而不是代码里写的那个值。
4. 解析：把常量池里的符号引用（比如仅仅是个字符串 "ArrayList"）替换为直接引用（内存中的实际地址指针）。
5. 初始化【重点】：这是类加载的最后一步。
 - 这时候才真正执行类中定义的 Java 代码（也就是 `static` 代码块和 `static` 变量的赋值操作）。

追问1：什么时候会触发类的初始化？

JVM 规定了只有 主动引用 时才会初始化，常见的场景有：

1. `new` 一个对象时。
2. 读取或设置一个类的静态字段（static）时。
3. 调用类的静态方法时。

4. 对类进行反射调用（`Class.forName`）时。
5. 初始化一个子类时，如果父类还没初始化，会先触发父类的初始化。

双亲委派模型（核中核，必须背熟）

Q：什么是类加载器？什么是双亲委派模型？为什么要这么设计？

A：

首先，类加载器的作用就是把编译好的 `.class` 字节码文件加载到 JVM 内存中。在 JDK 8 及之前的版本中，主要有三个核心的类加载器，它们呈层级关系：

1. **启动类加载器**：它是最顶层的。负责加载 JDK 的核心类库（即 `JAVA_HOME/lib` 目录下的类，比如 `String`、`System` 等）。
 - 注意点：它是由 C++ 实现的，所以我们在 Java 代码里拿不到它的引用（会返回 `null`）。
2. **扩展类加载器**：它负责加载 JDK 的扩展库（`JAVA_HOME/lib/ext` 目录）。
3. **应用类加载器**：这是我们平时接触最多的。它负责加载 `Classpath` 下的类，也就是我们自己的代码和引入的第三方 jar 包。”

所谓双亲委派模型，其实不是指有两个父母，而是指‘父辈委托’机制。它的核心逻辑可以概括为八个字：‘向上委托，向下加载’。

具体流程是这样的：当一个加载器（比如应用类加载器）收到类加载请求时，它不会自己先去加载，而是把这个请求原封不动地委托给父加载器去尝试。每一层都是如此，直到请求传送到最顶层的 **Bootstrap ClassLoader**。

- 如果父加载器在自己的搜索范围内找到了这个类，就成功返回；
- 只有当父加载器反馈‘我加载不了’（找不到）时，子加载器才会尝试自己去加载。

这么设计主要有两个目的：**安全和避免重复加载**。最核心的是**安全**。

举个最经典的例子：假设有人恶意写了一个 `java.lang.String` 类，里面植入了破坏系统的代码。

- **如果没有双亲委派**：应用类加载器可能直接就加载了这个恶意的 `String` 类，那整个系统的 `String` 就被替换了，JVM 也就崩溃了。
- **有了双亲委派**：当加载请求向上委托到 `Bootstrap ClassLoader` 时，它发现自己负责的 `rt.jar` 里已经有了 `java.lang.String`，它就会直接加载 JDK 自带的那个安全的 `String` 类。

这样，恶意的类就永远没有机会被加载进来。这就保证了 **Java 核心类库的安全性（沙箱安全机制）**

追问1: 父加载器是子加载器的父类吗?

不是继承关系, 而是组合关系。它们在代码层面并没有 `extends` 关系, 而是通过一个 `parent` 成员变量持有父加载器的引用。这是一种包含关系, 不是类继承

怎么打破双亲委派

Q: 有什么场景需要打破双亲委派, 怎么打破

A:

双亲委派不是强制约束, 而是一种建议

场景一: Tomcat

- Tomcat 上可能部署了两个 Web 应用。应用 A 依赖 Spring 4, 应用 B 依赖 Spring 5。
- 如果遵循双亲委派, 类加载器只会加载一份 Spring (假设是 4)。那应用 B 也是用的 Spring 4, 启动就报错了。
- **解决**: Tomcat 自定义了 `WebAppClassLoader`, 它重写了 `loadClass` 方法。优先自己加载 `WEB-INF/classes` 下的类, 加载不到再给父类。这样就实现了应用间的隔离。

场景二: JDBC

- JDBC 的接口 (`java.sql.Driver`) 是 Java 核心包, 由 Bootstrap 加载。
- 但具体的驱动实现 (如 MySQL Driver) 是厂商提供的第三方 Jar 包, 在 Classpath 下, 由 Application 加载器加载。
- **矛盾**: Bootstrap 加载的代码 (DriverManager) 需要去调用 Application 加载的代码 (MySQL Driver), 这违反了双亲委派 (父调子)。
- **解决**: 利用 线程上下文类加载器 (Thread Context ClassLoader)。核心类通过 `Thread.currentThread().getContextClassLoader()` 拿到应用类加载器, 去加载第三方的实现类。

JVM调优实战

JVM 调优这块，面试官更看重你是不是有“问题驱动”的思维，而不是背参数大全。回答时最好按“现象 -> 排查 -> 结论 -> 调整方案”来讲。

JVM 调优的基本思路

Q：你做过 JVM 调优吗？一般怎么做？

如果让我概括 JVM 调优的基本思路，我会分成四步：**第一步，先看现象**。接口 RT 抖动Full GC 频繁Young GC 特别频繁CPU 飙高内存持续上涨**第二步，看监控**。堆使用率GC 次数和停顿时间老年代增长趋势晋升速率对象分配速率**第三步，定位原因**。比如是年轻代太小、对象创建过快、存在内存泄漏、还是垃圾回收器不适配业务场景。**第四步，再做参数调整**。调优应该基于现象和监控，不是先拍脑袋改参数。

常见调优场景

Q：Young GC 很频繁，你会怎么排查？

Young GC 频繁通常说明年轻代压力过大，常见原因有：年轻代空间偏小短生命周期对象创建太多批量操作导致瞬时分配过高排查时我会重点看：Eden 区是否很快被打满对象分配速率是否异常接口是否存在大对象创建、重复对象创建优化方向通常包括：适当调大年轻代减少无意义对象创建优化批量逻辑，降低瞬时分配峰值

Q：Full GC 频繁怎么办？

Full GC 频繁比 Young GC 更危险，因为它往往意味着停顿更长，对线上 RT 影响更明显。常见原因包括：老年代空间不足对象晋升过快大对象直接进入老年代存在内存泄漏排查思路一般是：看老年代占用是否持续上涨看 Full GC 后内存是否能明显回落如果回落不明显，就要怀疑内存泄漏结合 dump 文件分析大对象和引用链

调优时常见的参数关注点

Q：JVM 调优时你会关注哪些参数？

我会优先关注这些参数：`-Xms`、`-Xmx`：初始堆和最大堆`-Xmn`：年轻代大小`-XX:SurvivorRatio-XX:MaxTenuringThreshold-XX:+UseG1GC` 等垃圾回收器选择参数`-XX:MaxGCPauseMillis`：目标停顿时间但面试里我不会把重点放在背参数上，而是强调：**参数只是工具，关键是它要和实际业务现象对应起来。**

如何选择垃圾回收器

Q：垃圾回收器怎么选？

一般我会结合三点来选：机器资源情况业务更关注吞吐还是停顿堆大小和对象生命周期分布如果是比较新的业务系统，而且希望停顿更可控，我会优先考虑 G1。如果是对极低停顿要求非常高、JDK 版本也匹配，才会进一步

考虑 ZGC 这类更先进的回收器。

【了解】执行引擎与JIT

执行引擎与JIT

执行引擎和 JIT 一般不是最前面的基础题，但很适合拿来体现你对 JVM“不是只会背堆和栈”的理解深度。

Java 是编译型还是解释型

Q: Java 是编译型语言还是解释型语言？

更准确的说，Java 同时包含了 **编译** 和 **解释** 两个阶段。源码先通过 `javac` 编译成字节码，这是编译阶段；运行时，JVM 先解释执行字节码，在热点代码达到一定阈值后，再通过 JIT 编译成本地机器码执行。所以如果面试官这样问，我不会简单回答“Java 是编译型”或者“Java 是解释型”，而是会说：**Java 是先编译成字节码，再由 JVM 解释执行并结合 JIT 动态优化。**

JIT 是什么

Q: 什么是 JIT？

JIT 指的是 **Just In Time Compiler**，也就是即时编译器。它的作用是把热点字节码编译成本地机器码，提高运行效率。如果一直纯解释执行，灵活是灵活，但性能不够高；JIT 的意义就在于：**把最值得优化的那部分代码进一步编译优化。**

为什么热点代码更适合 JIT

Q: 为什么 JVM 一开始就把所有代码都编译成机器码？

因为 JIT 编译本身也是有成本的。如果一开始就把所有代码全部编译：启动会变慢很多根本不会高频执行的代码也会被白白编译内存占用也会更高所以 JVM 的策略更聪明：**先解释执行，等某段代码真的成为热点，再去编译优化。**这是一种典型的“按需优化”思路。

集合

集合

对于集合的考察，面试官比较喜欢上来先问你自己在项目中会用什么集合，怎么用的

这种类型的问题其实很常见，因为可以考察你的知识广度和深度，回答的时候要从两方面回答

1. 先大而广地罗列一下，讲一下主要区别

面试官你好，Java 集合框架主要分为两条主线，**Collection** 接口和 **Map** 接口，**Collection** 下主要有三个子接口：**List**（有序、可重复）、**Set**（无序、唯一）和 **Queue**（队列），**Map** 接口则是存储键值对（Key-Value）的结构。

在具体实现上，常用的有 `ArrayList`、`LinkedList`、`HashSet`、`TreeSet`，以及最核心的 `HashMap`、`ConcurrentHashMap` 和 `TreeMap`

2. 然后有侧重地介绍自己比较熟悉的

比如我项目里面规则树的实现，为了在决策过程中实现 $O(1)$ 级别的节点跳转，我用 `HashMap` 来存储节点 ID 与其对应逻辑实体的映射关系。

3. 在这之后面试官就会顺着你讲的展开了，这样子面试的节奏就是你的了

集合的话我比较推荐看 `hashmap`，因为 `hashmap` 的八股是集合里比较有深度的，可以展示你的水平

类似的问题也有会出现在 `redis` 八股的考察，会问你 `redis` 有哪些数据结构，你在项目中会用什么，怎么用。

ArrayList与LinkedList的区别

- 底层结构：

- `ArrayList` 基于动态数组。它在内存中是连续存储的。
- `LinkedList` 基于双向链表（JDK1.7 之后）。它的节点在内存中是分散存储的，通过指针连接。

- 性能差异：

- **查询**：`ArrayList` 支持随机访问，通过下标能直接算出地址，复杂度是 $O(1)$ 。`LinkedList` 需要从头遍历，复杂度是 $O(n)$ 。

- 增删：
 - LinkedList 在已知节点的情况下，增删只需改动指针，是 $O(1)$ 。
 - ArrayList 如果在中间增删，需要挪动后续所有元素，是 $O(n)$ 。

追问1：你在项目中怎么选这两种数据结构

- 绝大多数场景（90%）我都会选 ArrayList。
 - 原因：除了支持快速查询，ArrayList 的连续内存对 CPU 缓存（Cache Line）非常友好，遍历速度极快。而 LinkedList 内存分散，容易造成缓存未命中。
 - 只有在‘需要频繁在头部或中间插入删除，且几乎不随机访问’的极少数特殊场景下，我才会考虑 LinkedList。”

追问2：你说 LinkedList 插入更快，那我在 List 中间插入 1000 万条数据，谁更快？

这要看情况。如果是用 `for` 循环根据下标 `i` 去插入，ArrayList 反而更快。因为 LinkedList 每次都要 `get(i)` 遍历找到位置，这一步就是 $O(n)$ ，总复杂度变成 $O(n^2)$ 。只有用 `Iterator` 遍历并插入，LinkedList 才能发挥 $O(1)$ 插入的优势。

追问3：ArrayList 是线程安全的吗？如果不安全怎么办？

不安全。多线程下建议使用 `CopyOnWriteArrayList`（适合读多写少）或者用 `Collections.synchronizedList` 包装一下

ArrayList的扩容机制

ArrayList 的扩容主要发生在 `add` 操作时。

1. 初始化：在 JDK 1.8 中，如果使用无参构造器，它初始化的是一个空数组（懒加载）。只有当第一次 `add` 添加元素时，才会初始化为默认容量 10。
2. 触发条件：当当前元素个数等于数组容量时，就会触发扩容。
3. 增长策略：新容量通常是旧容量的 1.5 倍。
 - 源码细节：`int newCapacity = oldCapacity + (oldCapacity >> 1);`（右移一位相当于除以 2）。
4. 数据迁移：计算好新容量后，底层会调用 `Arrays.copyOf`（本质是 `System.arraycopy`），在堆中创建一个新数组，把老数据复制过去，然后丢弃老数组。

追问1: 既然扩容需要复制数组, 效率很低, 怎么优化

最直接的优化就是**预估容量**。如果我能预知列表大概要存 1000 个对象, 我就直接 `new ArrayList<>(1000)`。这样就避免了中间多次的扩容 (10 -> 15 -> 22...), 既省了时间也减少了数组碎片的产生。

HashMap的底层原理 (重要)

HashMap 的底层结构在JDK 1.7 和 1.8 中是有区别的, 我分开来讲, JDK 1.7采用的是**数组+链表**的结构, 而 JDK 1.8 做了优化, 采用了**数组+链表+红黑树**的结构。

具体的插入流程 (put) 是这样的

1. 首先, 根据 Key 计算 Hash 值, 经过扰动函数处理后, 通过 $(\text{数组长度}-1) \& \text{键的哈希值}$ 公式确定它在数组中的下标。
2. 如果该位置为空, 直接插入。
3. 如果该位置已经有数据了 (发生Hash冲突), 会遍历链表检查Key是否存在:
 - 如果Key相同, 就覆盖Value。
 - 如果Key不同, JDK 1.8 会判断当前节点是链表还是红黑树。如果是链表, 采用**尾插法**追加到末尾; 如果是红黑树, 则调用树的插入方法。
4. **重点是**, 在 JDK 1.8 中, 当链表长度超过 8 且数组长度大于等于 64 时, 链表会转换为红黑树, 这样能将查找复杂度从 $O(n)$ 降低到 $O(\log n)$, 解决链表过长导致的性能下降问题。


追问1: 为什么 JDK 1.8 要用尾插法? 1.7 的头插法有什么问题

JDK 1.7 用头插法是因为作者认为最新插入的数据被访问的概率更大。但在**多线程并发扩容**时, 头插法会改变链表的顺序, 容易导致**环形链表**, 从而引发死循环 (CPU 100%)。1.8 改用尾插法, 扩容后链表顺序保持不变, 就解决了这个问题。

追问2: HashMap的扩容机制是怎么样的 (重要)

HashMap 默认初始容量是 16, 加载因子是 0.75。当元素数量超过 `容量 * 0.75` 时, 就会触发扩容, 容量变为原来的**2倍**。扩容时需要重新计算每个元素在数组中的位置。不过 JDK 1.8 做了优化, 不需要重新 Hash, 只需要看 hash 值新增的那一位比特是 0 还是 1。如果是 0, 位置不变; 如果是 1, 位置变为 `原索引 + 原容量`。这样效率更高。

帮理解解的例子



追问3：为什么 HashMap 的容量必须是 2 的幂

为了支持两个优化：

1. **极速寻址**：只有当容量是 2 的幂时，`hash % 容量` 才能等价于位运算 `hash & (容量 - 1)`，位运算比取模快得多。
2. **扩容优化**：就是刚才讲的，利用高位比特判断位置，避免重新 Hash。

追问4：HashMap 是线程安全的吗

HashMap **不是**线程安全的。在多线程环境下使用它，主要会产生两个严重问题：

1. **数据丢失（覆盖）**：这是最常见的问题。
 - 在 JDK 1.7 和 1.8 中都存在。当两个线程同时进行 `put` 操作，并且 Key 的 Hash 值冲突时，它们可能会同时判断“当前位置为空”。
 - 于是，线程 A 刚准备插入，线程 B 抢先插入了。等线程 A 恢复执行时，它不知道该位置已经被占了，就会直接写入，把线程 B 的数据覆盖掉。
2. **死循环（CPU 100%）**：这是 JDK 1.7 的经典 Bug。
 - JDK 1.7 在扩容时采用的是**头插法**。
 - 在并发扩容时，如果链表结构被破坏，可能会导致链表成环（A指向B，B又指向A）。

- 当下次 `get` 操作遍历这个链表时，程序就会进入死循环，导致服务器 CPU 飙升。
- 补充：虽然 JDK 1.8 改用了尾插法解决了死循环问题，但数据覆盖的问题依然存在，所以它依然是不安全的。

补充，生产环境要使用线程安全的map有三种方案

1. **Hashtable**：虽然安全，但它给所有方法都加了 `synchronized`，锁粒度太粗，全表只有一把锁，效率极低，现在基本没人用了。
2. **Collections.synchronizedMap**：它是对 `HashMap` 做了一层包装，本质上也是用 `synchronized` 锁住整个 `Map`，并发性能依然不高。
3. **ConcurrentHashMap**：这是最佳选择。它通过降低锁粒度（分段锁或节点锁）实现了高效的并发。

ConcurrentHashMap的实现原理

`ConcurrentHashMap` 的核心思想是分而治之，尽量缩小锁的范围。JDK 1.7 和 1.8 的实现差异很大：

1. JDK 1.7：分段锁

- **结构**：它由一个 `Segment` 数组组成。每个 `Segment` 本质上继承了 `ReentrantLock`。
- **原理**：它把一个大的 `HashMap` 切分成了 16 个小段（`Segment`）。
- **并发度**：理论上支持 16 个线程并发写入，只要它们访问的是不同的段，就不会互斥。
- **缺点**：并发度受限于 `Segment` 的个数，且 `Segment` 对象本身占用不少内存。

2. JDK 1.8：CAS + Synchronized

- **结构**：摒弃了 `Segment`，结构和 `HashMap 1.8` 一样（数组+链表+红黑树）。
- **原理**：
 - 它直接锁链表/红黑树的头节点。
 - 如果是第一次插入（桶为空）：利用 **CAS** (`Compare And Swap`) 指令进行无锁插入，速度极快。
 - 如果发生冲突（桶不为空）：使用 `synchronized` 锁住当前桶的头节点。
- **优势**：锁粒度细化到了每一个 `Node`（桶）。只要 `Hash` 不冲突，几千个线程都能并发写，性能比 1.7 提升巨大。”

追问1：为什么 JDK 1.8 要把 `ReentrantLock` 换成 `synchronized`? `synchronized` 不是性能很差吗

这其实是一个误区。

1. **JDK 优化**：从 JDK 1.6 开始，JVM 对 `synchronized` 做了大量优化（偏向锁、轻量级锁、锁消除

等），在低竞争下，它的性能已经不输 ReentrantLock 了。

- 2. **节省内存**：ReentrantLock 需要创建额外的 Segment 对象，而 synchronized 直接锁住 Node 对象头，不需要额外内存。
- 3. **自动释放**：synchronized 自动释放锁，而 Lock 必须手动 unlock，代码更简洁安全。


追问2：ConcurrentHashMap 的 Key 和 Value 能为 null 吗？为什么？

坚决不能（HashMap 可以）。

原因：主要是为了避免二义性（Ambiguity）。假设我 `map.get(key)` 返回了 null。

- 在单线程（HashMap）中，我可以再调用 `map.containsKey(key)` 来确认是‘没这个键’还是‘值为 null’。
- 但在多线程（ConcurrentHashMap）中，这两次调用之间，可能有另一个线程把数据改了。所以我没法判断最初那个 null 到底是什么意思。为了系统健壮性，并发集合直接禁止了 null。


图解补充：集合体系与选型




结构	底层	查询	中间插入/删除	线程安全	典型场景
ArrayList	动态数组	快， $O(1)$	慢，可能搬迁元素	否	绝大多数业务列表
LinkedList	双向链表	慢， $O(n)$	已知节点时快	否	极少数频繁头尾插入
HashMap	数组+链表/红黑树	平均快， $O(1)$	插入快	否	普通 KV 映射

ConcurrentHashMap	数组+链表/红黑树	平均快, $O(1)$	并发写更稳	是	并发缓存、共享状态
TreeMap	红黑树	$O(\log n)$	$O(\log n)$	否	需要有序键

图解补充：HashMap put 与扩容





高频追问补充

追问补充1: 为什么实际开发里 LinkedList 用得很少?

主要是因为它理论上的插入优势, 往往会被遍历定位成本抵消。再加上链表节点分散, CPU 缓存命中率差, 真实业务里通常 `ArrayList` 更快也更省内存。

追问补充2: HashMap 为什么链表转红黑树的阈值是 8?

这个值本质上是时间复杂度和空间开销之间的折中。链表太短时直接转树不划算，链表太长又会拉低查询性能，所以 JDK 选择在冲突较严重时再树化，同时要求数组长度至少 64，优先扩容而不是立刻树化。

追问补充3: 面试里怎么回答集合选型更像工程实践?

可以按这个顺序回答：

1. 先讲业务形态，是列表、去重、队列还是 KV 映射。
2. 再讲读多写多、是否需要排序、是否并发访问。
3. 最后给出具体实现和原因，比如 `ArrayList + HashMap`、`ConcurrentHashMap`、`TreeMap`。

速记版

集合面试可以按这条线背：

- 先分 `Collection` 和 `Map`
- `List` 常问 `ArrayList` vs `LinkedList`
- `Map` 常问 `HashMap`、扩容、线程安全
- 并发场景收口到 `ConcurrentHashMap`

一句话记忆：

`ArrayList` 看查询和遍历，`LinkedList` 看节点插删，`HashMap` 看寻址和扩容，`ConcurrentHashMap` 看并发控制。

反射

反射

反射是 Java 能够成为动态语言的关键，也是所有主流框架（Spring、MyBatis）的基石

所以如果考察反射，很多时候会跟spring/mybatis一起考察

什么是反射？它有什么用？

Q：什么是 Java 反射机制？你在哪里用过？

A：

反射的本质是：在运行状态中，对于任意一个类，都能够知道这个类的所有属性和方法；对于任意一个对象，都能够调用它的任意方法和属性。简单来说，就是把 Java 类中的各种成分（成员变量、方法、构造器等）映射成一个个 Java 对象（Field、Method、Constructor）。

至于用途，虽然我在写业务代码时很少直接写反射，但我用的所有框架底层都在用反射。比如 Spring 的 IOC（控制反转），它读取 XML 或注解配置，通过反射实例化 Bean 并注入依赖；还有 MyBatis，它也是通过反射将数据库结果集映射成 Java 对象的。

反射的原理：

其实比较好理解，java中有一个核心类，`java.lang.Class`

当 JVM 加载一个 `.class` 文件时，会在堆内存中产生一个代表这个类的 `Class` 对象。这个对象包含了该类的完整结构信息（类名、包名、父类、接口、方法、属性等）。程序员可以通过操作这个 `Class` 对象，动态地获取信息或执行操作。

追问1：反射机制有什么优缺点

优点是灵活性极高。它允许程序在运行时动态加载类，这使得我们可以编写通用的框架代码，不需要在编译期就将被调用的类写死。

缺点主要有两个：

1. 性能开销：反射涉及动态解析，JVM 无法对这些代码进行极致的 JIT 优化，所以比直接调用要慢

（虽然现在 JDK 优化得已经很快了，但在高频调用场景下仍需注意）。

2. **安全隐患**：反射可以绕过泛型检查，甚至通过 `setAccessible(true)` 访问私有成员，可能会破坏类的封装性。

获取 Class 对象的几种方式

Q：获取 Class 对象有哪几种方式？它们有什么区别？

A：

主要有三种方式：

1. **`Class.forName("全类名")`**：这是最常用的方式，通常用于读取配置文件加载类（比如 JDBC 加载驱动）。它需要捕获异常。
2. **`类名.class`**：这种方式最简单，但需要编译期就导入该类，一般用于参数传递（比如 `new ArrayList<>(String.class)`）。
3. **`对象.getClass()`**：必须要有实例化后的对象才能用。

区别在于：`Class.forName()` 是动态加载，最灵活；`类名.class` 是静态加载；`getClass()` 依赖实例。在编写框架或通用工具时，第一种用得最多。

深拷贝浅拷贝

深拷贝浅拷贝

这部分内容其实是考察Java 内存模型（堆/栈） 的理解。

面试官想听到的关键词是：引用地址 vs 实际对象。

深拷贝和浅拷贝的核心区别

Q： 什么是深拷贝和浅拷贝？ 它们的区别是什么？

A：

面试官你好。 这两者的核心区别在于对‘引用类型’成员变量的处理方式不同。

1. 浅拷贝：

- 它只复制对象本身，对于对象内部的引用类型变量（比如对象里有个 `List` ），它只复制了引用的地址，没有复制引用的对象。
- 后果：原对象和新对象指向堆内存中的同一个实体。修改新对象的 `List`，原对象的 `List` 也会跟着变。
- Java 中默认的 `Object.clone()` 方法就是浅拷贝。

2. 深拷贝：

- 它不仅复制对象本身，还会递归地复制对象内部所有引用指向的对象。
- 后果：原对象和新对象在内存中是完全独立的。修改其中一个，互不影响。

如何实现深拷贝

Q： 在项目中，如果让你实现一个对象的深拷贝，你会怎么做？

A:

虽然理论上可以通过重写 `clone()` 方法，在里面手动对每个引用对象再次调用 `clone` 来实现，但这在实际开发中**非常不推荐**。因为代码太繁琐，容易漏写，且维护成本高。

在工程实践中，我通常使用**序列化**来实现深拷贝。具体有两种方式：

1. JSON 序列化（推荐）：

- 这是最常用的方法。利用 Jackson 或 FastJson 把对象转成 JSON 字符串，再转回 Java 对象。
- 比如：`User copy = JSON.parseObject(JSON.toJSONString(original), User.class);`
- 优点是代码简单，通用性强。

2. Java 原生序列化：

- 让对象实现 `Serializable` 接口，然后通过**字节流**写出去再读回来。
- 这种方式比较重，但在处理一些不支持 JSON 转换的复杂对象时（比如对象里有循环引用）会用到。

String与浅拷贝

Q: String 也是引用类型，那为什么我在浅拷贝一个对象后，修改 String 字段，原对象没变呢？

A:

String 是引用类型，浅拷贝时复制的也是地址。但是，**String 是不可变类**。当我修改副本的 String 属性时（比如 `user.name = "NewName"`），并非修改了堆内存中原来的那个字符串对象，而是指向了一个新的字符串对象。原对象的引用依然指向老的字符串，所以看起来互不影响。

异常机制

异常机制 异常机制这块很适合面试官连续追问，通常会从 `Exception` 和 `Error` 区别 开始，一路问到受检异常、运行时异常、`throw/throws`、`finally`。

Error 和 Exception 的区别

Q: Error 和 Exception 有什么区别？

它们都继承自 `Throwable`，但语义完全不同。**Error** 通常表示系统级、JVM 级的问题，比如：`OutOfMemoryError``StackOverflowError`这类问题一般不是业务代码能优雅恢复的，所以通常不建议捕获后继续运行。**Exception** 则更多表示程序运行过程中的异常情况，往往是可以通过代码处理的，比如：文件不存在参数非法空指针数组越界所以一句话总结就是：**Error 更偏“系统已经出大问题了”，Exception 更偏“程序要显式处理异常场景”。**

受检异常和运行时异常

Q: 受检异常和运行时异常的区别是什么？

Java 的异常大致可以分为两类：**第一类是受检异常（Checked Exception）**。这类异常在编译期就会被检查，方法如果可能抛出它，要么 `try-catch`，要么在方法签名里 `throws`。常见的比如：`IOException``SQLException``ClassNotFoundException`**第二类是运行时异常（RuntimeException）**。这类异常不强制在编译期处理，通常代表代码逻辑本身有问题。常见的比如：`NullPointerException``ArrayIndexOutOfBoundsException``ClassCastException`所以可以把它理解为：**受检异常强调“外部环境可能出错”，运行时异常更强调“代码本身写得有问题”。**

throw 和 throws 的区别

Q: throw 和 throws 有什么区别？

`throw` 和 `throws` 都和异常相关，但位置和作用完全不同。**throw** 用在方法体内部，表示主动抛出一个具体异常对象。**throws** 用在方法签名上，表示这个方法可能抛出哪些异常。所以一句话记忆：`throw` 是“真的抛”`throws` 是“先声明可能会抛”

finally 一定会执行吗

Q: finally 中的代码一定会执行吗？

大多数正常场景下，`finally` 都会执行，所以它很适合写资源释放逻辑。但它**不是绝对一定执行**，典型例外包括：在 `try` 中调用了 `System.exit()`JVM 直接崩溃程序死机、断电线程陷入死循环，根本没有机会走到 `finally`所以更

准确的说法是：在 JVM 还能正常继续执行控制流的前提下，finally 基本都会执行。

追问1: finally 里写 return 有什么问题？

不推荐。因为它会覆盖 try 或 catch 里的返回值，代码可读性很差，也容易埋坑。面试里最好直接表态：finally 应该只做清理动作，不要写 return。

异常处理的最佳实践

Q：项目里你是怎么设计异常体系的？

如果是在项目里，我一般会这样设计：业务异常和系统异常分开自定义业务异常，承载错误码和错误信息
Controller 层统一做全局异常处理日志里保留上下文信息，但不给前端暴露内部堆栈也就是说，异常处理要做到两件事：对用户或调用方来说，返回的信息清晰、稳定对开发排障来说，日志信息充分、可追踪

代理

代理JDK

动态代理& CGLIB

Q：了解动态代理吗？JDK 动态代理和 CGLIB 有什么区别？

A：面试官你好，动态代理主要用于在**不修改源码**的情况下，对方法进行功能增强（比如加日志、事务控制），它是 Spring AOP 的底层基石。在 Java 中主要有两种实现方式：**JDK 动态代理**：这是 Java 原生提供的。它的核心是 Proxy 类和 InvocationHandler 接口。**特点是**：它要求被代理的类**必须实现接口**。因为它生成的代理对象默认继承了 Proxy 类，利用反射机制调用目标方法。**CGLIB 动态代理**：这是一个第三方高性能代码生成包。它在内存中动态生成一个被代理类的子类。**特点是**：它**不要求实现接口**，是通过**继承**的方式来重写父类方法实现增强的。

为什么 JDK 代理必须基于接口

Q：为什么 JDK 动态代理强制要求目标类必须实现接口？不能像 CGLIB 那样直接代理类吗？

A：这主要受限于 Java 的**单继承机制**。因为 JDK 动态代理生成的那个 Proxy 代理类，它在底层代码中已经**显式**继承了 java.lang.reflect.Proxy 这个父类。Java 语法规则规定，一个类只能有一个父类。既然它已经继承了 Proxy 类，就无法再继承业务目标类了。所以，它只能通过实现接口的方式与目标类建立联系，这就是为什么 JDK 代理必须基于接口的原因。

追问1：那 CGLIB 基于继承机制，有什么缺点或者限制吗

的。因为 CGLIB 是通过生成子类并**重写方法**来实现代理的。在 Java 中，**final** 修饰的方法和类是无法被继承或重写的。所以，如果目标类被标记为 final，或者目标方法被标记为 final，CGLIB 就无法对它进行代理（增强会失效），这是使用继承机制天然的局限性。

静态代理 vs 动态代理

Q：静态代理和动态代理有什么区别？

A：**静态代理**是指在编译期就已经写好了代理类的 .java 文件。比如我写一个 UserProxy 类，手动实现 UserService 接口，在内部调用 Target 的方法前后打印日志。它的缺点很明显：**代码冗余**。如果我有 100 个 Service 需要加日志，我就得写 100 个代理类，维护成本极高。**动态代理**则是把这个过程推迟到了**运行期**。我们不需要手动写代理类，而是让 JVM（JDK）或者字节码框架（CGLIB）在内存中自动生成代理类的字节码。这样我们只需要写一套通用的增强逻辑，就能应用到成千上万个不同的类上，实现了代码的**解耦**和**复用**。

Spring相关

String相关

String 是 Java 面试里非常高频的基础题，常见考法一般是：底层结构、为什么不可变、字符串常量池、以及和 StringBuffer、StringBuilder 的区别。

String 的底层实现

Q: String 底层是怎么实现的？JDK1.8 和 JDK1.9 之后有什么区别？

在 JDK1.8 之前，String 底层主要是 char[]。在 JDK1.9 之后，底层改成了 byte[] + coder 的方式，也就是所谓的紧凑字符串（Compact Strings）。这样做的原因是：很多字符串其实只需要 Latin-1 编码，一个字节就够了。如果继续统一使用 char[]，每个字符两个字节，会造成额外的内存浪费。所以 JDK1.9 之后，String 更关注节省内存占用。

String 为什么不可变

Q: 为什么 String 被设计成不可变的？

String 设计成不可变，核心原因主要有三个：**第一是安全性**。字符串常用于类加载、数据库连接、网络地址、用户名密码等敏感场景。如果 String 可变，那么一个方法拿到字符串引用后，可能在外部被偷偷改掉，这会带来很大的安全风险。**第二是线程安全**。String 不可变后，多线程之间共享同一个字符串对象时，不需要额外同步。**第三是便于缓存和复用**。比如字符串常量池、字符串哈希值缓存，都依赖于“内容一旦创建就不变”这个前提。

追问1: String 不可变是怎么做到的？

主要靠两点：底层存储数组是私有的，外部拿不到可直接修改的入口String 类本身是 final，不能被继承后破坏语义所以可以理解为：既不让你改内部状态，也不让子类改规则。

字符串常量池

Q: 什么是字符串常量池？有什么好处？

字符串常量池是堆中的一块特殊区域，用于复用内容相同的字符串常量。比如：这里 s1 和 s2 指向的是常量池中的同一个对象。这样做的好处主要是：节省内存避免重复创建对象提升字符串比较和使用效率本质上，它是 JVM 基于“String 不可变”做的一种缓存优化。

追问1: new String("hello") 会创建几个对象？

这取决于常量池里原来有没有 "hello"。如果常量池没有，那么会先在常量池中创建一个，再在堆中创建一个 new String 对象，一共两个。如果常量池已经有了，那么只会在堆里再创建一个对象，一共一个新对象。

intern 方法

Q: intern() 方法是做什么的?

intern() 的作用是尝试把字符串对象和常量池中的字符串关联起来。如果常量池中已经有相同内容的字符串，就返回池中的引用；如果没有，就把该字符串放入常量池（或让池中记录这个引用）并返回池中的引用。因此它常用于：大量重复字符串的去重需要统一引用语义的场景但也不能滥用，因为如果字符串非常多且重复率不高，反而会增加常量池压力。

String、StringBuffer、StringBuilder 的区别

Q: String、StringBuffer、StringBuilder 有什么区别?

三者最核心的区别在于 **可变性** 和 **线程安全**。**String**：不可变因为不可变，所以天然线程安全适合字符串内容基本不变的场景**StringBuffer**：可变方法大多带同步，线程安全适合多线程下频繁修改字符串，但性能相对一般**StringBuilder**：可变不保证线程安全单线程下拼接性能最好，也是开发中最常用的可变字符串类如果面试官问项目中怎么选，我的回答会很直接：**单线程拼接优先用 StringBuilder；多线程且共享时再考虑 StringBuffer；普通常量或少量拼接直接用 String。**

String 的长度限制

Q: String 有长度限制吗?

有，但编译期和运行期要分开看。**编译期**，字符串字面量会进入 class 文件常量池，对应 `CONSTANT_Utf8_info` 结构，这一层有长度限制。**运行期**，String 的底层长度本质上受数组长度和 JVM 可用内存限制，不是说能无限大。面试里这里不用展开得太底层，知道“存在限制，而且编译期和运行期的限制来源不同”就够了。

迭代器

迭代器

为什么要有 Iterator? for-each 循环的本质

Q: Java 既然已经有 for 循环了, 为什么还要设计 Iterator? 平时用的增强 for 循环 (for-each) 和它有什么关系?

A: Iterator 的主要作用是‘统一’和‘解耦’。不同的集合底层结构不同, 比如 ArrayList 是数组, LinkedList 是链表, HashSet 是哈希表。如果没有 Iterator, 我就需要了解每种集合的内部结构才能遍历它 (比如数组用下标, 链表用指针)。Iterator 提供了一套统一的 API (hasNext、next), 让我不需要关心容器的底层实现就能遍历所有集合。至于增强 for 循环 (for-each), 它其实就是 Java 提供的一个语法糖。在编译成字节码后, 它本质上还是被转成了 Iterator 的调用。所以用 for-each 遍历 List, 本质上就是在用 Iterator。

原理: 设计模式: 这是典型的迭代器模式。提供一种方法顺序访问一个聚合对象中的各个元素, 而又不暴露其内部的表示。语法糖验证: 可以查看 .class 反编译后的代码, 会发现 for(String s : list) 变成了 while(iterator.hasNext()) { ... }。

追问1: 那既然 for-each 底层就是 Iterator, 为什么我在 for-each 里面删除元素会报错

虽然 for-each 底层是 Iterator, 但它隐藏了迭代器对象。当我们调用 list.remove() 删除元素时, 集合的结构改变了, 但背后的那个隐形迭代器并不知道, 它的预期状态和实际状态不一致了, 所以下一次循环时就会触发 Fail-Fast 机制, 抛出异常。如果要在遍历中删除, 必须显式获取 Iterator 对象, 并调用 iterator.remove()。

Fail-Fast机制

Q: 什么是 Fail-Fast 机制? 它是怎么检测到并发修改的?

Fail-Fast (快速失败) 是 Java 集合的一种错误检测机制。它的初衷是: 一旦发现数据可能不一致, 立马抛异常, 宁可停止程序也不给出错误结果。实现原理是基于一个变量 modCount: 集合类 (如 ArrayList) 内部有一个 modCount 变量, 用来记录集合被修改的次数 (add/remove 都会让它 +1)。当我们创建迭代器时, 迭代器内部会复制一份 modCount, 记为 expectedModCount。此后每次调用 iterator.next(), 迭代器都会检查: modCount 是否等于 expectedModCount? 如果不相等, 说明在迭代期间, 集合被其他代码 (或者多线程) 修改了, 于是直接抛出 ConcurrentModificationException。

追问1: Fail-Fast 是线程安全的吗? 有没有不抛异常的集合

Fail-Fast 不是线程安全的, 它只是尽力检测错误, 不能作为并发控制的手段。如果需要 Fail-Safe (安全失败) 的集合, 可以使用 java.util.concurrent 包下的类, 比如 CopyOnWriteArrayList。它的原理是写时复制,

遍历的是原数组的快照，修改的是新数组，所以永远不会抛出并发修改异常，但可能读不到最新的数据（弱一致性）。

泛型

泛型

什么是泛型？什么是类型擦除？

Q：谈谈你对 Java 泛型的理解？什么是类型擦除？

A：泛型的主要目的是为了增强代码的类型安全和重用性。在没有泛型之前，我们从集合中取对象必须强制转换，容易抛出 `ClassCastException`。有了泛型，编译器就能帮我们做类型检查。Java 的泛型其实是伪泛型，这是通过类型擦除实现的。简单来说，Java 的泛型只存在于编译阶段。当编译器把 `.java` 翻译成 `.class` 文件时，它会把所有的泛型参数（如 `<T>`，`<String>`）都擦除掉

【拓展】 通配符与 PECS 原则

Q：List、List 和 List 有什么区别？平时怎么用？

A：这三个都是泛型的通配符，区别主要在于读写权限不同，使用时遵循 PECS 原则（Producer Extends, Consumer Super）：

- `? extends T`（上界通配符）：表示集合里装的是 T 的子类。特点：只能读（取出来一定是 T），不能写（因为不知道具体是哪个子类，怕类型不匹配）。适用：它适合作为生产者（Producer），也就是只读数据的场景。
- `? super T`（下界通配符）：表示集合里装的是 T 的父类。特点：可以写（可以安全地放入 T 及其子类），但读出来只能是 Object（类型丢失）。适用：它适合作为消费者（Consumer），也就是写入数据的场景。
- `?`（无界通配符）：等价于 `? extends Object`，通常只用于只读且不关心具体类型的场景。

IO模型

IO模型

IO 模型这块在 Java 八股里，最常见的就是 BIO / NIO / AIO，以及“同步异步、阻塞非阻塞”的区别。

BIO、NIO、AIO 的区别

Q: BIO、NIO、AIO 分别是什么？有什么区别？

如果只抓面试最核心的区别，我会这样总结：**BIO** 是同步阻塞 IO。线程发起读写后，会一直阻塞等待结果返回。模型简单，但高并发下一个连接往往就要占一个线程，线程资源很容易成为瓶颈。**NIO** 是同步非阻塞 IO。它引入了 Channel、Buffer、Selector 等概念，可以基于 IO 多路复用，让一个线程同时管理多个连接。**AIO** 是异步非阻塞 IO。应用发起 IO 请求后，不需要主动轮询，等底层完成后通过回调通知应用继续处理。所以三者的主线可以理解为：BIO：简单，但扩展性差NIO：工程里更常见，适合高并发网络编程AIO：理论上更先进，但在 Java 生态里使用没有 NIO 普遍

同步和异步

Q: 同步和异步怎么理解？

同步和异步，强调的是 **任务结果的获取方式**。**同步** 是我发起一个调用后，要等这个调用完成，才能继续往下走。**异步** 是我发起调用后，不必原地等待，后续通过通知、回调、Future 等方式拿结果。所以同步异步的核心不是“线程会不会卡住”，而是：**调用方是不是必须自己等结果**。

阻塞和非阻塞

Q: 阻塞和非阻塞怎么理解？

阻塞和非阻塞，强调的是 **线程在等待结果时的状态**。**阻塞**：线程会挂起等待，期间不能干别的事。**非阻塞**：线程发起请求后，如果条件不满足，会立刻返回，线程可以继续做别的事。所以阻塞非阻塞的核心是：**等待期间线程是不是被卡住**。

追问1: 同步一定阻塞吗？异步一定非阻塞吗？

不一定。这是面试里特别爱考的点。同步不一定阻塞，比如同步轮询也可以是非阻塞的异步也不一定完全非阻塞，某些框架内部仍然可能用阻塞线程池来承接任务所以这两组概念不是同一维度。

Java 工程里怎么回答这类题

Q: 项目里如果面试官问你 NIO 的实际价值，你会怎么答？

我会从“为什么需要它”来回答。在高并发网络场景下，如果继续沿用 BIO，就会出现“一连接一线程”的问题。当连接数很大、请求里还夹杂大量阻塞等待时，线程数量会迅速膨胀，带来上下文切换和内存开销。NIO 通过 Selector 把多个连接复用到少量线程上处理，因此更适合：Netty 这类网络框架网关、IM、RPC 通信高并发长连接场景所以 NIO 的实际价值，本质上是：**用更少的线程支撑更多连接。**

JDK新特性

JDK新特性

JDK 新特性的考察，一般不是让你背版本号，而是看你能不能说出“这个特性解决了什么问题、适合什么场景、项目里是否真用过”。

JDK5 到 JDK8 的核心变化

Q: JDK5、JDK8 分别有哪些你觉得最重要的新特性？

面试官你好，如果只抓面试里最常见、最有代表性的特性，我会这样回答：JDK5 重点是引入了 **泛型、枚举、注解、自动装箱拆箱**。其中泛型和注解影响最大，前者提升了类型安全，后者为 Spring 这种框架式开发打下了基础。JDK8 重点是 **Lambda 表达式、Stream 流、Optional、接口默认方法、时间 API**。这一版最核心的变化，是 Java 开始明显吸收函数式编程思想，让集合处理、空值处理和时间处理更现代化。如果从“项目里最常用”的角度看，JDK8 的几个特性几乎是现在 Java 开发的标配。

Lambda 表达式

Q: 什么是 Lambda 表达式？它解决了什么问题？

Lambda 表达式本质上是 **对匿名内部类的简化**，它的核心价值是：**把函数当成参数传递**。以前如果我想给集合排序、给线程池提交任务、给 Stream 做过滤，往往需要写很多模板化代码；有了 Lambda 之后，可以把关注点放在“做什么”，而不是“怎么写一个匿名类”。比如：相比传统匿名内部类，代码更短，可读性也更强。

追问1: Lambda 的底层是匿名内部类吗？

不是简单地等价于匿名内部类。JVM 层面主要借助 `invokedynamic` 指令和 `LambdaMetafactory` 来实现，因此它不是每次都真的生成一个新的匿名类文件。你可以把它理解为：**语法层面像匿名类，运行时实现更轻量、更灵活**。

Stream 流

Q: Stream 流的核心价值是什么？

Stream 流的核心价值，是把集合处理从“命令式写法”变成“声明式写法”。传统写法里，我们往往要自己写 `for` 循环、判断条件、临时变量；而 Stream 更强调“我要过滤什么、映射什么、聚合什么”。常见操作包括：

`filter`: 过滤 `map`: 转换 `sorted`: 排序 `collect`: 收集 `count`: 统计例如：它的优势是代码表达力强，尤其适合做列表筛选、转换、统计类场景。

追问1: Stream 一定比 `for` 循环快吗？

不一定。如果只是简单遍历，`for` 循环往往更直接，性能未必差。Stream 的核心优势主要是 可读性、链式表达、便于组合操作。如果是非常高频、极度关注性能的热点路径，还是要以压测结果为准，不能机械地说 Stream 一定更好。

Optional

Q: Optional 是干什么的？为什么它能减少空指针问题？

Optional 是一个“可能有值，也可能没值”的容器类。它的意义不是彻底消灭 `null`，而是 强迫开发者显式处理空值。例如以前我们可能这样写：而使用 Optional 后，可以写成更清晰的链式处理。它比较适合：返回值可能为空的方法多层对象取值时的空值兜底需要默认值、异常抛出、条件分支时

追问1: Optional 适合当实体类字段吗？

一般不推荐。Optional 更适合作为方法返回值，而不是实体类字段或 RPC 传输字段。因为这样会增加序列化、框架兼容、代码理解上的复杂度。

JDK21 的虚拟线程

Q: 你了解 JDK21 的虚拟线程吗？

虚拟线程可以理解成由 JVM 管理的轻量级线程。传统平台线程是一个 Java 线程对应一个操作系统线程，创建和切换成本都比较高；而虚拟线程是 大量用户态线程复用少量平台线程，因此更适合高并发、阻塞等待多的场景。它特别适合：大量 IO 阻塞任务—请求一线程模型需要提升并发量，但不想手动把代码改造成异步回调风格。它的优势主要是：创建成本低切换成本低编程模型仍然接近同步代码，心智负担比手写异步低

追问1: 虚拟线程会完全替代线程池吗？

不会这么绝对。虚拟线程更适合“高并发 IO 阻塞”场景，但 CPU 密集型任务的瓶颈仍然是 CPU 本身。如果是计算型任务，线程数量仍然不能无限增加。所以更准确的说法是：虚拟线程降低了阻塞型并发编程的成本，但没有消灭线程模型和资源调度的基本约束。

线程基础

线程基础

线程基础题通常是 JUC 面试的开场题，面试官会先确认你对线程状态、创建方式、常见方法这些最基础的概念是否清楚。

线程的创建方式

Q: Java 创建线程有哪些方式?

常见的创建线程方式主要有四种：**第一种，继承 Thread 类。**直接重写 `run()` 方法，简单直观，但耦合度高，不够灵活。**第二种，实现 Runnable 接口。**这是更常见的方式，因为它把“任务”和“线程”解耦了。**第三种，实现 Callable 接口配合 FutureTask。**它适合有返回值、还能抛异常的异步任务。**第四种，通过线程池创建线程。**这是生产环境最推荐的方式，因为线程池可以复用线程、统一管理资源。如果面试官问项目里怎么用，我会直接回答：**生产环境优先线程池，不会手动频繁 `new Thread`。**

线程的状态流转

Q: Java 线程有哪些状态?

Java 在线程状态上，`Thread.State` 枚举里定义了六种：

`NEW``RUNNABLE``BLOCKED``WAITING``TIMED_WAITING``TERMINATED`比较容易混淆的是：**`RUNNABLE`**不等于“此刻一定正在 CPU 上运行”，它表示线程已经具备运行资格，可能在运行，也可能在等待 CPU 调度。**`BLOCKED`**一般是抢锁失败。**`WAITING`**一般是调用了 `wait()`、`join()` 等无限等待方法。**`TIMED_WAITING`**一般是 `sleep()`、带超时的 `wait()`、带超时的 `join()`。

start 和 run 的区别

Q: `start()` 和 `run()` 有什么区别?

`run()` 只是普通方法调用，不会启动新线程。`start()` 才会真正创建新的执行路径，让 JVM 去调度这个线程，然后由新线程去执行 `run()` 方法。所以如果直接调用 `run()`，本质上还是主线程自己在执行。

sleep 和 wait 的区别

Q: `sleep` 和 `wait` 有什么区别?

这是一个特别经典的对比题。**`sleep`** 是 `Thread` 类的方法。它表示让当前线程休眠一段时间，但**不会释放锁**。**`wait`** 是 `Object` 类的方法。它必须在同步代码块里调用，调用后线程会进入等待状态，并且**会释放当前持有的**

对象锁。所以一句话记：sleep：线程休眠，不释放锁wait：线程等待，释放锁

volatile关键字

volatile关键字

volatile 是并发编程中的高频考点，面试官通常会从"volatile 有什么作用"切入，然后深挖可见性、重排序等底层原理。

volatile的作用

Q: volatile 关键字有什么作用？

面试官你好，volatile 主要有两个作用：第一个是**保证可见性**。当一个线程修改了 volatile 变量的值，这个新值会立即刷新到主内存，其他线程读取这个变量时，会从主内存中读取最新值，而不是使用自己工作内存中的旧值。第二个是**禁止指令重排序**。编译器和处理器为了优化性能，可能会对指令进行重排序，但 volatile 通过内存屏障，禁止特定类型的重排序，保证代码按照我们预期的顺序执行。需要注意的是，volatile **不能保证原子性**，这是它和 synchronized 的一个重要区别。

追问1: 什么是可见性问题？为什么会出现？

可见性问题是指一个线程修改了共享变量的值，其他线程无法立即看到这个修改。出现这个问题的原因是，现代计算机为了提高性能，每个 CPU 核心都有自己的缓存。线程在读取变量时，会先从自己的工作内存（缓存）中读取，而不是直接从主内存读取。当一个线程修改了变量，可能只是修改了自己缓存中的值，还没有刷新到主内存，其他线程的缓存中还是旧值，就会出现可见性问题。举个例子，比如我有一个 `boolean flag = false`，线程 A 把它改成 `true`，但线程 B 可能一直读到 `false`，导致程序出现意外的行为。给 flag 加上 volatile 关键字就能

解决这个问题。volatile的底层原理

Q: volatile 是如何保证可见性和禁止重排序的？

面试官你好，volatile 的底层实现依赖于**内存屏障**（Memory Barrier）。对于可见性，当写一个 volatile 变量时，JMM（Java 内存模型）会在写操作后插入一个 Store 屏障，强制将缓存中的数据刷新到主内存。当读一个 volatile 变量时，JMM 会在读操作前插入一个 Load 屏障，强制从主内存中读取最新值，使工作内存中的缓存失效。对于禁止重排序，volatile 通过内存屏障，禁止了几种重排序：写 volatile 变量之前的操作不能重排序到写操作之后，读 volatile 变量之后的操作不能重排序到读操作之前。这样就保证了代码的执行顺序符合我们的预期。

追问1: 什么是指令重排序？为什么要重排序？

指令重排序是指编译器和处理器为了优化性能，可能会改变指令的执行顺序，但会保证单线程下的执行结果不变。重排序的目的是提高 CPU 的执行效率，减少流水线停顿。但在多线程环境下，重排序可能导致程序出现意

外的结果，所以在某些关键位置，我们需要用 volatile 来禁止重排序。**volatile不能保证原子性**

Q: volatile 能保证原子性吗？为什么？

面试官你好，volatile 不能保证原子性。我举个例子，比如 count++ 这个操作，看起来是一条语句，但实际上包含三个步骤：读取 count 的值、将 count 的值加 1、将新值写回 count。在多线程环境下，可能出现这样的情况：线程 A 和线程 B 同时读取 count = 0，然后都计算出 1，最后都写回 1。这样执行了两次 count++，但最终 count 只等于 1，而不是期望的 2。如果要保证原子性，我们需要使用 synchronized 或者 Lock，或者使用 AtomicInteger 这样的原子类。

追问1: 什么情况下 volatile 可以保证线程安全？

当满足以下两个条件时，volatile 可以保证线程安全：第一，对变量的写操作不依赖当前值，比如直接赋值 flag = true，而不是 count++ 这种依赖当前值的操作。第二，该变量不需要与其他变量共同参与不变约束。典型的场景就是用 volatile 修饰一个布尔变量作为状态标志，或者在双重检查锁定（DCL）单例模式中使用。

volatile与synchronized的区别

Q: volatile 和 synchronized 有什么区别？

面试官你好，volatile 和 synchronized 的区别主要有以下几点：首先，**作用范围不同**。volatile 只能修饰变量，而 synchronized 可以修饰方法和代码块。其次，**原子性不同**。volatile 不能保证原子性，synchronized 可以保证原子性。但它们都能保证可见性和有序性。第三，**性能不同**。volatile 是轻量级的同步机制，性能更好，不会阻塞线程。synchronized 是重量级的同步机制，可能会阻塞线程，但 JDK 1.6 之后做了很多优化，性能也提升了不少。最后，**使用场景不同**。volatile 适用于一写多读的场景，比如状态标志。synchronized 适用于需要原子性的场景，比如 count++ 这种操作。总结一下，能用 synchronized 就用 synchronized，除非只需要保证可见性，不需要原子性，那用 volatile 就够了。

追问1: 既然 synchronized 功能更强大，为什么还要用 volatile？

因为 volatile 的性能更好，开销更小。如果我只需要保证可见性，不需要原子性，用 volatile 就够了，没必要

用 synchronized 增加额外的开销。**volatile的典型应用场景**

Q: volatile 有哪些典型的应用场景？

面试官你好，volatile 的典型应用场景主要有两个：第一个是**状态标志**。最常见的就是用 volatile 修饰一个布尔变量，作为线程的停止标志。比如我有一个 volatile boolean stop = false，在线程的 run 方法里用 while (!stop) 循环执行任务，当其他线程调用 stop = true 时，执行任务的线程能立即看到这个修改，退出循环。第二个是**双重检查锁定（DCL）单例模式**。在单例模式中，我们会用 volatile 修饰 instance 变量。这是因为 instance = new Singleton() 这行代码实际上包含三个步骤：分配内存空间、初始化对象、将 instance 指向分

配的内存地址。由于指令重排序，可能变成先分配内存、再指向内存、最后初始化对象。如果线程 A 执行到指向内存这一步时，线程 B 进入第一次检查，发现 instance 不为 null，直接返回，但此时对象还没有初始化完成，就会出现空指针异常。volatile 的作用就是禁止这种重排序，保证对象初始化完成后，才将引用赋值给 instance。

追问1: DCL 单例模式中，为什么要双重检查?

第一次检查是在 synchronized 外面，目的是避免每次调用 getInstance() 都进入同步块，提高性能。如果 instance 已经初始化了，直接返回，不需要加锁。第二次检查是在 synchronized 里面，目的是防止多个线程同时通过第一次检查，进入同步块后，重复创建实例。比如线程 A 和 B 同时调用 getInstance()，都通过了第一次检查，然后线程 A 先获取锁，创建了实例。线程 B 获取锁后，如果不进行第二次检查，就会再创建一个实例，这就违背了单例模式的初衷。

ThreadLocal

ThreadLocal

ThreadLocal 是 JUC 中的高频考点，面试官通常会问"ThreadLocal 是什么"，然后深挖内存泄漏问题。

ThreadLocal是什么

Q: ThreadLocal 是什么？有什么作用？

面试官你好，ThreadLocal 是 Java 提供的一个**线程局部变量**工具类。它的作用是让每个线程都拥有自己独立的变量副本，线程之间互不干扰。简单来说，就是我在 ThreadLocal 里存一个值，线程 A 存的是 A 的值，线程 B 存的是 B 的值，它们互相看不到对方的值，这样就避免了线程安全问题。典型的使用场景有这么几个：第一个是**数据库连接管理**，每个线程持有自己的数据库连接。第二个是**用户信息传递**，在 Web 应用中，把用户信息存在 ThreadLocal 里，整个请求链路都能访问。第三个是**SimpleDateFormat**，因为 SimpleDateFormat 不是线程安全的，可以用 ThreadLocal 让每个线程持有自己的实例。

追问1: 为什么不直接用局部变量，要用 ThreadLocal?

局部变量确实是线程安全的，但它的作用域只在方法内部。如果我想在整个线程的多个方法之间共享数据，又不想通过参数传递，就可以用 ThreadLocal。比如在 Web 应用中，我在 Filter 里把用户信息存到 ThreadLocal，然后在 Service、Dao 等各层都能直接获取，不需要层层传递参数。

ThreadLocal的底层原理

Q: ThreadLocal 的底层实现原理是什么？

面试官你好，ThreadLocal 的底层实现其实挺巧妙的。每个 **Thread** 对象内部都有一个 **ThreadLocalMap** 属性，这个 Map 的 Key 是 ThreadLocal 对象，Value 是我们存储的值。当我们调用 `threadLocal.set(value)` 时，实际上是：获取当前线程的 ThreadLocalMap 把 ThreadLocal 对象作为 Key，value 作为 Value，存到这个 Map 里当我们调用 `threadLocal.get()` 时，实际上是：获取当前线程的 ThreadLocalMap 用 ThreadLocal 对象作为 Key，从 Map 里取出 Value 所以，数据实际上是存在**线程对象**里的，而不是 ThreadLocal 对象里。这样每个线程都有自己的 Map，自然就隔离了。

追问1: ThreadLocalMap 和 HashMap 有什么区别？

ThreadLocalMap 和 HashMap 虽然都是 Map，但实现上有很大的区别：第一个是**解决冲突的方式不同**。HashMap 用的是链表法（或红黑树），而 ThreadLocalMap 用的是**开放地址法**（线性探测）。当发生 Hash 冲突时，ThreadLocalMap 会往后找下一个空位置。第二个是**Key 的类型不同**。ThreadLocalMap 的 Key 是

WeakReference，也就是弱引用，这是为了防止内存泄漏。第三个是**扩容机制不同**。HashMap 的扩容阈值是

0.75，而 ThreadLocalMap 的扩容阈值是 2/3。

ThreadLocal的内存泄漏问题

Q: ThreadLocal 会导致内存泄漏吗？为什么？

面试官你好，ThreadLocal 可能会导致内存泄漏，这是一个很经典的问题。我先说一下原因：

ThreadLocalMap 的 Key 是 **WeakReference**（弱引用），Value 是**强引用**。当 ThreadLocal 对象没有外部强引用时，在 GC 时，Key 会被回收，变成 null。但是 Value 还是强引用，不会被回收。这样就会出现 Key 为 null，但 Value 还在的情况，这个 Value 就永远访问不到了，但又占着内存，这就是内存泄漏。而且，如果使用的是线程池，线程会被复用，线程对象不会被回收，ThreadLocalMap 也不会被回收，这些泄漏的 Value 就会一直存在，越积越多。

追问1：为什么 Key 要设计成弱引用？

这是为了**降低内存泄漏的风险**。如果 Key 是强引用，那么即使外部没有对 ThreadLocal 的引用了，ThreadLocalMap 里还持有强引用，ThreadLocal 对象就永远不会被回收。这样不仅 ThreadLocal 对象泄漏了，Value 也泄漏了。用弱引用的话，至少 ThreadLocal 对象可以被回收，只是 Value 可能泄漏。而且 ThreadLocalMap 在 set、get、remove 时，会主动清理 Key 为 null 的 Entry，这样可以一定程度上缓解内存泄漏。

追问2：如何避免 ThreadLocal 的内存泄漏？

最佳实践是：**用完之后一定要调用 remove() 方法**。在 Web 应用中，通常在 Filter 或拦截器的 finally 块中调用 remove()，确保请求结束后清理 ThreadLocal。另外，如果可以的话，尽量把 ThreadLocal 定义成 **static final** 的，这样 ThreadLocal 对象本身不会被回收，就不会出现 Key 为 null 的情况。

ThreadLocal的使用场景

Q: ThreadLocal 有哪些典型的使用场景？

面试官你好，ThreadLocal 的典型使用场景主要有这么几个：**第一个是数据库连接管理**。在传统的 JDBC 编程中，每个线程需要持有自己的数据库连接，可以用 ThreadLocal 来存储。这样在事务管理时，同一个线程的多个 DAO 操作可以共享同一个连接。**第二个是用户信息传递**。在 Web 应用中，我们可以在 Filter 或拦截器里把用户信息（如用户 ID、用户名）存到 ThreadLocal，然后在 Controller、Service、Dao 等各层都能直接获取，不需要层层传递参数。Spring Security 就是这么做的。**第三个是 SimpleDateFormat**。SimpleDateFormat 不是线程安全的，如果多个线程共享一个实例，会出现问题。可以用 ThreadLocal 让每个线程持有自己的 SimpleDateFormat 实例。**第四个是分布式追踪的 Traceld**。在微服务架构中，我们会给每个请求分配一个 Traceld，用于追踪整个调用链路。这个 Traceld 可以存在 ThreadLocal 里，方便在日志中打印。

追问1：你在项目中是怎么用 ThreadLocal 的？

在我的项目中，主要用 ThreadLocal 来传递用户信息。我们在网关层会解析 JWT Token，获取用户 ID 和用户名，然后通过 HTTP Header 传递给下游服务。下游服务在拦截器里把用户信息存到 ThreadLocal，这样在整个请求处理过程中，任何地方都能通过 `UserContext.getUserId()` 获取当前用户信息，不需要在每个方法里传递 `userId` 参数。在拦截器的 `finally` 块中，我们会调用 `UserContext.clear()` 来清理 ThreadLocal，避免内存泄漏。

ThreadLocal的注意事项

Q：使用 ThreadLocal 有哪些注意事项？

面试官你好，使用 ThreadLocal 主要有这么几个注意事项：**第一个是一定要记得 remove**。这是最重要的，尤其是在使用线程池的场景下，线程会被复用，如果不 remove，上一个请求的数据可能会影响下一个请求。**第二个是不要存储大对象**。因为 ThreadLocal 的数据是存在线程对象里的，如果存储的对象很大，会占用大量内存。而且在线程池场景下，线程不会被回收，这些大对象会一直占着内存。**第三个是注意父子线程的数据传递**。ThreadLocal 的数据是线程隔离的，子线程无法访问父线程的 ThreadLocal 数据。如果需要传递，可以使用 `InheritableThreadLocal`。**第四个是避免在异步场景下使用**。比如在一个线程里设置了 ThreadLocal，然后提交了一个异步任务到线程池，异步任务是在另一个线程执行的，就拿不到 ThreadLocal 的值了。如果需要传递，可以使用阿里的 `TransmittableThreadLocal`。

追问1：InheritableThreadLocal 是什么？

`InheritableThreadLocal` 是 `ThreadLocal` 的子类，它可以让**子线程继承父线程的 ThreadLocal 数据**。实现原理是：在创建子线程时，会把父线程的 `InheritableThreadLocal` 数据复制一份给子线程。但是要注意，`InheritableThreadLocal` 只在**创建子线程时**复制数据。如果使用线程池，线程是复用的，不会重新创建，就无法传递数据了。这种情况需要用阿里的 `TransmittableThreadLocal`。

线程池

线程池

线程池是 JUC 中面试出现频率最高的知识点，几乎是必问题。面试官通常会从"你项目中怎么用线程池"切入，然后深挖底层原理、参数配置、拒绝策略等。

为什么要使用线程池

Q：为什么要使用线程池？有什么好处？

面试官你好，使用线程池主要有三大好处：第一个是**降低资源消耗**。因为线程的创建和销毁是有开销的，需要调用操作系统内核。线程池通过复用已创建的线程，避免了频繁创建销毁的开销。第二个是**提高响应速度**。任务到达时，不需要等待线程创建，可以立即执行。第三个是**提高线程的可管理性**。线程是稀缺资源，如果无限制创建，会消耗系统资源，甚至导致系统崩溃。线程池可以统一分配、调优和监控线程。

ThreadPoolExecutor的七大参数

Q：ThreadPoolExecutor 有哪些核心参数？分别是什么作用？

面试官你好，ThreadPoolExecutor 有七个核心参数：我详细说一下这七个参数：第一个是 **corePoolSize（核心线程数）**，它表示线程池中常驻的线程数量。即使这些线程处于空闲状态，也不会被回收，除非设置了 **allowCoreThreadTimeOut**。第二个是 **maximumPoolSize（最大线程数）**，它表示线程池允许创建的最大线程数量。当任务队列满了，且当前线程数小于最大线程数时，会创建新线程处理任务。第三个是 **keepAliveTime（空闲线程存活时间）**，当线程数超过核心线程数时，多余的空闲线程在被回收前的最大等待时间。第四个是 **unit（时间单位）**，就是 keepAliveTime 的时间单位，比如 **TimeUnit.SECONDS**。第五个是 **workQueue（任务队列）**，用于存放等待执行的任务。常见的有 **ArrayBlockingQueue（有界队列）**、**LinkedBlockingQueue（无界队列，默认容量是 Integer.MAX_VALUE）**、还有 **SynchronousQueue（不存储元素的队列，每个插入操作必须等待一个移除操作）**。第六个是 **threadFactory（线程工厂）**，用于创建新线程。我们可以自定义线程名称、优先级等。第七个是 **handler（拒绝策略）**，当任务队列满了，且线程数达到最大值时，如何处理新提交的任务。

线程池的工作流程

Q：线程池的执行流程是怎样的？

面试官你好，线程池的执行流程可以总结为以下几步：首先，我们调用 `execute()` 或 `submit()` 提交任务。然后，线程池会判断当前运行的线程数是不是小于核心线程数。如果小于，就直接创建新线程执行任务，即使有空闲线程也会创建新的。如果当前运行的线程数大于等于核心线程数，任务会被放入任务队列等待。如果任务队列已满，且当前线程数小于最大线程数，就会创建新的非核心线程执行任务。最后，如果任务队列满了，且线程数已达到最大值，就会执行拒绝策略。我画个流程图可能更清楚：

追问1：为什么线程数小于核心线程数时，即使有空闲线程也要创建新线程？

这是线程池的设计策略。核心线程是“常驻”的，线程池会尽快达到核心线程数，以保证有足够的线程处理任务。这样可以避免任务在队列中等待，提高响应速度。

四种拒绝策略

Q：线程池有哪些拒绝策略？分别适用什么场景？

面试官你好，JDK 提供了四种内置的拒绝策略：第一个是 **AbortPolicy（默认）**，它会直接抛出异常 `RejectedExecutionException`。这个适用于需要感知任务被拒绝的情况，及时发现问题。第二个是 **CallerRunsPolicy**，它会由调用线程（提交任务的线程）自己执行任务。这个适用于任务不能丢失，且可以接受降低提交速度的场景。这种策略会降低任务提交的速度，起到一定的限流作用。第三个是 **DiscardPolicy**，它会直接丢弃任务，不抛异常。这个适用于允许任务丢失的场景，比如日志记录。第四个是 **DiscardOldestPolicy**，它会丢弃队列中最老的任务，然后尝试重新提交当前任务。这个适用于优先处理新任务的场景。

追问1：生产环境中你会选择哪种拒绝策略？

这要看具体业务场景：如果是**核心业务**，比如订单、支付这种，我会使用 **AbortPolicy**，抛异常后可以记录日志、告警，不能让任务悄悄丢失。如果是**非核心业务**，比如日志、埋点这种，可以用 **DiscardPolicy**，允许部分数据丢失。如果是**需要限流**的场景，我会用 **CallerRunsPolicy**，让调用线程自己执行，降低提交速度。

常见的线程池类型

Q：Executors 提供了哪些常见的线程池？有什么问题？

面试官你好，Executors 工具类提供了几种快速创建线程池的方法：第一个是 **`newFixedThreadPool(int n)`**，它是固定大小的线程池，核心线程数等于最大线程数等于 `n`。它使用 `LinkedBlockingQueue`（无界队列）。问题是队列无界，可能导致内存溢出（OOM）。第二个是 **`newSingleThreadExecutor()`**，它只有一个线程的线程池，也使用 `LinkedBlockingQueue`。同样存在 OOM 风险。第三个是 **`newCachedThreadPool()`**，它的核心线程数为 0，最大线程数为 `Integer.MAX_VALUE`，使用 `SynchronousQueue`（不存储任务）。问题是可能创建大量线程，导致系统资源耗尽。第四个是 **`newScheduledThreadPool(int n)`**，它支持定时和周期性任务执行。同样使用无界队列，存在 OOM 风险。

追问1: 为什么阿里巴巴开发手册不推荐使用 Executors 创建线程池?

主要有两个原因: 第一个是 `FixedThreadPool` 和 `SingleThreadExecutor` 使用的是 `LinkedBlockingQueue`, 默认容量是 `Integer.MAX_VALUE` (约 21 亿)。如果任务提交速度大于处理速度, 队列会无限增长, 导致内存溢出。第二个是 `CachedThreadPool` 的最大线程数是 `Integer.MAX_VALUE`, 可能创建大量线程, 导致 CPU 和内存资源耗尽。所以推荐的做法是使用 `ThreadPoolExecutor` 手动创建线程池, 明确指定核心参数, 避免资源失控。比如这样:

```
1  ThreadPoolExecutor executor = new ThreadPoolExecutor(  
2      10,                // 核心线程数  
3      20,                // 最大线程数  
4      60L,               // 空闲线程存活时间  
5      TimeUnit.SECONDS,  
6      new ArrayBlockingQueue<>(100), // 有界队列  
7      new ThreadPoolExecutor.CallerRunsPolicy() // 拒绝策略  
8  );
```

如何合理配置线程池参数

Q: 如何合理设置线程池的核心线程数和最大线程数?

面试官你好, 线程池参数的配置需要根据任务类型来决定: **第一种是 CPU 密集型任务**, 任务主要消耗 CPU 资源, 比如计算、加密这种。推荐配置是核心线程数等于 CPU 核心数加 1。原因是 CPU 密集型任务, 线程数过多会导致频繁的上下文切换, 反而降低性能。加 1 是为了在某个线程因为偶尔的内存页失效或其他原因暂停时, 额外的线程可以顶上。**第二种是 IO 密集型任务**, 任务主要等待 IO 操作, 比如网络请求、数据库查询、文件读写这种。推荐配置是核心线程数等于 CPU 核心数乘以 2, 或者 CPU 核心数除以 (1 减去阻塞系数)。阻塞系数通常在 0.8 到 0.9 之间, 也就是线程有 80% 到 90% 的时间在等待 IO。原因是 IO 密集型任务, 线程大部分时间在等待, 可以创建更多线程来提高 CPU 利用率。**第三种是混合型任务**, 建议拆分成 CPU 密集型和 IO 密集型任务, 分别用不同的线程池处理。

追问1: 你在项目中是怎么配置线程池的?

在我的项目中, 我会根据实际业务场景来配置: 比如**异步任务处理**, 像发送短信、邮件这种, 这是典型的 IO 密集型任务。我会设置核心线程数为 20, 最大线程数为 50, 使用有界队列 (比如 `ArrayBlockingQueue(200)`), 拒绝策略用 `CallerRunsPolicy`。如果是**数据计算任务**, 这是 CPU 密集型任务。我会设置核心线程数等于 CPU 核心数加 1, 最大线程数与核心线程数相同, 使用较小的队列。重点是, 生产环境中, 我会通过压测和监控 (比如线程池的活跃线程数、队列大小、拒绝次数) 来动态调

整参数, 找到最优配置。**线程池的关闭**


Q: 如何正确关闭线程池? shutdown 和 shutdownNow 有什么区别?


面试官你好，线程池提供了两种关闭方法：第一个是 `shutdown()`，这是温柔关闭。它不再接受新任务，但会执行完队列中的所有任务。已提交的任务会继续执行，线程池状态变为 `SHUTDOWN`。第二个是 `shutdownNow()`，这是强制关闭。它不再接受新任务，尝试停止正在执行的任务，并返回队列中未执行的任务列表。它通过调用线程的 `interrupt()` 方法来中断线程，线程池状态变为 `STOP`。推荐的做法是这样：

追问1: 为什么不能直接用 shutdownNow?

因为 `shutdownNow()` 只是尝试中断线程，但如果任务没有正确处理中断信号（比如没有检查 `Thread.interrupted()`），任务可能无法停止。而且，正在执行的任务可能处理到一半，导致数据不一致。所以生产环境中，优先使用 `shutdown()` 优雅关闭。

图解补充：线程池任务流转





图解补充：参数和队列怎么记

维度	核心结论	面试表达
<code>corePoolSize</code>	常驻线程数	先保响应，再谈扩容
<code>maximumPoolSize</code>	极限兜底线程数	队列扛不住时再扩线程
<code>workQueue</code>	决定是“排队”还是“扩线程”	队列类型直接影响系统行为
<code>handler</code>	最后的降级策略	核心业务不能悄悄丢任务
<code>keepAliveTime</code>	非核心线程回收时间	高峰过后及时缩容

队列	特点	常见风险	适用场景
<code>ArrayBlockingQueue</code>	有界、数组实现	容量太小易拒绝	明确限流的业务
<code>LinkedBlockingQueue</code>	默认近似无界	任务堆积可能 OOM	不建议直接无脑用
<code>SynchronousQueue</code>	不存元素，直接交接	容易快速拉高线程数	短任务、高吞吐

高频追问补充

追问补充1: `execute()` 和 `submit()` 有什么区别?

`execute()` 只提交任务, 没有返回值; `submit()` 会返回 `Future`, 可以拿结果, 也会把异常包装到 `Future` 里。面试里一般会补一句: 如果要感知异步任务异常, 不能只调 `submit()` 不看 `Future`。

追问补充2: 生产里线程池参数怎么定, 不要只背公式, 怎么回答更靠谱?

更好的答法是: 先按 CPU 密集型、IO 密集型做初始估算。队列一定设成有界, 先把系统上限卡住。再结合压测看活跃线程数、队列长度、拒绝次数、任务平均耗时。最终根据业务 SLA 调整, 而不是死背“CPU 核数乘 2”。

追问补充3: 核心业务为什么常选 `AbortPolicy` 或 `CallerRunsPolicy`?

因为核心业务最怕“悄悄丢任务”。`AbortPolicy` 适合快速失败并告警, `CallerRunsPolicy` 适合反压, 把压力回传给调用方。真正线上系统一般不会选静默丢弃。**速记版**

线程池可以背成一句话: 先开核心线程 -> 再进队列 -> 队列满了再扩线程 -> 还扛不住就拒绝面试里最容易被追问的四个点: 七大参数执行流程拒绝策略为什么不用 `Executors`

AQS

AQS原理

AQS 是 JUC 中最核心的底层框架，面试官通常用它来考察候选人对并发编程的理解深度。

AQS是什么

Q: 什么是 AQS? 它的作用是什么?

面试官你好，AQS 全称是 **AbstractQueuedSynchronizer**（抽象队列同步器），它是 JUC 包中最核心的**基础框架**。AQS 的作用是为实现锁和同步器提供一个**通用的框架**。像 **ReentrantLock**、**Semaphore**、**CountDownLatch**、**ReentrantReadWriteLock** 这些同步工具，底层都是基于 AQS 实现的。AQS 的核心思想是：如果请求的共享资源空闲，就把当前请求资源的线程设置为有效的工作线程，并将共享资源设置为锁定状态。如果请求的共享资源被占用，就需要一套**线程阻塞等待以及被唤醒时锁分配的机制**。AQS 用的是 **CLH 队列锁**（一个虚拟的双向队列）来实现这个机制，将暂时获取不到锁的线程加入到队列中。

追问1: 为什么要有 AQS? 直接用 **synchronized** 不行吗?

synchronized 是 JVM 层面的，功能比较固定，不够灵活。而 AQS 提供了一个可扩展的框架，让我们可以根据不同的需求实现各种同步器。比如 **ReentrantLock** 可以实现公平锁和非公平锁，**Semaphore** 可以控制并发数量，**CountDownLatch** 可以实现等待多个线程完成。这些功能用 **synchronized** 都很难实现，但基于 AQS 就很容易。

AQS的核心原理

Q: AQS 的核心原理是什么?

面试官你好，AQS 的核心原理主要包括三个部分：**第一个是 state 状态**。AQS 内部维护了一个 **volatile int state** 变量，用来表示同步状态。比如在 **ReentrantLock** 中，**state = 0** 表示锁空闲，**state > 0** 表示锁被占用，**state** 的值表示重入次数。**第二个是 CLH 队列**。AQS 内部维护了一个 **FIFO 的双向队列**，用来存放等待获取锁的线程。当线程获取锁失败时，会被封装成一个 **Node** 节点，加入到队列尾部。当持有锁的线程释放锁时，会唤醒队列中的第一个线程。**第三个是独占模式和共享模式**。AQS 支持两种模式：**独占模式 (Exclusive)**：同一时刻只有一个线程能获取资源，比如 **ReentrantLock**。**共享模式 (Shared)**：多个线程可以同时获取资源，比如 **Semaphore**、**CountDownLatch**。

追问1: CLH 队列是什么?

CLH 队列是一种**基于链表的 FIFO 队列**，全称是 **Craig, Landin, and Hagersten** 队列（三个人名的缩写）。在 AQS 中，CLH 队列的每个节点（Node）包含：**thread**：等待的线程**waitStatus**：节点状态（如

CANCELLED、SIGNAL 等) **prev**: 前驱节点**next**: 后继节点当线程获取锁失败时, 会被封装成 Node 加入队列尾部。当锁被释放时, 会唤醒队列头部的下一个节点。

AQS的工作流程

Q: AQS 的加锁和释放锁的流程是怎样的?

面试官你好, 我以独占模式 (比如 ReentrantLock) 为例, 说一下 AQS 的工作流程: **加锁流程 (acquire)**: 首先, 线程调用 tryAcquire() 尝试获取锁 (这个方法由子类实现)。如果获取成功 (state 从 0 变成 1), 直接返回, 线程获得锁。如果获取失败 (state 已经是 1), 说明锁被占用, 线程会被封装成 Node 节点, 加入到 CLH 队列的尾部。加入队列后, 线程会进入自旋, 再次尝试获取锁。如果前驱节点是头节点, 就尝试获取锁。如果还是获取失败, 线程会被 LockSupport.park() 阻塞, 进入等待状态。**释放锁流程 (release)**: 线程调用 tryRelease() 释放锁 (这个方法由子类实现)。如果释放成功 (state 从 1 变成 0), 会唤醒 CLH 队列中的第一个等待线程。被唤醒的线程会再次尝试获取锁, 如果成功, 就从队列中移除, 成为新的持有锁的线程。流程图可能更清楚: 线程 A 获取锁成功 (state: 0 → 1) ↓ 线程 B 尝试获取锁失败 ↓ 线程 B 加入 CLH 队列尾部 ↓ 线程 B 被 park 阻塞 ↓ 线程 A 释放锁 (state: 1 → 0) ↓ 唤醒队列头部的线程 B ↓ 线程 B 获取锁成功 (state: 0 → 1)

追问1: 为什么加入队列后还要自旋?

这是一种优化策略。因为如果前驱节点就是头节点, 说明当前线程是队列中的第一个等待线程, 很可能马上就能获取到锁。这时候自旋一下, 可能就获取到了, 避免了线程阻塞和唤醒的开销。如果自旋几次还是获取不到, 说明锁的持有时间比较长, 这时候再阻塞, 避免浪费 CPU 资源。

ReentrantLock如何基于AQS实现

Q: ReentrantLock 是如何基于 AQS 实现的?

面试官你好, ReentrantLock 内部有一个 Sync 类, 它继承了 AQS。Sync 又有两个子类: **FairSync (公平锁)** 和 **NonfairSync (非公平锁)**。**非公平锁的实现**: 当调用 lock() 时: 首先用 CAS 尝试将 state 从 0 改成 1, 如果成功, 直接获取锁。如果失败, 调用 AQS 的 acquire() 方法, 进入队列等待。在 tryAcquire() 方法中: 如果 state = 0, 再次用 CAS 尝试获取锁 (插队)。如果当前线程已经持有锁 (state > 0), state 加 1 (可重入)。否则返回 false, 线程进入队列。**公平锁的实现**: 公平锁和非公平锁的区别在于: 公平锁在 tryAcquire() 时, 会先检查队列中是否有等待的线程。如果有, 当前线程必须排队, 不能插队。这就是为什么公平锁性能比非公平锁差, 因为多了一次队列检查。

追问1: state 是如何保证线程安全的?

state 是用 volatile 修饰的, 保证了可见性。修改 state 时, AQS 使用 **CAS (Compare And Swap)** 操作, 保证了原子性。CAS 是一种无锁的原子操作, 通过硬件指令实现, 性能很高。比如在获取锁时, 会用 compareAndSetState(0, 1) 来尝试将 state 从 0 改成 1。如果成功, 说明获取锁成功; 如果失败, 说明有其他线程抢先了。

AQS的共享模式

Q: AQS 的共享模式是怎么实现的?

面试官你好, AQS 的共享模式和独占模式的主要区别在于: **共享模式下, 多个线程可以同时获取资源**。典型的例子是 **Semaphore (信号量)**。Semaphore 可以控制同时访问某个资源的线程数量。**实现原理**: 在共享模式下, state 表示**可用的资源数量**。比如 `new Semaphore(3)` 表示最多允许 3 个线程同时访问。当线程调用 `acquire()` 时: 调用 `tryAcquireShared()`, 尝试将 state 减 1。如果 `state >= 0`, 获取成功, 线程继续执行。如果 `state < 0`, 获取失败, 线程加入队列等待。当线程调用 `release()` 时: 调用 `tryReleaseShared()`, 将 state 加 1。如果队列中有等待的线程, 唤醒它们。**共享模式的特点是**: 当一个线程释放资源后, 可能会唤醒**多个**等待的线程, 而不是只唤醒一个。

追问1: CountdownLatch 是如何基于 AQS 实现的?

CountDownLatch 也是基于 AQS 的共享模式实现的。在 CountDownLatch 中, state 表示**计数器的值**。比如 `new CountDownLatch(3)` 表示需要等待 3 个线程完成。当线程调用 `await()` 时: 如果 `state > 0`, 线程加入队列等待。如果 `state = 0`, 线程直接返回。当线程调用 `countDown()` 时: 将 state 减 1。如果 state 变成 0, 唤醒所有等待的线程。这样就实现了"等待多个线程完成"的功能。

AQS的优势

Q: AQS 相比 synchronized 有什么优势?

面试官你好, AQS 相比 synchronized 的优势主要有这么几点: **第一个是灵活性更高**。AQS 提供了一个可扩展的框架, 我们可以根据不同的需求实现各种同步器。比如公平锁、非公平锁、读写锁、信号量等, 这些用 synchronized 都很难实现。**第二个是功能更强大**。AQS 支持可中断的锁获取 (`lockInterruptibly`)、超时获取 (`tryLock(timeout)`)、非阻塞获取 (`tryLock`), 而 synchronized 只能阻塞等待。**第三个是性能更好**。在高并发场景下, AQS 的性能通常比 synchronized 好。虽然 JDK 1.6 后 synchronized 做了很多优化, 但 AQS 的灵活性让它在某些场景下性能更优。**第四个是支持条件变量**。AQS 支持 Condition, 可以实现更复杂的线程协作, 比如生产者-消费者模式。synchronized 只有一个等待队列, 而 AQS 可以有多个 Condition 队列。

追问1: 什么时候用 AQS, 什么时候用 synchronized?

这要看具体场景: 如果是简单的同步需求, 比如保护一个临界区, 用 **synchronized** 就够了, 代码简单, 性能也不差。如果需要更高级的功能, 比如可中断、超时、公平锁、读写锁, 就用 **AQS 相关的类** (如 `ReentrantLock`、`ReadWriteLock`)。如果可以实现自定义的同步器, 就可以继承 AQS, 实现自己的 `tryAcquire` 和 `tryRelease` 方法。更新: 2026-01-30 20:59:34原文:

<https://www.yuque.com/u63312805/wnyutc/erxkffw0ggr6bq6c>

CAS与原子类

CAS与原子类

CAS、原子类、乐观锁悲观锁通常是一套组合题，面试官很喜欢顺着这一条线往下挖。

CAS 是什么

Q: 什么是 CAS?

CAS 的全称是 **Compare And Swap**，也叫比较并交换。

它包含三个值：

- 内存中的旧值 V
- 预期值 A
- 要修改的新值 B

执行时会先比较：如果 $V == A$ ，就把值更新成 B；如果不相等，说明这段时间被其他线程改过了，本次更新失败。

所以它本质上是一种 **无锁的乐观并发控制思想**。

CAS 的优缺点

Q: CAS 有什么优缺点?

优点：

- 不需要阻塞线程
- 在低竞争场景下性能很好
- 避免了传统锁的上下文切换开销

缺点：

- 高竞争下可能一直自旋，浪费 CPU
- 只能保证单个共享变量更新的原子性
- 会有 ABA 问题

所以 CAS 并不是万能替代锁，而是更适合“短时间、冲突不高”的更新场景。

ABA 问题

Q：什么是 ABA 问题？怎么解决？

ABA 问题的意思是：

一个线程看到某个值从 A 变成 B，又变回 A。

它会误以为这个值从来没被改过，于是 CAS 成功，但实际上共享变量已经经历过一次变化了。

解决方案通常是给值加一个 版本号 或 时间戳，也就是“值 + 版本”一起比较。

JUC 里常见的实现是 `AtomicStampedReference`。

原子类

Q：Java 里有哪些常见原子类？

JUC 里常见的原子类可以分成几类：

基础类型原子类：

- `AtomicInteger`
- `AtomicLong`
- `AtomicBoolean`

数组原子类：

- `AtomicIntegerArray`
- `AtomicLongArray`

引用原子类：

- `AtomicReference`
- `AtomicStampedReference`
- `AtomicMarkableReference`

字段更新器：

- `AtomicIntegerFieldUpdater`
- `AtomicLongFieldUpdater`
- `AtomicReferenceFieldUpdater`

它们底层大量依赖的就是 CAS。

乐观锁和悲观锁

Q：乐观锁和悲观锁怎么理解？

悲观锁 的思想是：先假设冲突一定会发生，所以先加锁再操作。

典型代表就是 `synchronized`、`ReentrantLock`、数据库行锁。

乐观锁 的思想是：先假设冲突不太会发生，不先加锁，提交更新时再检查有没有被别人改过。

典型代表就是 CAS、数据库版本号机制。

如果冲突频繁，悲观锁往往更稳；

如果冲突不高、操作很短，乐观锁往往效率更高。

synchronized与Lock

synchronized 和 Lock 是 Java 并发编程中最常用的两种锁机制，面试中经常会被拿来对比。

面试官通常会问"synchronized 和 Lock 有什么区别"，然后深挖锁升级、公平锁、死锁等问题。

synchronized与Lock的区别

Q: synchronized 和 Lock 有什么区别？

面试官你好，synchronized 和 Lock 的主要区别可以从以下几个维度来看：

我详细说一下：

第一个是**使用方式**，synchronized 是关键字，使用简单，自动加锁解锁。而 Lock 是接口，需要手动 lock 和 unlock，通常在 finally 块中释放锁。

第二个是**锁的获取**，synchronized 只能阻塞等待，无法中断。而 Lock 提供了 `tryLock()`（尝试获取锁）、`tryLock(timeout)`（超时获取）、`lockInterruptibly()`（可中断获取）等方法。

第三个是**公平性**，synchronized 是非公平锁，线程获取锁的顺序不确定。而 ReentrantLock 可以在构造时指定是否为公平锁（`new ReentrantLock(true)`）。

追问1: 什么时候用 synchronized，什么时候用 Lock？

这要看具体场景：

推荐使用 synchronized 的场景有这么几种：第一个是锁竞争不激烈的场景。第二个是代码简单，不需要高级功能（如超时、中断、公平锁）。第三个是 JDK 1.6 后，synchronized 性能已经很好，且代码更简洁。

推荐使用 Lock 的场景也有几种：第一个是需要**尝试获取锁**（tryLock），避免死锁。第二个是需要**可中断的锁获取**（lockInterruptibly）。第三个是需要**公平锁**，保证线程按顺序获取锁。第四个是需要**读写锁**（ReadWriteLock），读多写少的场景。

总结一下就是：能用 synchronized 就用 synchronized，除非需要 Lock 的高级特性。

synchronized的底层原理

Q: synchronized 的底层实现原理是什么？

面试官你好，synchronized 的底层实现依赖于 JVM 的 Monitor（监视器锁）。

我分两种情况来说：

第一种是同步代码块，编译后会在代码块前后插入 `monitorenter` 和 `monitorexit` 指令。`monitorenter` 会尝试获取对象的 Monitor，如果获取成功，锁计数器 +1；如果失败，线程阻塞等待。`monitorexit` 会释放 Monitor，锁计数器 -1，当计数器为 0 时，锁被释放。

第二种是同步方法，方法上加 synchronized 关键字，编译后会在方法的访问标志中添加 `ACC_SYNCHRONIZED` 标记。JVM 在调用方法时，会检查这个标记，自动获取和释放 Monitor。

Monitor 的本质是这样的：每个 Java 对象都有一个 Monitor 对象（对象头中的 Mark Word 指向 Monitor）。Monitor 内部有一个计数器、一个等待队列和一个同步队列。

追问1: synchronized 锁的是什么？

synchronized 锁的是**对象**，具体来说有三种情况：

第一种是**修饰实例方法**，锁的是**当前实例对象（this）**。

第二种是**修饰静态方法**，锁的是**当前类的 Class 对象**。

第三种是**修饰代码块**，锁的是**括号里指定的对象**。

```
1  // 锁的是 this
2  public synchronized void method1() { }
3
4  // 锁的是 MyClass.class
5  public static synchronized void method2() { }
6
7  // 锁的是 obj
8  synchronized (obj) { }
```

synchronized的锁升级机制

Q: synchronized 的锁升级过程是怎样的？

面试官你好，JDK 1.6 对 synchronized 做了大量优化，引入了**锁升级机制**，从低到高依次是：

无锁 → 偏向锁 → 轻量级锁 → 重量级锁

这个过程是**单向的**，只能升级，不能降级（为了提高效率）。

我详细说一下这几种锁：

第一个是偏向锁（Biased Locking），它适用于锁总是被同一个线程获取，没有竞争的场景。原理是在对象头的 Mark Word 中记录获取锁的线程 ID。当这个线程再次请求锁时，无需做任何同步操作，直接获取锁。优势是几乎没有性能开销。但是当有其他线程尝试获取锁时，偏向锁会被撤销，升级为轻量级锁。

第二个是轻量级锁（Lightweight Locking），它适用于多个线程交替获取锁，但没有实际竞争（不同时获取）的场景。原理是通过 CAS（Compare And Swap）操作尝试将对象头的 Mark Word 替换为指向锁记录的指针。优势是避免了重量级锁的线程阻塞和唤醒，性能较好。但是如果 CAS 失败（说明有竞争），轻量级锁会膨胀为重量级锁。

第三个是重量级锁（Heavyweight Locking），它适用于多个线程同时竞争锁的场景。原理是依赖操作系统的 **Mutex Lock（互斥锁）**，线程会被阻塞，进入等待队列。劣势是涉及用户态和内核态的切换，性能开销大。

我画个流程图可能更清楚：

追问1：为什么锁只能升级，不能降级？

这是 JVM 的设计选择。锁降级需要额外的开销来判断是否可以降级，而且降级后如果又发生竞争，还要再次升级，反而增加了复杂度。JVM 认为，一旦发生过竞争，后续大概率还会竞争，所以干脆不降级，保持在高级别的锁状态。

追问2：什么是自旋锁？为什么要自旋？

自旋锁是指线程在获取锁失败时，不立即阻塞，而是**循环尝试获取锁（自旋）**。

为什么要自旋呢？主要有两个原因：

第一个是线程的阻塞和唤醒需要从用户态切换到内核态，开销很大。

第二个是如果锁的持有时间很短，自旋等待一下，可能很快就能获取到锁，避免了线程切换的开销。

自旋的问题是：如果锁的持有时间很长，自旋会浪费 CPU 资源。所以 JVM 引入了**自适应自旋**：根据上次自旋的结果动态调整自旋次数。如果上次自旋成功了，这次可以多自旋几次；如果上次失败了，这次就少自旋或直接阻塞。

ReentrantLock的使用

Q: ReentrantLock 怎么用？有什么注意事项？

面试官你好，ReentrantLock 的基本使用是这样的：先调用 `lock()` 获取锁，然后在 `try` 中执行业务逻辑，最后一定要在 `finally` 中调用 `unlock()` 释放锁。

注意事项有这么几点：

第一个是**必须手动释放锁**，一定要在 `finally` 块中调用 `unlock()`，否则如果发生异常，锁永远不会被释放，导致死锁。

第二个是**lock 和 unlock 要成对出现**，每次 `lock()` 必须对应一次 `unlock()`。

第三个是**避免在 lock 之前写业务代码**，如果在 `lock()` 之前的代码抛异常，会导致 `finally` 中的 `unlock()` 被执行，但锁根本没获取到，会抛 `IllegalMonitorStateException`。

高级用法还有这些：

`tryLock()` 可以尝试获取锁，拿不到就立即返回；带超时时间的 `tryLock()` 可以在指定时间内等待锁，超时后放弃；`lockInterruptibly()` 可以在等待锁的过程中响应中断；构造方法可以设置公平锁和非公平锁；还可以配合 `Condition` 实现更精细的等待和唤醒。

所以整体来说，`synchronized` 更简单，适合普通同步场景；`ReentrantLock` 更灵活，适合需要超时等待、可中断等待、公平性控制、多条件队列这些更复杂的并发场景。

公平锁与非公平锁

Q: 什么是公平锁和非公平锁？有什么区别？

面试官你好，我先解释一下这两个概念：

公平锁是指多个线程按照**申请锁的顺序**来获取锁（先到先得），内部维护了一个 FIFO 队列。

非公平锁是指线程获取锁的顺序**不确定**，可能后来的线程先获取到锁。新来的线程会先尝试直接获取锁（插队），如果失败再进入队列。

区别主要体现在这几个方面：

第一，**获取锁的顺序不同**。公平锁强调先来后到，尽量按照线程排队顺序获取锁；非公平锁允许线程插队，后来的线程可能比先等待的线程更早获取锁。

第二，**性能不同**。公平锁为了保证顺序，每次获取锁时都要判断队列中是否已经有等待线程，如果有，就不能直接抢锁，而是进入队列等待。非公平锁则会先尝试直接 CAS 获取锁，如果成功，就省去了线程挂起、唤醒、入队、出队等开销，所以吞吐量通常更高。

第三，**饥饿风险不同**。公平锁可以减少线程长期等待的问题，因为线程基本按照顺序获取锁；非公平锁由于允许插队，极端情况下可能导致某些线程一直抢不到锁，出现线程饥饿。

第四，**适用场景不同**。如果业务非常关注线程获取资源的顺序，或者希望尽量避免线程饥饿，可以考虑公平锁；如果业务更关注整体吞吐量，通常会选择非公平锁。

为什么非公平锁性能更好呢？因为公平锁在获取锁时，必须先检查队列中是否有等待的线程，如果有，当前线程必须排队。而非公平锁可以直接尝试获取锁，如果成功，就省去了入队和出队的开销。

ReentrantLock 的公平性可以这样设置：

```
// 默认是非公平锁
ReentrantLock lock1 = new ReentrantLock();

// 显式指定非公平锁
ReentrantLock lock2 = new ReentrantLock(false);

// 显式指定公平锁
ReentrantLock lock3 = new ReentrantLock(true);
```

公平锁和非公平锁在 **ReentrantLock** 里的核心区别，主要体现在获取锁的入口逻辑上。

非公平锁在调用 **lock()** 方法时，会先尝试通过 CAS 把 AQS 中的 **state** 从 **0** 修改为 **1**。如果修改成功，就说明当前线程直接获取到了锁，不需要管同步队列里是否已经有其他线程在等待。

公平锁在尝试 CAS 获取锁之前，会先判断同步队列中当前线程前面是否已经有等待线程。如果前面有人排队，那么当前线程不会直接抢锁，而是进入 AQS 队列等待。

追问1: `synchronized` 是公平锁还是非公平锁?

`synchronized` 是非公平锁, 且无法改变。这也是为什么在需要公平性的场景下, 要使用 `ReentrantLock`。

可重入锁

Q: 什么是可重入锁? `synchronized` 和 `ReentrantLock` 是可重入的吗?

面试官你好, 可重入锁 (Reentrant Lock) 是指同一个线程可以多次获取同一把锁, 而不会被自己阻塞。

为什么需要可重入呢? 因为在递归调用或方法嵌套调用时, 如果锁不可重入, 线程会被自己持有的锁阻塞, 导致死锁。

`synchronized` 和 `ReentrantLock` 都是可重入锁。

我举个例子:

在这个例子中, `method1` 获取了锁, 然后调用 `method2`, `method2` 也需要获取同一把锁。因为 `synchronized` 是可重入的, 所以不会死锁。

实现原理是这样的: 锁内部维护了一个计数器和持有锁的线程 ID。当线程第一次获取锁时, 计数器等于 1。当同一个线程再次获取锁时, 计数器加 1。每次释放锁时, 计数器减 1, 当计数器为 0 时, 锁被完全释放。

追问1: 如果锁不可重入会怎样?

如果锁不可重入, 上面的例子中, 线程在 `method1` 中获取了锁, 然后调用 `method2` 时, 发现锁已经被占用 (被自己占用), 就会一直等待, 导致死锁。

并发经典题

并发经典题本身不难，但特别能区分“只会背概念”和“真能写出并发代码”的人。面试官经常会问交替打印、顺序控制这类问题。

多线程交替打印 0-100

Q：两个线程交替打印 0 到 100，你会怎么做？

这类题的关键不是语法，而是 线程之间怎么协调顺序。

常见做法有三种：

- `synchronized + wait/notify`
- `ReentrantLock + Condition`
- `CAS + 自旋`

如果是面试，我一般优先答 `synchronized + wait/notify`，因为它最能体现基础。

核心思路是：

- 共享一个计数器
- 打印完之后唤醒对方
- 自己不满足条件时进入等待

如果追求代码表达更清晰，也可以用 `ReentrantLock + Condition`。

三线程交替打印 ABC

Q：三个线程交替打印 ABC，你会怎么设计？

这个题和交替打印数字的本质一样，关键是引入一个 **状态变量**。

比如可以定义：

- 0 表示轮到 A
- 1 表示轮到 B
- 2 表示轮到 C

每个线程只在轮到自己时打印；打印后修改状态并唤醒其他线程。

实现手段同样可以是：

- `synchronized + wait/notifyAll`
- `ReentrantLock + 3 个 Condition`

如果线程数更多、规则更复杂，我更倾向于 `Lock + Condition`，可读性会更好。

如何回答这类题

Q：面试里遇到并发手撕题，怎么答更稳？

我一般会按这个顺序答：

第一步，先确认需求。

比如是两个线程还是三个线程，要不要严格交替，打印到多少结束。

第二步，说思路。

先说“需要共享状态 + 线程协作 + 顺序控制”。

第三步，选工具。

简单场景优先 `synchronized + wait/notify`，复杂一点再上 `Lock + Condition`。

第四步，说边界。

比如要注意唤醒后重新判断条件，所以通常写 `while` 而不是 `if`。

这样回答，面试官会觉得你不是在背模板，而是在真的设计并发逻辑。

线程安全与JMM

线程安全和 JMM 是并发面试里非常高频的一组题。很多人会把它们拆开背，但更好的理解方式是：JMM 解释了为什么会出现线程安全问题，以及 Java 是怎么约束可见性、有序性和原子性的。

什么是线程安全

Q：你怎么理解线程安全？

如果一个类或一段逻辑在多线程并发访问下，仍然能够保持结果正确、状态一致，而且调用方不需要额外做同步控制，那我就认为它是线程安全的。

线程不安全的典型表现包括：

- 数据覆盖
- 脏读
- 结果不符合预期
- 对象状态被多个线程改乱

比如 `i++` 看起来只是一行代码，但实际上包含读取、计算、写回三个步骤，多线程并发执行就可能丢失更新。

JMM 是什么

Q：什么是 JMM？

JMM 指的是 **Java 内存模型**。

它不是说 JVM 真实内存怎么实现，而是一套并发访问内存时的规范。

它主要解决的是多线程环境下三个核心问题：

- 原子性
- 可见性
- 有序性

JMM 规定了线程和主内存之间的交互方式，也规定了什么场景下一个线程对共享变量的修改，必须让其他线程可见。

原子性、可见性、有序性

Q：原子性、可见性、有序性分别是什么意思？

原子性：一个操作要么全部执行完，要么完全不执行，中间不能被打断。

比如单次基本类型赋值通常具有原子性，但 `i++` 不是原子操作。

可见性：一个线程修改了共享变量，其他线程能够及时看到最新值。

如果没有可见性保证，一个线程可能一直读到旧值。

有序性：程序执行顺序不一定严格按照代码顺序，因为编译器和 CPU 可能会做指令重排序。

JMM 允许一定范围内的重排序，但不能破坏单线程语义和多线程同步语义。

happens-before

Q：你怎么理解 happens-before？

happens-before 可以理解成 JMM 里判断“一个操作的结果，对另一个操作是否一定可见”的规则。

只要满足 happens-before 关系，就意味着前一个操作的执行结果，对后一个操作是可见的，而且前一个操作的执行顺序也排在后一个之前。

常见规则包括：

- 程序次序规则
- 锁规则：解锁 happens-before 后续加锁
- `volatile` 变量规则：对一个 volatile 变量的写 happens-before 后续对它的读
- 线程启动规则： `start()` 先于线程内动作
- 线程终止规则：线程内动作先于其他线程感知它结束

面试里不用把规则全背全，只要知道它是 JMM 的可见性和有序性判断依据 就够了。

JMM 和 volatile 的关系

Q: volatile 为什么能保证可见性？

volatile 变量的写，会强制把工作内存中的值刷新到主内存；

volatile 变量的读，会强制从主内存重新读取最新值。


同时，volatile 在读写前后会插入内存屏障，禁止特定类型的指令重排序。

所以它能保证：

- 可见性
- 一定程度的有序性

但它不能保证复合操作的原子性，比如 `i++` 这种场景，还是需要加锁或 CAS。

图解补充：JMM 的主内存与工作内存



对比补充：happens-before 规则怎么记

规则	可以怎么理解	面试里的简短说法
程序次序规则	单线程里前面的操作先于后面的操作	单线程看代码顺序
锁规则	解锁先于后续加锁	同一把锁天然建立可见性
<code>volatile</code> 规则	写先于后续读	写完别人能看到
线程启动规则	<code>start()</code> 先于线程内动作	主线程先发车，子线程后执行
线程终止规则	线程内动作先于 <code>join()</code> 后的感知	等线程结束后看到它结果

高频追问补充

追问补充1：为什么 `i++` 不是线程安全的？

因为它不是一个原子动作，而是“读 -> 加一 -> 写回”三个步骤。即使变量是 `volatile`，也只能保证别的线程能看到最新值，不能阻止两个线程同时读到旧值后再覆盖写回。

追问补充2：`synchronized` 和 `volatile` 分别解决什么问题？

`volatile` 主要解决可见性和部分有序性；`synchronized` 同时能解决可见性、原子性和有序性。面试里如果只问“轻量同步”，可以先答 `volatile`；如果涉及复合操作，一般就要收口到锁或 CAS。

追问补充3：面试里怎么把 JMM 和线程安全串起来？

可以这么讲：线程安全问题的本质通常就落在三个维度上，原子性、可见性、有序性。JMM 定义了这三个问题的约束边界，`volatile`、`synchronized`、CAS 这些手段，都是在这个模型上解决不同类型的并发风险。

速记版

JMM 建议按这条线记：

- 线程安全先看三个问题：原子性、可见性、有序性
- JMM 是规则，不是物理实现
- happens-before 是判断“可见且有序”的依据
- `volatile` 能见、不能包办原子性

一句话回答模板：

JMM 的核心作用是定义多线程下共享变量什么时候可见、什么时候允许重排序，以及通过什么同步手段建立可靠的可见性和有序性。

微服务架构与拆分

微服务是进阶面试里很容易被追问的一块。这里最怕的不是“不知道”，而是把“拆服务”说成一句空话，所以一定要能讲出拆分依据、服务边界和落地代价。

什么是微服务

Q：什么是微服务？

微服务可以理解成：把一个大系统拆成多个围绕业务能力组织的小服务，每个服务独立开发、部署、扩容。它强调的不是“服务一定要很小”，而是：边界清晰职责单一可以独立演进所以面试里更稳的表述是：**微服务本质上是按业务能力做拆分，用分布式协作替代单体内部调用。**

为什么要拆微服务

Q：什么时候会从单体演进到微服务？

常见触发点有四类：团队变大，单体代码协作成本太高某些模块流量特别大，需要独立扩容不同业务节奏差异大，希望独立发布单体模块耦合严重，改一个地方容易影响全局但注意，不是所有系统都该拆。如果业务还很早期、团队不大、复杂度不高，单体反而更快。


追问1：微服务一定比单体好吗？

不一定。单体的优势是开发简单、调用链短、事务天然好处理。微服务只有在系统规模、团队规模、复杂度都上来之后，收益才会显现。

微服务怎么拆

Q：微服务拆分一般按什么维度来做？

最常见的拆分维度有三个：按业务领域拆，比如用户、订单、库存、支付按核心链路拆，比如交易链路、营销链路、履约链路按通用能力拆，比如搜索、推荐、消息通知最不推荐的，是按技术层拆，比如“Controller 服务”“Service 服务”“DAO 服务”。因为这种拆法没有业务闭环，只会制造大量跨服务调用。面试时最好强调一句：**服务拆分不是按代码层次拆，而是按业务边界拆。**



服务粒度怎么控制

Q: 服务是不是越小越好?

不是。服务太大，会退化成“小单体”；服务太小，会导致：调用链变长维护成本上升事务变复杂排查困难判断粒度是否合适，可以看三个点：服务是否有清晰业务边界大多数高频调用是否还在服务内部这个服务是否真的有独立扩容和独立发布价值

微服务之间怎么通信

Q: 微服务之间常见的通信方式有哪些?

常见方式主要有两类：同步调用：HTTP / RPC异步调用：MQ / 事件驱动选择思路通常是：结果要立刻拿到，用同步解耦、削峰、异步通知，用消息很多系统不是二选一，而是混合使用：下单时同步调用库存校验下单成功后异步发消息做积分、通知、埋点

微服务为什么更强调无状态

Q: 为什么微服务里经常强调服务无状态?

因为服务一旦无状态：可以随时水平扩容请求落到任意节点都能处理节点挂掉时影响更小如果会话状态放在应用本地内存，就会带来：扩容困难Session 丢失节点迁移麻烦所以微服务里常见方案是：Session 集中存储到 Redis直接改成 Token / JWT

微服务拆分后最常见的问题

Q: 单体拆成微服务后，最容易踩什么坑?

最常见的问题有：服务边界模糊，互相直连，调用网变蜘蛛网一个请求串很多服务，链路太长分布式事务处理不好日志、监控、追踪没跟上，出了问题查不出来组织结构没变，技术拆了但协作方式还是单体时代所以微服务不是只拆代码，还要配套：服务治理链路追踪配置中心灰度发布容错降级

项目里怎么说

Q：如果面试官问你项目里为什么拆微服务，你怎么答？

可以按下面的结构说：先讲原来的瓶颈，比如单体模块耦合、发布风险高、订单流量压力大再讲拆分依据，比如按用户、订单、库存、支付这些业务边界拆再讲拆分后的问题，比如事务、调用链、治理成本最后讲你的配套方案，比如注册发现、网关、MQ 解耦、链路追踪这样会让面试官觉得你不是只会背“微服务优点”，而是真的知道拆分后会多什么麻烦。

高频追问补充

追问1：拆数据库和拆服务谁先做？

多数情况下先按服务边界拆业务能力，再逐步推动数据隔离。如果一上来强行完全拆库，但边界没梳理好，反而容易把复杂度提前引爆。

追问2：微服务是不是一定要上 Spring Cloud 或 Kubernetes？

不一定。这些只是治理工具，不是微服务本身。即使不用这些框架，只要系统按业务能力拆分、独立部署和协作，本质上也是微服务。

RAG相关八股

RAG（检索增强生成）是大模型应用落地的核心技术之一，面试中既会考察基础概念，也会深入追问技术细节、落地难点和项目实践，最怕只背定义而讲不清原理和落地逻辑，因此需明确核心组件、技术选型、优化方向和实际踩坑点。

什么是RAG知识库系统

Q：什么是RAG知识库系统？

RAG（Retrieval-Augmented Generation，检索增强生成）知识库系统，本质是将“检索”与“大模型生成”结合的智能问答系统：先通过检索模块从预设的知识库中，精准找到与用户问题相关的上下文信息，再将这些信息作为提示词（Prompt）输入大模型，让大模型基于检索到的事实性内容生成回答。

它强调的不是“单纯用大模型回答”，而是：**检索补全事实、生成保证流畅、知识库承载专业内容**，核心解决大模型“幻觉”（编造虚假信息）、“知识滞后”（训练数据未覆盖最新内容）、“专业度不足”（无法精准匹配垂直领域知识）的问题。

面试里更稳的表述是：RAG本质上是用“检索+生成”的协同模式，让大模型在特定领域（由知识库定义）内，输出精准、可控、可追溯的回答，是大模型落地垂直场景的核心方案。

为什么要用RAG，而不直接用大模型

Q：为什么不直接用大模型回答，非要做RAG知识库系统？

核心原因是直接使用大模型存在3个无法规避的问题，而RAG能精准解决，常见触发场景有4类：

1. 大模型存在幻觉：生成内容可能与事实不符，无法用于专业场景（如医疗、法律、企业内部问答）；
2. 知识存在滞后性：大模型训练数据有截止日期，无法获取实时/最新知识（如企业最新政策、行业新规）；
3. 垂直领域适配差：通用大模型对细分领域（如企业产品、专业技术）的知识覆盖不足，回答不够精准；
4. 回答不可追溯：大模型无法说明回答来源，出现问题无法排查，不符合合规要求（如金融、政务场景）。

但注意，不是所有场景都需要RAG。如果是通用闲聊、简单问答（无需精准事实），直接用大模型更高效；只有需要“精准、可追溯、专业、实时”回答的场景，RAG才有不可替代的价值。

追问1: RAG和微调 (Fine-tuning) 有什么区别? 该怎么选?

核心区别在于“知识承载方式”和“落地成本”，选择思路结合场景：

1. 微调：将知识“灌入”大模型参数中，优点是回答更流畅、贴合领域语气，缺点是成本高（需大量标注数据）、更新困难（知识变了要重新微调）、易出现过拟合；
2. RAG：将知识“存储”在知识库中，优点是成本低（无需大量标注）、更新灵活（直接修改知识库）、可追溯（能定位回答来源），缺点是检索精度影响回答质量，对长文本处理有挑战。

选择原则：知识高频更新、预算有限、需合规追溯 → 选RAG；知识稳定、追求极致流畅度、有充足数据和预算 → 选微调；实际落地中，多采用“RAG+轻量微调”的组合方案。

RAG知识库系统的核心组件有哪些

Q：一个完整的RAG知识库系统，主要由哪些模块组成？每个模块的作用是什么？

核心组件分为5个，缺一不可，各模块职责清晰、协同工作，流程为：数据接入→处理→存储→检索→生成：

1. 数据接入模块：负责采集、导入知识库的原始数据，常见数据源有文档（PDF、Word、TXT）、网页、数据库、表格等，核心要求是“兼容多格式、批量/增量导入”；
2. 文档处理模块（核心）：将原始文档转化为可检索的格式，核心步骤是“文档拆分→文本清洗→嵌入（Embedding）”：
 - 文档拆分：将长文档拆分为短文本块（Chunk），避免上下文过长导致检索精准度下降；
 - 文本清洗：去除无关内容（如页眉页脚、乱码），提取核心信息；
 - 嵌入（Embedding）：通过嵌入模型，将文本块转化为向量（Vector），用于后续相似性检索；
3. 向量数据库模块：存储文本块的向量和原始内容，核心作用是“快速相似性检索”，替代传统关系型数据库（无法高效处理向量检索）；
4. 检索模块：接收用户问题，将问题转化为向量后，在向量数据库中检索出与问题最相关的Top N文本块，核心要求是“精准、高效”；
5. 生成模块：将检索到的相关文本块、用户问题，结合Prompt模板，输入大模型，生成最终回答，核心是“融合检索信息、避免幻觉、保持流畅”。

补充：部分复杂系统会增加“Prompt工程模块”“重排模块”（优化检索结果顺序）“反馈模块”（收集用户反馈，优化检索和生成效果）。

文档拆分（Chunk）的技巧和粒度控制

Q：RAG中，文档拆分（Chunk）的粒度怎么控制？有什么技巧？拆分不好会有什么问题？

文档拆分是影响RAG检索精度的核心环节，核心原则是“拆分后的文本块，既保留完整语义，又不冗余”，不是越细越好，也不是越粗越好。

1. 常见拆分技巧：

- 按语义拆分（推荐）：以段落、章节为单位，确保每个文本块围绕一个核心主题（如一个段落讲一个知识点），避免拆分后语义断裂；
- 按长度拆分（辅助）：结合嵌入模型的最大上下文长度，设置文本块的长度范围（如512token、1024token），避免超出模型处理范围；
- 保留上下文关联：拆分时可保留文本块的前后缀（如每个文本块末尾加上下一段的开头），减少语义丢失；
- 特殊格式处理：对表格、代码块，单独拆分并标注格式，避免被误拆导致信息丢失。

2. 粒度控制判断标准：

- 粗粒度（大文本块）：优点是语义完整，缺点是冗余多、检索精准度低（无关信息多）；
- 细粒度（小文本块）：优点是检索精准，缺点是语义断裂、可能出现“碎片化”（单个文本块无法回答完整问题）；
- 合适的粒度：能完整回答一个具体的小问题，且不包含过多无关信息，比如“一个产品的功能介绍”“一个概念的定义”作为一个文本块。

3. 拆分不好的影响：

- 拆分过粗：检索时会匹配到大量无关内容，大模型生成回答时易混淆，甚至出现部分幻觉；
- 拆分过细：检索到的文本块无法构成完整语义，大模型无法基于碎片化信息生成准确回答，或回答不完整。

向量数据库的选型和核心指标

Q：RAG中常用的向量数据库有哪些？选型时重点看什么指标？

1. 常用向量数据库（按场景分类）：

- 开源免费（适合中小企业、测试场景）：Milvus（米诺斯，国内常用，支持大规模向量，易部署）、Chroma（轻量，适合快速上手，集成友好）、FAISS（Facebook开源，适合小规模向量，检索速度快）；
- 商业付费（适合大型企业、生产场景）：Pinecone（云端托管，无需部署，scalability强）、Weaviate（支持混合检索，功能丰富）、Zilliz Cloud（Milvus的云端版本，运维更省心）。

2. 核心选型指标（按优先级排序）：

- 检索精度：能否精准匹配与用户问题最相关的向量，核心看支持的索引类型（如IVF_FLAT、HNSW，HNSW更适合平衡速度和精度）；
- 性能：检索速度（毫秒级响应）、支持的向量规模（如百万级、亿级，对应不同业务体量）；
- 易用性：是否易部署、易集成（如支持Python SDK、与LangChain等框架兼容）、运维成本高低；
- 功能：是否支持混合检索（向量检索+关键词检索，提升精准度）、动态更新（增量导入文本块）、权限管理（合规场景必备）。

追问1：为什么不用MySQL、Redis这类传统数据库存向量？

因为传统数据库不支持“高效相似性检索”：

1. MySQL：本质是关系型数据库，存储向量需用BLOB类型，无法快速计算向量之间的相似度（如余弦相似度），检索速度极慢，无法支撑大规模向量场景；
2. Redis：虽能存储向量（通过插件），但检索精度和性能远不如专业向量数据库，且不支持复杂的索引优化，适合小规模、低精度的临时场景，不适合生产级RAG系统。

Embedding模型的选型和优化

Q：RAG中，Embedding模型怎么选？如何优化Embedding的效果？

Embedding模型的核心作用是“将文本转化为可用于检索的向量”，向量的质量直接决定检索精度，选型和优化需结合业务场景。

1. 模型选型（按场景分类）：

- 通用型（适合通用场景、快速上手）：Sentence-BERT（如all-MiniLM-L6-v2，轻量、速度快，适合大多数场景）、OpenAI的text-embedding-ada-002（精度高，需调用API，有成本）；
- 垂直领域型（适合专业场景）：如医疗领域的BioBERT、法律领域的Legal-BERT，能更好地理解领域内的专业术语，提升检索精度；
- 本地化部署（适合隐私敏感场景）：ERNIE 3.0 Tiny、ChatGLM-Embedding，可本地部署，避免数据泄露，适合企业内部知识库。

2. 优化Embedding效果的技巧：

- 文本预处理：清洗无关内容、去除停用词（如“的、地、得”），突出核心信息，减少噪声对向量的影响；
- Prompt优化：对文本块和用户问题添加Prompt（如“这是企业产品介绍：XXX”“请基于以下内容回答问题：XXX”），让模型更精准理解文本含义；

- 模型微调：针对自身业务场景，用领域内的文本数据微调Embedding模型，让向量更贴合领域语义；
- 向量归一化：将生成的向量做归一化处理，确保向量之间的相似度计算更准确。

RAG的检索策略和优化方法

Q：RAG中常用的检索策略有哪些？如何优化检索精度？

检索是RAG的“眼睛”，核心目标是“快速找到与用户问题最相关的文本块”，常用检索策略分为3类，优化方法围绕“提升精准度、减少冗余”展开。

1. 常用检索策略：

- 相似性检索（最基础）：计算用户问题向量与知识库中文本块向量的相似度（余弦相似度、欧氏距离），返回Top N相似度最高的文本块，适合简单场景；
- 混合检索（推荐，提升精准度）：结合“向量相似性检索+关键词检索”，比如先用关键词过滤掉无关文本块，再对剩余文本块做相似性检索，避免因向量语义偏差导致的检索失误；
- 多轮检索：针对复杂问题（如多步骤、多关键词），先将问题拆解为子问题，分别检索，再融合检索结果，确保覆盖所有核心信息；
- 重排（Reranking）：对检索到的Top N文本块，用重排模型（如Cross-BERT）再次排序，提升最相关文本块的排名，减少冗余信息。

2. 优化检索精度的方法：

- 优化文档拆分和Embedding模型（基础）：从源头提升向量质量和文本块的语义完整性；
- 调整检索参数：如调整Top N的数量（太多冗余、太少可能遗漏关键信息，通常设5-10）、相似度阈值（过滤掉相似度过低的文本块）；
- 问题改写（Query Rewriting）：对用户的模糊问题（如口语化、歧义问题），通过大模型改写为更精准的问题，再进行检索；
- 建立同义词/近义词词典：针对领域内的专业术语，建立同义词库，避免因关键词不一致导致的检索遗漏（如“AI”和“人工智能”）。

RAG落地过程中常见的问题和解决方案

Q：实际落地RAG知识库系统时，最容易踩什么坑？怎么解决？

RAG落地的核心难点的是“检索精度”和“生成质量”，常见坑有5类，配套解决方案可直接用于面试回答：

1. 检索精度低，找不到相关文本块：

– 原因：文档拆分不合理、Embedding模型不贴合场景、检索策略单一；

– 解决方案：优化文档拆分（按语义拆分，保留上下文）、更换贴合领域的Embedding模型、采用混合检索+重排策略。

2. 大模型仍出现幻觉，生成内容与知识库不符：

– 原因：检索到的文本块不相关、Prompt模板设计不合理、大模型过度联想；

– 解决方案：增加相似度阈值，过滤无关文本块；优化Prompt（明确要求“仅基于检索到的内容回答，未找到相关信息请说明”）；采用“检索结果+事实校验”双重机制。

3. 知识库更新麻烦，无法实时同步新内容：

– 原因：缺乏增量更新机制，每次更新需重新处理所有文档；

– 解决方案：搭建增量导入模块，新增/修改文档时，仅处理变化的部分，重新生成向量并更新到向量数据库；定期对知识库进行全量校验，确保内容准确性。

4. 长文本处理效果差（如长文档拆分后语义断裂）：

– 原因：文本块拆分过细，缺乏上下文关联；

– 解决方案：采用“父子块”拆分模式（父块为章节，子块为段落），检索时先匹配父块，再匹配子块；保留文本块的前后缀，补充上下文信息。

5. 系统响应速度慢，无法满足实时问答需求：

– 原因：向量数据库检索速度慢、Embedding生成耗时久、大模型调用延迟高；

– 解决方案：优化向量数据库索引（如用HNSW索引）、选用轻量的Embedding模型、对检索结果和Embedding向量做缓存、采用大模型量化版本（如4-bit量化）提升响应速度。

项目里怎么说（面试高频追问）【PS：这里是泛指所有的项目，不是本项目】

Q：如果面试官问你“项目中你是怎么设计和落地RAG知识库系统的”，你怎么答？

按“瓶颈→设计→落地→问题→优化”的结构回答，体现实操能力，避免只讲理论，参考结构如下：

1. 先讲原来的瓶颈：比如业务需要做企业产品问答，直接用通用大模型存在幻觉，无法精准匹配产品细节，且产品更新快，大模型无法实时同步知识，用户体验差；

2. 再讲系统设计思路：基于RAG架构，拆分5个核心模块，明确技术选型——数据接入支持PDF/Word批量导入，文档按语义拆分（每块512token），Embedding用all-MiniLM-L6-v2（本地化部署，兼顾速度和精度），向量数据库用Milvus，检索采用“混合检索+重排”，生成用ChatGLM-6B，搭配自定义Prompt模板；

3. 再讲落地过程中的问题：比如初期检索精度低，部分产品术语无法匹配；知识库更新繁琐，每次新增产品文档需重新全量处理；

4. 最后讲你的优化方案：优化文档拆分，增加产品术语同义词词典；搭建增量更新模块，实现文档新增/修改的实时同步；优化Prompt模板，限制大模型仅基于检索内容回答，减少幻觉；

这样回答，会让面试官觉得你不是只会背RAG的概念，而是有实际落地经验，知道如何解决实际问题。

高频追问补充

追问1：RAG中的Prompt怎么设计？有什么技巧？

核心原则是“明确指令、提供上下文、限制幻觉”，常用模板和技巧：

1. 基础模板：“请基于以下提供的参考内容，回答用户问题。参考内容：{检索到的文本块}。用户问题：{用户问题}。要求：仅使用参考内容中的信息，不添加任何额外信息；如果参考内容中没有相关信息，请直接说明‘未找到相关答案’；回答简洁、精准，贴合用户问题。”
2. 技巧：① 加入“角色提示”（如“你是企业产品顾问，仅基于提供的产品文档回答问题”）；② 明确禁止幻觉（如“禁止编造任何未在参考内容中出现的信息”）；③ 控制检索结果的展示格式（如按相似度排序，标注来源），方便大模型提取信息。

追问2：RAG系统的评估指标有哪些？怎么评估系统效果？

核心评估指标分2类，分别对应检索和生成，实操中需结合人工评估：

1. 检索指标（评估检索精度）：

- 召回率（Recall）：用户问题的相关文本块，被检索到的比例（越高越好，避免遗漏关键信息）；
- 精确率（Precision）：检索到的文本块中，与用户问题相关的比例（越高越好，减少冗余）；

2. 生成指标（评估回答质量）：

- 准确率（Accuracy）：生成的回答与知识库内容一致的比例（避免幻觉）；
- 流畅度（Fluency）：回答的语句通顺、符合逻辑；
- 相关性（Relevance）：回答与用户问题高度相关，不偏离主题；

3. 实操评估：除了量化指标，还需人工抽样评估（如抽取100个用户问题，检查回答是否准确、完整），结合用户反馈持续优化。


O1微服务架构设计

1.1 服务划分设计

- 用户服务（user-service）：用户认证、注册、权限管理
- 文件服务（file-service）：文件上传/下载、元数据管理、存储策略
- AI服务（ai-service）：文档摘要、纠错、关键词提取、RAG问答
- 文档服务（document-service）：文档CRUD、版本控制、搜索索引
- API网关（gateway-service）：路由转发、JWT鉴权、限流熔断

1.2 服务间通信设计

- OpenFeign声明式调用
- RabbitMQ异步消息队列
- Nacos服务发现与配置管理



一、微服务划分设计

解决了什么问题

随着业务发展，单体应用的代码越来越庞大，修改任何功能都需要重新部署整个系统，开发团队之间频繁出现代码冲突。想扩展某个模块时不得不扩展整个应用，造成资源浪费。更严重的是，一旦某个功能出现严重故障，整个系统都会崩溃。

为什么这么设计

我们按照业务领域来划分服务边界。用户服务专门处理"谁"的问题，包括身份认证、权限校验、用户信息管理。文件服务专门处理"存"的问题，包括文件上传下载、元数据记录、存储策略选择。AI服务专门处理"智"的问题，提供文档摘要、纠错、关键词提取和问答能力。文档服务专门处理"文"的问题，负责文档的创建读取修改删除、版本历史和搜索索引。网关服务则是统一入口，做路由转发、身份验证和流量控制。

这种设计背后的思想是，每个服务都有自己的明确职责，不会互相僭越。服务之间通过标准接口通信，内部实现可以随时更换而不会影响其他服务。

具体是怎么设计的

从项目目录结构可以清楚看到五个独立的服务模块，每个都有自己独立的代码仓库、Dockerfile和配置文件。服务之间通过HTTP接口或消息队列通信，不存在直接调用对方数据库的情况。网关服务作为唯一入口，所有外部请求都必须经过它。

为什么不采用别的方式

如果继续用单体架构，以上提到的所有问题都无法解决。传统ESB中心化架构虽然也能解耦，但总线本身会成为性能瓶颈和单点故障源。如果把服务拆得过细，比如拆成几十个纳米服务，维护成本会非常高，服务之间的调用关系会变得极其复杂，排查问题时要追踪一长串调用链，开发和运维都会崩溃。

二、服务间通信设计

1. OpenFeign声明式调用

解决了什么问题

在没有OpenFeign之前，如果文档服务想调用文件服务获取文件内容，需要手动拼接HTTP请求URL，手动处理服务发现（从注册中心获取可用地址），手动实现负载均衡（选择用哪个实例），还要处理网络超时和失败重试。这些跟业务逻辑毫无关系的样板代码散落在各处，严重污染了业务代码。

为什么这么设计

OpenFeign的核心思想是"声明式"，你只需要用Java接口描述"我要调用哪个服务的哪个接口"，框架会自动帮你处理所有底层的网络通信。你面向的是接口而不是URL，这符合面向对象设计的原则。接口定义好了之后，替换实现（比如从测试环境切到生产环境）只需要改配置，不改代码。

具体是怎么设计的

项目中定义了FeignGlobalConfig来统一配置超时时间和重试策略。连接超时设为10秒，读取超时设为60秒，这是因为AI服务处理文档可能需要较长时间。重试策略是失败后100毫秒开始重试，最多尝试3次。选择这个重试间隔是因为太短会给下游服务压力，太长会影响用户体验。

为什么不采用其他方式

Dubbo也是优秀的RPC框架，但它更强调高性能和同步阻塞调用，学习曲线较陡，Spring生态的集成度也不如OpenFeign。gRPC需要定义proto文件，虽然性能很好但增加了额外复杂度，对文档服务这种场景来说过于重量级。如果直接用RestTemplate手动处理服务发现和负载均衡，代码会变得冗长，而且每个团队可能实现得不一样，难以统一。

2. RabbitMQ异步消息队列

解决了什么问题

文件上传是一个高频操作，但如果每上传一个文件就同步等待AI分析完成，用户可能要等几十秒才能看到"上传成功"。这体验太差了。更重要的是，文件服务不应该依赖AI服务的可用性——如果AI服务挂了，文件上传也必须能正常工作。另外，大促期间可能瞬间有几万个文件同时上传，但AI服务处理能力有限，直接调用会把AI服务冲垮。

为什么这么设计

引入消息队列后，文件服务只需要把"有文件待处理"这个事件发送到队列里就可以立即返回用户"上传成功"。AI服务按照自己的节奏从队列消费消息进行处理。这就是典型的生产者-消费者模式，实现了

时间解耦（不用同步等待）、空间解耦（文件服务不需要知道AI服务在哪）和流量削峰（队列缓冲突发流量）。

具体是怎么设计的

AI服务配置了一个名为ai.exchange的交换机，绑定两个队列：ai.task.queue用于常规AI任务，ai.alert.queue用于告警消息。文件上传成功后往交换机发送一条消息，路由键是"task"，AI服务监听对应的队列处理任务。这种设计的好处是可以灵活扩展消费者数量来提高吞吐量，也可以添加新的队列处理不同类型的任务。

为什么不采用其他方式

Kafka吞吐量极高，但它的设计更偏向大数据场景，消息持久化机制复杂，延迟也比RabbitMQ高。对于文档处理这种需要快速响应的场景，RabbitMQ的轻量级模型更合适。直接用线程池异步处理看起来简单，但服务重启时未处理的任务会丢失，无法持久化。定时任务轮询的方式实时性太差，而且无论有没有任务都要不断查询数据库，浪费资源。

3. Nacos服务发现与配置管理

解决了什么问题

在微服务架构中，服务实例的地址是动态变化的——实例扩缩容、故障重启、容器漂移都会导致IP变化。如果把服务地址写死在代码或配置文件里，每次地址变更都要改一堆文件，容易出错。更糟糕的是，改完配置还要重启服务才能生效，生产环境不能随便重启。

为什么这么设计

Nacos充当了服务地址的"电话簿"和"配置中心"双重角色。服务启动时向Nacos注册自己的地址，调用方不需要知道具体IP，只需要知道服务名，Nacos会自动解析到当前可用的地址。这就是服务发现。同时，所有公共配置放在Nacos里，服务启动时从Nacos读取，修改配置只需要在Nacos控制台操作，服务自动感知无需重启。

具体是怎么设计的

AI服务的配置文件中指定了Nacos服务器地址为nacos:8848，服务名是ai-service。服务启动后会自动向Nacos注册，并定时发送心跳续约。如果服务不可用（没收到心跳），Nacos会自动把它的地址从

可用列表中移除，调用方不会拿到已故障的地址。

为什么不采用其他方式

Consul虽然是成熟的服务发现方案，但它是多语言友好的，对Spring Cloud的集成不如Nacos顺畅，需要额外配置。Eureka已经停止维护，不再是Spring Cloud官方推荐。Zookeeper的临时节点机制适合做分布式锁，但用于服务发现需要自己实现很多逻辑，性能也不如专门做服务发现的Nacos。静态配置文件的方式最原始，但完全无法应对服务动态变化的情况。

三、API网关设计

解决了什么问题

在有网关之前，前端要记住每个后端服务的地址，比如调用用户服务要访问192.168.1.100:8081，调用文件服务要访问192.168.1.101:8082。这暴露了内部架构，不安全也不好维护。而且每个服务都要重复实现一遍登录验证、跨域处理、限流熔断，代码重复难以维护。

为什么这么设计

网关作为统一入口，所有外部请求都先到网关。网关负责验证请求是否合法（JWT是否有效），然后根据路由规则转发到对应的服务。如果发现某个服务负载过高或故障，网关可以主动拒绝请求保护下游。这就像办公楼的门禁系统，访客先到前台登记，前台核实身份后指引到具体部门。

具体是怎么设计的

AuthGlobalFilter是网关的核心过滤器。它维护了一个白名单列表，登录和注册接口不需要验证直接放行。其他所有请求都必须携带有效的JWT token，过滤器验证token有效性后，把用户ID、用户名、角色等信息提取出来放到请求头里传递给下游服务。下游服务可以直接使用这些信息，不需要再解析token。过滤器优先级设为-100，确保它在路由之前执行。

为什么不采用其他方式

如果在每个微服务里单独做鉴权，代码重复是小事，更重要的是每个服务可能实现得不一样，存在安全漏洞。NGINX做反向代理很擅长，但它是底层网络代理，难以集成Spring Cloud的生态，服务发现、动态路由这些能力较弱。Kong是优秀的API网关产品，功能确实强大，但需要单独部署和维护，学习成本高，对现有架构改动较大。

四、整体设计思路

整个架构的设计原则是让每个服务专注于自己的业务，把跨领域的关注点（认证、流量控制、服务发现）抽离出来由专门的组件处理。

同步调用场景用OpenFeign是因为它的声明式风格让接口调用看起来就像调用本地方法一样自然，调试和测试都比较方便，而且跟Spring Cloud生态无缝集成。异步场景用RabbitMQ是因为它足够轻量，配置简单，界面友好，运维成本低，能够满足业务对实时性的要求。服务治理用Nacos是因为它同时解决了服务发现和配置管理两个问题，对Spring Boot应用友好，社区活跃文档丰富。

这套架构能让团队高效协作，不同服务可以由不同团队负责开发、测试和部署。可以根据各服务的负载情况独立扩展，比如AI服务CPU密集就多部署几个，文件服务IO密集就用更高性能的存储。系统整体具备容错能力，某个服务故障不会扩散到全局。

02RAG知识库设计

2.1 文档向量化设计

- 文本分割策略（Chunk Size、Overlap）
- Embedding模型选择与配置
- 向量存储方案（Redis/专业向量数据库）

2.2 检索策略设计

- 向量相似度匹配算法
- 重排序（Rerank）优化
- 上下文窗口管理

2.3 知识更新机制

- 增量索引更新
- 文档版本同步
- 过期知识清理



一、文档向量化设计

1.1 文本分割策略（Chunk Size、Overlap）

解决了什么问题

原始文档通常很长，少则几千字多则几万字，直接对整篇文档做向量化会产生几个问题：一是向量维度太大，超出Embedding模型的处理范围；二是语义模糊，把完全不相关的段落强行融合在一起；三是检索精度低，用户问一个问题，整篇文档作为匹配单元太粗糙。

为什么这么设计

将文档切分成中等大小的文本块（Chunk），每个块独立向量化。检索时以块为单位返回，能精准匹配用户问题的具体段落。选择合适的块大小是因为太小会丢失上下文语义（比如一段完整的论证被截断），太大又会把无关内容混进来。块之间保留一定重叠（Overlap）是为了防止语义被生硬截断，比如一句话被拆到两个块里，检索时可能丢失关键信息。

具体是怎么设计的

从DocumentVectorizer的代码可以看到，它接收任意长度的文本直接向量化。块的管理逻辑在KnowledgeBase中，当添加文档时，先将内容按一定规则分割成多个块，每个块单独调用vectorize生成向量，然后存储到VectorStore。块的元数据（所属文档ID、块序号、在原文中的位置等）也一并存储，便于后续还原上下文。

为什么不采用别的方式

如果直接对整篇文档向量化，效果会很差。一篇100页的PDF和一个10字的问题，它们的向量在语义空间里可能完全不接近。固定大小切分而不考虑语义边界是最简单的方式，但会把完整的句子或段落截断，影响理解。如果用更复杂的语义分割（按句子、段落、主题）虽然更精准，但实现成本高，对文档结构要求也高，目前阶段先用规则切分是合理的折中。

1.2 Embedding模型选择与配置

解决了什么问题

Embedding模型的作用是把文本转换成向量，让语义相似的内容在向量空间中距离相近。不同模型有不同的语义理解能力、生成向量维度、速度、成本。选择合适的模型直接影响RAG系统的效果。

为什么这么设计

从代码配置可以看到，项目使用了阿里云百炼的dashscope Embedding API，模型是text-embedding-v4，输出维度1024维。选择阿里云的原因有几个：一是国内服务，延迟和稳定性比调用OpenAI接口好很多；二是API简单，集成方便；三是成本相对可控，适合企业级应用。维度设为1024是因为这个维度既能保留足够的语义信息，又不会太大导致存储和计算成本过高。

具体是怎么设计的

DocumentVectorizer类封装了对dashscope API的调用。每次向量化时，构建TextEmbeddingParam参数，包含模型名称、API密钥和文本内容。调用后解析返回的向量结果，转换为float数组存储。配置文件中通过 `spring.ai.dashscope.api-key` 读取密钥，通过 `{spring.ai.dashscope.embedding.dimension:1024}` 设置维度，默认1024。批量向量化时会循环调用单条接口，逐条处理。

为什么不采用别的方式

如果用OpenAI的text-embedding-3-large，语义效果可能更好，但需要翻墙，延迟高，稳定性差，成本也更高。如果用本地部署的开源模型如sentence-transformers，优点是不需要付费，但需要GPU资源，部署和运维复杂，而且模型更新不方便。选择dashscope是因为它在效果和便利性之间取得了平衡，对中文语义理解做得不错，API响应速度快。

1.3 向量存储方案（Redis/专业向量数据库）

解决了什么问题

有了向量之后需要存储和检索。如果用传统关系型数据库存储向量，检索时需要计算向量相似度，MySQL等数据库不支持高效的向量运算，查询会非常慢。需要专门的向量存储方案来解决这个问题。

为什么这么设计

项目选择用Redis存储向量。Redis本身支持Hash和List数据结构，可以存储向量值和元数据，而且Redis本身就是微服务架构中常用的缓存组件，不需要额外引入新组件，降低了运维复杂度。虽然Redis本身不是专业的向量数据库，但通过自己实现余弦相似度计算，对于中小规模的知识库完全够用。

具体是怎么设计的

VectorStore类实现了向量存储的核心逻辑。它使用两个Redis键前缀：vector: 存储向量本身，metadata: 存储元数据。向量在存储时从float数组转换为List 以适配Redis的序列化。检索时，获取所有以vector:开头的键，逐一取出向量计算余弦相似度，然后排序返回TopK结果。这种暴力匹配的方式实现简单，对于向量数量不多（几千到几万）的场景完全够用。

为什么不采用别的方式

如果用专业的向量数据库如Milvus或Pinecone，它们有专门的向量索引（如HNSW、IVF），能支持十亿级向量的毫秒级检索。但引入这些组件会增加架构复杂度，需要单独部署和维护，对当前项目的规模来说过于重量级。如果直接用MySQL的向量列（MySQL 8.0+支持），向量计算能力有限，查询性能差。Redis虽然检索是暴力匹配，但胜在简单，对于这个知识库规模完全能hold住。

二、检索策略设计

2.1 向量相似度匹配算法

解决了什么问题

给定用户查询，需要在海量文档块中找到与查询语义最相关的那些。向量相似度算法解决的就是"哪些文档块跟这个问题最像"这个问题。

为什么这么设计

代码中实现的是余弦相似度（Cosine Similarity）。它的取值范围是-1到1，值越大表示两个向量越相似。选择余弦相似度是因为它关注的是向量方向的相似性而非绝对大小，这在文本语义匹配场景中非常合适——一段话长一点短一点，只要表达的核心语义相近，向量方向就接近，相似度就高。

具体是怎么设计的

VectorStore的search方法中遍历所有存储的向量，调用cosineSimilarity计算相似度。算法实现是：分子是两个向量的点积，分母是两个向量模的乘积。这种计算方式避免了向量长度的影响。得到所有候选的相似度分数后，按分数降序排列，取前topK个返回。

为什么不采用别的方式

除了余弦相似度，还有欧氏距离（Euclidean Distance）也是常用的向量距离度量。欧氏距离关注的是向量的绝对位置差异，更适合图像、语音等特征匹配场景。文本语义匹配更关注“说的是不是一回事”，方向的一致性比绝对距离更重要，所以余弦相似度更合适。还有点积相似度，跟余弦相似度类似但没有归一化，对向量长度敏感，在这个场景下不如余弦相似度稳健。

2.2 重排序（Rerank）优化

解决了什么问题

向量检索虽然快，但精度有限。Embedding模型在训练时追求的是全局语义理解，可能对某些局部细节把握不够准确。检索到的TopK结果可能存在语义相关但实际答案不精确的问题，需要进一步优化排序。

为什么这么设计

Reranker组件实现了多阶段检索策略。第一阶段用向量检索快速从海量数据中筛选出候选集（可以多取一些，比如Top50）。第二阶段用更精准的算法对候选集重新排序，选出最终最相关的几个返回。这种先粗召回再精排序的两阶段设计，在效果和性能之间取得平衡。

具体是怎么设计的

Reranker支持三种重排序策略。BM25_FUSION策略融合了BM25关键词匹配和向量相似度，权重分别是0.6和0.4。BM25是一种经典的信息检索算法，衡量的是关键词的匹配程度，跟向量相似度形成互补。HYBRID策略更进一步，同时考虑BM25和Cross-Encoder分数，各占50%权重。Cross-Encoder是更精准的语义匹配模型，但计算成本高，所以只对候选集重排而不做初筛。默认的CROSS_ENCODER策略则是完全用Cross-Encoder的分数作为最终分数。

为什么不采用别的方式

如果只用向量检索不做重排序，效果会打折扣，尤其是在需要精确匹配的问答场景。如果直接用Cross-Encoder做全量检索，计算量太大，延迟无法接受。BM25单独使用效果也不如向量检索+重排序的组合，因为它只考虑关键词字面匹配，无法理解语义。所以两阶段策略是目前业界的主流做法。

2.3 上下文窗口管理

解决了什么问题

RAG返回的答案需要引用相关文档块，但单个文档块可能不包含完整答案，需要把多个相关的块拼凑起来作为上下文传给大模型生成。同时，上下文太长会超过大模型的最大输入限制，需要精简。

为什么这么设计

从KnowledgeBase的搜索结果处理可以看到，返回的每个结果不仅包含向量相似度分数，还包含文档内容（content字段）和元数据。调用方可以根据这些信息决定取多少个块作为上下文。设计上每个块是独立存储的，上下文窗口大小由调用方控制，灵活度更高。

具体是怎么设计的

搜索结果返回后，调用方（如RagController）会获取多个候选块的内容，然后按需拼接成完整的上下文。如果上下文太长，会优先保留相似度最高的块，或者按相关性动态裁剪。每个块的元数据中记录了所属文档和位置序号，有助于判断是否需要补充相关块（比如文档的前后段落）来提供更完整的上下文。

为什么不采用别的方式

如果让系统自动管理上下文窗口，实现复杂度会很高——需要考虑块之间的关联性、语义连贯性、长度限制等因素。现在把控制权交给调用方，好处是灵活，不同场景可以采用不同的上下文策略。比如简单问答可以只用Top1，复杂分析可以拼更多块。代价是调用方需要自己处理这些逻辑。

三、知识更新机制

3.1 增量索引更新

解决了什么问题

知识库不是静态的，新文档会不断添加，旧文档会修改删除。如果每次更新都重新处理所有文档，成本太高且不现实。需要支持增量更新，只处理变化的部分。

为什么这么设计

KnowledgeBase的addDocument方法实现了增量添加逻辑。新文档直接调用添加方法，完成文本分割、向量化、存储三个步骤。已存在的文档如果内容变了，旧的向量需要先删除再重新插入。设计上把

文档内容和向量分开存储，元数据存储在Redis Hash中，增量更新时只更新变化的部分，不影响其他文档。

具体是怎么设计的

添加文档时，content存储到 content: 前缀的键中，元数据存储到 doc: 前缀的Hash中，向量存储到 vector: 前缀的键中，同时建立向量ID到元数据的关联。如果文档ID已存在，添加操作会覆盖旧的内容和向量，实现原子更新。批量导入时逐文档处理，单个文档失败不影响其他文档。

为什么不采用别的方式

如果用定时全量重建索引的方式，实现简单但代价太大，每次都要处理整个知识库，耗时长且影响线上服务。如果用消息队列驱动增量更新，实时性更好但架构复杂度增加。当前方案是同步增量更新，好处是实现简单、一致性好，对于知识库规模不大的场景完全够用。

3.2 文档版本同步

解决了什么问题

文档会不断迭代更新，新版本发布后，知识库中的向量索引也需要同步更新，否则用户问到的可能是过时的内容。同时需要保留版本历史，支持回滚。

为什么这么设计

FileVersionService管理文件的版本历史，当新版本上传时创建新版本记录。从代码可以看到版本记录包含版本ID、创建时间、上传者、备注等信息。版本切换时，旧版本的向量标记为非当前版本，新版本的向量作为当前版本。知识库在检索时默认只使用当前版本的向量。

具体是怎么设计的

创建新版本时，版本信息存入内存的ConcurrentHashMap中（代码注释提到待实现MinIO版本功能）。版本元数据中记录了是否是当前版本（isCurrent字段）。文档更新时，先从知识库删除旧向量，再插入新向量，保持一致。回滚操作只需把目标版本标记为当前版本即可。

为什么不采用别的方式

如果不做版本控制，文档更新后知识库无法追踪哪个版本对应哪个向量，查询结果可能不一致。如果版本信息存数据库会增加复杂度，现在用内存存储对于单实例部署够用，但多实例部署时版本信息不同步是潜在问题，当前设计偏简单，随着系统规模扩大需要升级为分布式版本管理。

3.3 过期知识清理

解决了什么问题

知识库持续运行后，旧文档删除、版本回滚等情况会产生孤立数据——有元数据没有向量，或者有向量没有元数据。长期积累会造成存储浪费和数据不一致。还需要支持TTL机制，让某些有时效性的知识自动过期。

为什么这么设计

VectorStore的delete方法和KnowledgeBase的removeDocument方法实现了文档删除逻辑。删除时同时清理向量、元数据和文档内容三部分，保持数据一致。对于过期清理，Redis本身的Key过期机制可以辅助实现（比如设置TTL），定期清理任务可以扫描孤立数据。

具体是怎么设计的

删除文档时，先删除Redis中的 vector: 前缀的向量键，再删除 metadata: 前缀的元数据键，最后删除 doc: 前缀的文档信息键。三步顺序执行，确保不会留下孤立数据。孤立数据检测可以通过扫描所有向量键，检查对应的元数据是否存在，缺失则清理。对于TTL过期，Redis Key本身支持设置过期时间，到期自动删除。

为什么不采用别的方式

如果依赖Redis的TTL做自动清理，问题是向量数据和文档内容分散在不同的Key中，无法用同一个TTL统一管理。如果不做孤立数据检测，存储会持续膨胀，最终影响检索性能。现在手动调用删除方法虽然需要调用方主动触发，但逻辑清晰、可控性好。

03AI Agent设计

3.1 Agent架构设计

- ChatReactAgent：对话式Agent，支持工具调用
- PlanExecuteAgent：任务规划与执行Agent
- KnowledgeIndexAgent：知识库索引管理Agent

3.2 工具调用设计

- MCP (Model Context Protocol) 集成
- 技能注册与执行框架
- 工具参数校验与错误处理

3.3 会话管理设计

- 对话上下文维护
- 长期记忆存储
- 多轮对话状态追踪

一、Agent 架构设计

解决了什么问题

- 复杂任务的智能处理：传统的单一函数调用难以处理用户的复杂自然语言请求，需要将任务分解为多个步骤执行
- 上下文记忆与多轮对话：单次交互无法满足连贯对话需求，需要维护对话历史和上下文状态
- 知识检索与增强：LLM 缺乏实时和私有知识，需要结合知识库提供更准确的答案
- 可扩展性问题：硬编码的功能难以快速添加新能力，需要模块化的扩展机制

为什么这么设计

职责分离原则：三种 Agent 各司其职，ChatReactAgent 专注对话交互，PlanExecuteAgent 处理复杂任务，KnowledgeIndexAgent 管理知识库

经典设计模式的应用：

- ReAct 模式：推理（Reason）+ 行动（Act）交替进行，提升决策准确性
- Plan-Execute 模式：先规划后执行，支持重新规划，提高任务成功率
- Spring 生态集成：利用 Spring 的依赖注入、组件化等特性，便于维护和扩展
- 渐进式设计：代码中预留了很多扩展点（如 generateTags 方法目前是硬编码的），方便后续迭代升级

具体是怎么设计的

1. ChatReactAgent – 对话式 Agent

```
▼ Java |
1  @Component
2  ▼ public class ChatReactAgent {
3      // 核心流程：
4      // 1. 获取对话历史
5      // 2. 检索知识库相关内容
6      // 3. 构建提示词调用 LLM
7      // 4. 保存对话记录和上下文
8      }
```

2. PlanExecuteAgent – 任务规划与执行 Agent

```
▼ Java |
1  @Component
2  ▼ public class PlanExecuteAgent {
3      // 核心流程：
4      // 1. Plan: 调用 LLM 将任务分解为步骤
5      // 2. Execute: 逐个执行步骤，识别并调用相应技能
6      // 3. Replan: 失败时重新规划并执行
7      }
```

3. KnowledgeIndexAgent – 知识库索引管理 Agent

```
1 @Component
2 public class KnowledgeIndexAgent {
3     // 核心功能：
4     // 1. 文档索引：向量化 + 分类 + 打标签
5     // 2. 知识检索：相似度搜索
6     // 3. 索引管理：增删操作
7 }
```

架构特点：

- 所有 Agent 都是 Spring 组件（@Component），通过依赖注入协作
- 使用策略模式和工厂模式思想，不同 Agent 处理不同场景
- 清晰的分层：Agent 层 -> Service 层 -> Skill 层

为什么不采用其它方案

1. 不采用单一全能 Agent：

避免 God Class 问题，单一 Agent 会变得过于复杂难以维护

三种场景的技术实现差异较大，分离后更易优化

2. 不采用 LangChain 等第三方框架：

- 采用Spring AI框架，可以很好的开发轻量级应用
- 轻量级实现，避免引入过多依赖和复杂度
- 便于根据业务需求定制化开发

3. 不采用纯规则引擎：

- 规则引擎难以处理自然语言的模糊性和复杂性
- LLM 的灵活性远超规则匹配

二、工具调用设计

解决了什么问题

- 能力扩展问题：需要一种标准化的方式添加新功能（文件上传、删除等）
- 安全调用问题：工具调用需要权限校验和审计日志

- 参数验证问题：确保工具收到正确的输入参数、
- 错误处理问题：工具执行失败时要有统一的处理机制

为什么这么设计

- 接口抽象：Skill 接口定义了统一的契约，便于扩展
- 注册发现模式：SkillRegistry 集中管理所有技能，实现解耦
- 分层执行：SkillExecutor 和 SkillExecutorService 各司其职，一层负责内部逻辑，一层负责业务封装
- 审计与权限：InternalService 提供权限检查和审计日志功能

具体是怎么设计的

1. Skill 接口 – 技能契约

```
1 public interface Skill {
2     String getName(); // 技能名称
3     String getDescription(); // 技能描述
4     Object execute(Object... parameters); // 执行技能
5 }
```

2. SkillRegistry – 技能注册表

```
1 @Component
2 public class SkillRegistry {
3     private final Map<String, Skill> skills = new HashMap<>();
4     // 核心功能：注册技能、获取技能、获取所有技能
5 }
```

3. SkillExecutor – 技能执行器

```
1 @Component
2 public class SkillExecutor {
3     // 核心流程：
4     // 1. 接收技能名称和参数
5     // 2. 权限检查
6     // 3. 执行相应技能
7     // 4. 记录审计日志
8 }
```

设计特点：

- 简单的技能定义，易于扩展
- 支持运行时动态注册（通过 registerSkill 方法）
- 内置审计日志和权限检查机制
- 统一的错误处理和返回格式

为什么不采用其它方案

1. 不采用 MCP（Model Context Protocol）完全实现：

- 项目目前处于初级阶段，完整 MCP 实现过于复杂
- 当前功能用简单的接口设计已经够用
- 预留了扩展空间，后续可逐步接入

2. 不采用直接函数调用：

- 缺少统一的参数校验、错误处理、审计等横切关注点
- 难以实现动态发现和注册

3. 不采用复杂的工作流引擎：

- 过度设计，当前需求不需要复杂的编排
- 增加学习成本和维护复杂度

三、会话管理设计

解决了什么问题

- 多轮对话连贯：用户与系统的交互不是单次的，需要维护对话历史

- 上下文持久化：对话信息需要持久化，避免服务重启丢失
- 状态追踪：需要追踪对话过程中的各种状态信息
- 会话生命周期管理：创建、查询、结束等生命周期操作

为什么这么设计

双管理器模式：

- ConversationManager：管理对话历史和生命周期
- ContextManager：管理上下文状态信息
- 职责清晰，便于各自独立演进

Redis 作为存储：

- 高性能读写，适合对话场景
- 支持 TTL 自动过期，避免内存泄漏
- 分布式支持，便于集群部署

配置可定制：

- max-messages：最大消息数
- expiry-hours：过期时间
- 通过配置文件灵活调整

具体是怎么设计的

1. ConversationManager – 对话管理器

```
1  @Component
2  public class ConversationManager {
3      // 核心功能：
4      // - createConversation: 创建新对话
5      // - addMessage: 添加消息
6      // - getConversationHistory: 获取历史
7      // - deleteConversation: 删除对话
8      // - getUserConversations: 获取用户对话列表
9  }
```

2. ContextManager – 上下文管理器

```
1  @Component
2  public class ContextManager {
3      // 核心功能：
4      // - getContext: 获取上下文
5      // - updateContext: 更新上下文
6      // - setContextValue/getContextValue: 单个字段操作
7      // - clearContext: 清理上下文
8      // - mergeContext: 合并上下文
9  }
```

存储结构：

- 对话 Key: conv:{conversationId} (Hash 结构)
- 上下文 Key: ctx:{conversationId} (Hash 结构)
- 字段包括: userId、createdAt、updatedAt、messages 等

为什么不采用其它方案

1. 不采用内存存储：

- 服务重启数据丢失
- 无法支持多实例部署
- 内存占用不可控

2. 不采用数据库存储：

- 读写性能不如 Redis
- 对话数据不需要长期持久化（TTL 机制更合适）
- 增加数据库压力

3. 不采用单一管理器：

- 对话历史和上下文状态是两个不同的概念
- 分离后更易维护和测试
- 可以独立调整各自的存储策略

总结

- 模块化设计：职责分离，易于扩展
- 渐进式实现：从简单到复杂，预留扩展点
- Spring 集成：充分利用生态优势
- 实用性优先：不过度设计，满足当前需求

04文件服务设计

4.1 存储架构设计

- 本地存储 + MinIO分布式存储
- 文件分片上传策略
- 存储类型枚举管理


4.2 文件元数据设计

- 文件信息数据库表结构
- 文件版本历史管理
- 文件权限控制

4.3 文件操作设计

- 文件上传/下载/删除流程
- 文件类型校验与大小限制
- 文件内容预览生成

DocAI 文档处理主流程图



一、存储架构设计

解决了什么问题

- 1. 文件存储的灵活性问题：不同场景下需要不同的存储方式（本地开发用本地存储，生产用分布式存储）
- 2. 大文件上传问题：直接上传大文件容易超时、失败，需要分片上传机制
- 3. 存储类型管理问题：需要统一管理不同存储后端，便于切换
- 4. 存储扩展性问题：需要支持后续接入更多存储类型（如 AWS S3）

为什么这么设计

- 1. 策略模式：通过配置文件切换存储类型，便于根据环境选择不同存储后端
 - 2. 多层抽象：FileService 接口定义统一操作，具体实现由 FileServiceImpl 根据配置切换
 - 3. 容错设计：数据库不可用时不影响文件存储，降级处理
 - 4. 渐进式设计：预留 S3 存储类型预留，后续可扩展 4.1.3 具体是怎么设计的
- 存储架构：

- 配置层：FileStorageConfig 统一管理存储配置

```
1 // 支持配置：存储类型、本地路径、最大文件大小、MinIO 桶名
```

- 存储类型枚举：StorageTypeEnum 定义三种存储类型

▼ Java

```
1 LOCAL("local", "本地存储"),
2 MINIO("minio", "MinIO存储"),
3 S3("s3", "AWS S3存储")
```

- 分片上传策略：
 - a. 前端分片：使用 ConcurrentHashMap 暂存分片文件
 - b. 合并：按顺序读取分片合并后写入目标存储
 - c. 清理：合并完成后删除临时分片文件
 - MinIO 集成：MinioConfig 配置 MinIO 客户端
- 设计特点：
- 统一接口，易于扩展新存储类型

- 容错设计，数据库故障不影响文件操作
- 分片上传支持，大文件上传
- 配置驱动，通过配置文件切换存储方式

为什么不采用其它方案

1. 不采用固定单一存储：
 - 开发环境本地存储方便，生产环境需要分布式存储
 - 便于根据需求灵活切换
2. 不采用直接文件系统直接读写：
 - 缺少元数据管理
 - 缺少权限控制
 - 缺少分布式支持
3. 不采用复杂的存储网关：
 - 过度设计，当前需求不需要
 - 增加复杂度和维护成本

二、文件元数据设计

解决了什么问题

1. 文件信息管理问题：需要记录文件的各种元数据信息
2. 文件追踪问题：需要知道文件存放在哪里、多大、什么类型
3. 文件版本问题：需要支持文件版本管理（预留设计）
4. 文件权限问题：需要控制谁能访问文件

为什么这么设计

1. 数据库 + 存储分离：文件内容存储，元数据单独管理
2. UUID 作为主键：避免文件名冲突，便于跨存储管理
3. 状态字段：支持软删除等功能
4. 创建时间戳：便于追踪文件操作记录 4.2.3 具体是怎么设计的
文件元数据表结构：

```
1  @TableName("file_metadata")
2  public class FileMetadata {
3      @TableId(type = IdType.ASSIGN_UUID)
4      private String
5      id;                // 主键UUID
6      private String
7      fileId;           // 文件ID
8      private String
9      fileName;         // 文件名
10     private String
11     originalFileName;  // 原始文件名
12     private String
13     filePath;          // 文件路径
14     private String
15     fileType;          // 文件类型
16     private long
17     fileSize;          // 文件大小
18     private String
19     md5;               // 文件MD5
20     private String
21     storageType;        // 存储类型
22     private String
23     bucketName;        // 存储桶名
24     private String
25     objectKey;         // 对象键
26     private String
27     status;            // 状态
28     private String
29     createBy;          // 创建者
30     private LocalDateTime
31     createTime;        // 创建时间
32     private LocalDateTime
33     updateTime;        // 更新时间
34 }
```

文件类型枚举：

```
1 public enum FileTypeEnum {  
2     IMAGE("image", "图片文件"),  
3     DOCUMENT("document", "文档文件"),  
4     VIDEO("video", "视频文件"),  
5     AUDIO("audio", "音频文件"),  
6     ARCHIVE("archive", "压缩文件"),  
7     OTHER("other", "其他文件")  
8 }
```

设计特点：

- 双 ID 设计（id 和 fileId，便于扩展）
- 完整的元数据信息
- 支持多种存储类型适配
- 预留状态管理

为什么不采用其它方案

1. 不采用文件名直接作为标识：
 - 文件名可能冲突
 - 不便于跨存储迁移
2. 不采用 JSON 存储元数据：
 - 查询效率低
 - 不便于事务管理
3. 不采用复杂的版本控制：
 - 初赛先简化设计，后续可扩展

三、文件操作设计

解决了什么问题

1. 文件操作标准化问题：上传、下载、删除、重命名等操作需要统一接口
2. 文件安全问题：需要校验文件类型和大小限制
3. 用户体验问题：需要支持文件预览功能
4. 操作审计问题：需要记录文件操作

为什么这么设计

1. RESTful API 设计：统一的接口风格
2. 分层设计：Controller -> Service -> Storage 分层清晰
3. 事件驱动：通过 RabbitMQ 发送文件操作事件
4. 容错处理：数据库不可用时降级处理 4.3.3 具体是怎么设计的

文件服务接口：

```
1 public interface FileService {  
2     String upload(MultipartFile file);           // 单文件上传  
3     String[] uploadMultiple(MultipartFile[] files); // 多文件上传  
4     void uploadChunk(MultipartFile chunk, String fileId, int chunkIndex,  
5                     int totalChunks); // 分片上传  
6     String mergeChunk(String fileId, String fileName); // 分片合并  
7     byte[] download(String fileId);           // 文件下载  
8     void delete(String fileId);               // 文件删除  
9     void rename(String fileId, String newName); // 文件重命名  
10    void move(String fileId, String targetPath); // 文件移动  
11    String copy(String fileId, String targetPath); // 文件复制  
12 }
```

文件操作流程：

1. 上传流程：
 - 生成文件 ID (UUID)
 - 根据存储文件到存储后端
 - 保存元数据到数据库 (容错)
 - 发送 RabbitMQ 事件
2. 下载流程：
 - 从数据库获取元数据
 - 根据存储类型读取文件
 - 返回文件内容
3. 删除流程：
 - 从数据库获取元数据
 - 从存储后端删除文件
 - 删除元数据 (容错)

文件校验：

- 通过 FileStorageConfig 配置 maxSize 限制文件大小
- 文件类型通过 fileType 字段记录
文件预览：
- 复用下载接口，直接返回文件内容
事件通知：
- 通过 RabbitMQ 发送文件上传、下载、删除事件

为什么不采用其它方案

1. 不采用直接文件系统权限控制：
 - 不便于跨平台
 - 不便于分布式部署
2. 不采用 WebDAV 协议：
 - 学习成本高
 - 不便于集成到现有架构
3. 不采用复杂的工作流引擎：
 - 过度设计，当前需求不需要

总结

- 存储抽象：统一的存储接口，便于扩展
- 容错设计：数据库故障不影响文件操作
- 事件驱动：通过 RabbitMQ 解耦文件操作
- 配置驱动：通过配置文件灵活切换存储方式

05用户认证与安全设计

5.1 JWT鉴权设计

- Token生成与解析
- Token刷新机制
- Token过期与黑名单

5.2 安全配置设计

- Spring Security配置
- CORS跨域策略
- 请求限流与防护

5.3 密码安全设计

- BCrypt加密存储
- 密码强度校验
- 登录失败重试限制

一、JWT鉴权设计

解决了什么问题

解决了微服务架构下的无状态认证问题，无需服务端存储Session即可识别用户身份；解决了跨服务认证问题，多个服务共享统一的认证机制；解决了Token刷新问题，用户可在Token过期前无感刷新；解决了身份识别问题，可从Token中快速提取用户身份信息。

为什么这么设计

采用双Token机制，AccessToken有效期30分钟用于接口调用，RefreshToken有效期7天用于刷新，平衡安全性和用户体验；在网关层集中鉴权，减轻各服务压力，便于统一管理；通过请求头将用户信息传递给下游服务，避免各服务重复解析Token；将JWT操作封装在公共模块，便于各服务复用。

具体是怎么设计的

Token生成与解析：使用JWT工具类统一管理Token操作，包含密钥配置、过期时间设置。登录成功后生成双Token，AccessToken中包含用户ID、用户名、角色信息，RefreshToken仅包含用户ID。Token验证时检查签名和过期时间，解析时提取用户信息。

```
1 // Token中包含用户ID、用户名、角色信息
2 String accessToken = JwtUtils.
3 generateToken(user.getId(), user.
4             getUsername(), user.getRole());
5 String refreshToken = JwtUtils.
6 generateRefreshToken(user.getId());
```

- Token刷新机制：提供专门的刷新令牌接口，用户使用RefreshToken换取新的AccessToken。刷新时验证RefreshToken的有效性，查询用户信息后生成新的AccessToken返回，无需重新登录。
- Token过期与验证：Token自带过期时间字段，验证时自动检查是否过期。网关层配置白名单路径，登录、注册、刷新令牌等接口免认证，其他接口需要携带有效的Bearer Token。
- 网关鉴权：网关全局过滤器拦截所有请求，检查白名单路径，提取并验证Token，验证通过后将用户ID、用户名、角色等信息添加到请求头（X-User-Id、X-Username、X-Role）传递给下游服务，同时记录网关日志和告警信息。

为什么不采用其它方案

不采用Session认证，因为Session需要服务端存储状态，不适合微服务架构，跨服务共享Session复杂，也不便于水平扩展；

不采用OAuth2.0完整流程，因为过度设计，当前需求不需要，会增加复杂度和学习成本；

暂时不采用Redis存储Token，因为会增加Redis依赖，当前设计更简单，如需黑名单机制可后续扩展。（但是面试回答的时候可以说引入了Redis，并介绍相关依赖，我后续也会更新这部分代码）

二、安全配置设计

解决了什么问题

解决了CSRF攻击防护问题，API服务采用适合的CSRF策略；解决了跨域请求问题，前后端分离架构需要CORS支持；解决了请求路径权限控制问题，不同接口设置不同的访问权限；解决了统一安全配置问

题，多个微服务共享一致的安全配置。

为什么这么设计

采用基础配置继承方式，BaseSecurityConfig提供通用的安全设置，各服务继承使用，避免重复代码；使用无状态会话管理，适合API服务，不依赖Session；配置白名单机制，登录、注册、Swagger文档等接口免认证访问；采用网关+服务双重安全配置，网关层鉴权，服务层也有安全保障。

具体是怎么设计的

- Spring Security配置：基础安全配置类禁用CSRF保护，采用无状态会话管理，添加JWT认证过滤器。各服务的安全配置继承基础配置，在此基础上配置具体的路径权限规则，如Swagger相关路径、登录注册接口完全放行，其他接口需要认证。

```
1 // 基础配置：禁用CSRF、无状态会话、添加JWT过滤
2 器
3 applyBaseSecurityConfig(http);
4 // 配置路径权限：Swagger、登录注册放行，其他需
5 要认证
```

- CORS跨域策略：预留跨域配置扩展点，实际项目中可根据需要配置允许的源、HTTP方法、请求头等，支持前后端分离架构的跨域请求。
- 请求防护：通过网关日志记录所有请求信息，包括访问路径、方法、用户ID、时间戳等，发送到消息队列；配置网关告警机制，对未授权请求、无效令牌等异常情况发送告警消息，便于监控和防护。

为什么不采用其它方案

- 不启用CSRF保护，因为API服务使用Token认证，CSRF风险较低，同时简化了配置；
- 不采用复杂的权限框架，因为当前需求简单，基础的角色控制足够，避免过度设计；
- 不在每个服务都做鉴权，因为网关统一鉴权效率更高，减少重复代码，便于统一管理。

三、密码安全设计

解决了什么问题

解决了密码明文存储问题，即使数据库泄露也不会直接暴露用户密码；解决了密码强度不足问题，引导用户设置更安全的密码；预留了暴力破解防护能力，可防止恶意尝试登录；解决了用户输入校验问题，统一校验邮箱、手机号等格式。

为什么这么设计

采用BCrypt加密算法，自带盐值防止彩虹表攻击，计算成本高增加暴力破解难度；统一使用参数校验工具，避免重复代码，确保输入格式正确；设计用户状态管理，可禁用异常用户；通过事件日志记录登录、注册等操作，便于安全审计。

具体是怎么设计的

- BCrypt加密存储：使用Spring Security提供的BCryptPasswordEncoder进行密码加密。注册时将用户输入的密码加密后存储到数据库，不保存明文；登录时使用相同的加密算法验证密码是否匹配。

```
1  // 注册时加密密码
2  user.setPassword(passwordEncoder.encode
3                      (registerDTO.getPassword()));
4  // 登录时验证密码
5  passwordEncoder.matches(loginDTO.
6                          getPassword(), user.getPassword())
```

- 密码强度校验：提供密码格式校验工具，要求密码包含大小写字母、数字和特殊字符，且长度至少8位。注册时调用校验工具验证密码强度，不符合要求则提示用户。
- 登录安全管理：用户表设计状态字段，支持禁用异常账号。预留登录失败重试限制扩展点，可使用Redis记录失败次数，达到阈值后临时锁定账号，防止暴力破解。
- 其他参数校验：统一使用参数校验工具，对用户名、邮箱、手机号等进行非空和格式校验，邮箱使用正则表达式验证格式，手机号验证国内手机号格式，确保数据有效性。

为什么不采用其它方案

- 不采用MD5或SHA加密，因为这些算法计算太快，容易被暴力破解，且需要手动管理盐值，安全性不如BCrypt；
- 不采用第三方认证服务，因为会增加外部依赖和成本，数据不在自己掌控中；
- 不采用过于复杂的密码策略，因为当前设计已满足基本需求，过于复杂的策略会影响用户体验。

总结

采用双Token机制实现无状态认证，网关层集中鉴权，服务层继承基础安全配置，密码使用BCrypt加密存储，整体架构清晰，安全性较好。预留了Token黑名单、CORS配置、请求限流、登录失败重试限制等扩展点，后续可根据需要逐步完善。（后续将逐步完善项目）

06API网关设计

6.1 路由规则设计

- 服务路由映射
- 路径前缀匹配
- 负载均衡策略

6.2 全局过滤器设计

- JWT认证过滤器
- 请求日志记录
- 请求头处理

6.3 限流熔断设计

- Sentinel限流规则
- Redis分布式限流
- 服务降级策略

一、路由规则设计

解决了什么问题

解决了服务路由映射问题，将外部请求根据路径转发到对应的微服务；解决了路径前缀匹配问题，支持灵活的路由规则配置；解决了服务发现与负载均衡问题，支持动态发现服务实例并分发请求。

为什么这么设计

采用Spring Cloud Gateway作为网关组件，内置强大的路由规则引擎；支持服务发现模式（lb://）和直连模式（http://）两种模式，便于开发和生产环境灵活切换；使用配置驱动的方式配置路由，无需代码硬编码；集成Nacos服务发现，自动感知服务实例变化；支持负载均衡策略默认使用轮询方式，简单高效。

具体怎么设计的

- 服务路由映射：通过Java配置类定义路由规则，将/api/users/**路径映射到用户服务，/api/files/**路径映射到文件服务，/api/ai/**路径映射到AI服务，/api/documents/**路径映射到文档服务。路由目标地址通过配置参数管理，支持动态调整。

```
1 // 路由配置示例
2 .route("user", r -> r.path("/api/users/"
3     **").uri(userServiceUri))
4 .route("file", r -> r.path("/api/files/"
5     **").uri(fileServiceUri))
```

- 路径前缀匹配：采用Ant风格路径匹配规则，支持**通配符，如/api/users/**匹配该前缀下的所有路径。网关将匹配的路径原样转发到下游服务，下游服务无需感知网关的存在。
- 负载均衡策略：支持两种路由模式，服务发现模式使用lb://前缀，自动从Nacos获取服务实例列表，使用默认轮询策略分发请求；直连模式使用 http://前缀，直接转发到指定地址，适合开发调试环境。路由目标地址可通过配置文件灵活切换。

为什么不采用别的方式

- 不采用Nginx作为网关，因为Nginx配置修改需要重启，不支持Java生态的服务发现和过滤器链；
- 不采用Zuul1.x，因为是阻塞IO模型，性能不如Spring Cloud Gateway的响应式模型；
- 不采用手动写代码转发，因为可维护性差，缺少成熟组件的丰富功能。

二、全局过滤器设计

解决了什么问题

解决了JWT认证问题，在网关层统一鉴权，避免各服务重复实现；解决了请求日志记录问题，统一记录所有请求信息；解决了请求头处理问题，将用户信息安全传递给下游服务。

为什么这么设计

采用全局过滤器实现横切关注点，符合网关层统一处理；白名单机制，登录注册等接口免认证；使用Ordered接口控制过滤器优先级，确保鉴权优先执行；通过请求头传递用户信息，下游服务直接使用；集成RabbitMQ发送网关日志和告警，异步解耦。

具体怎么设计的

- JWT认证过滤器：实现GlobalFilter和Ordered接口，优先级设为-100优先执行。拦截所有请求，检查白名单路径，白名单直接放行。从请求头获取Bearer Token，验证Token有效性，无效返回401。验证通过后将用户ID、用户名、角色添加到请求头（X-User-Id、X-Username、X-Role）传递给下游服务。
- 请求日志记录：所有请求都记录日志，包括路径、方法、用户ID、时间戳，通过RabbitMQ发送到消息队列。对未授权请求、无效令牌等异常情况发送告警消息。

```
1 // 白名单配置示例
2 private static final List<String>
3 WHITE_LIST = List.of(
4     "/api/users/login",
5     "/api/users/register",
6     "/api/users/refresh"
7 );
```

- 请求头处理：验证Token成功后，修改请求对象，将用户信息添加到新的请求头中，下游服务从请求头中直接读取用户信息，无需再次解析Token。同时支持CORS跨域配置，允许指定来源、方法、请求头，允许携带凭证。

为什么不采用别的方式

- 不在每个服务中做鉴权，因为重复代码，维护成本高，网关统一鉴权效率更高；
- 不采用Session，因为是无状态架构，Token方式更适合；
- 不直接在请求参数传递用户信息，因为不安全，请求头更规范。

三、限流熔断设计

解决了什么问题

解决了限流问题，防止流量突增导致服务过载；解决了分布式限流问题，多实例网关统一限流；解决了服务降级问题，服务异常时提供降级方案。

为什么这么设计

预留Sentinel集成能力，配置中已引入sentinel.enabled配置项，默认关闭；预留Redis分布式限流配置，包括开关、前缀、默认限流阈值；配置文件设计支持灵活配置限流规则；当前版本优先保证核心功能可用，后续可逐步完善限流熔断能力。

具体怎么设计的

- Sentinel限流规则：配置文件中预留Sentinel配置，支持启用/禁用，后续可配置QPS限流、线程数限流、热点限流等规则，可配置流控模式（直接、关联、链路），可配置流控效果（快速失败、预热、排队等待）。
- Redis分布式限流：配置文件中预留Redis限流配置，包括开关、Redis键前缀、默认限流速率、默认突发流量限制。使用Redis作为限流存储，实现多网关实例共享限流数据，支持基于令牌桶或漏桶算法。

```
1  # 限流配置示例
2  custom:
3    rate-limit:
4    enable: true
5    redis-key-prefix: gateway:rate-limit
6    default-rate: 100
7    default-burst: 200
```

- 服务降级策略：预留降级策略扩展点，服务超时或异常时，可返回默认值、缓存数据、友好提示等，避免级联故障。

为什么不采用别的方式

- 不采用Guava RateLimiter，因为是单机限流，不支持分布式；
- 不直接在每个服务中做限流，因为网关统一限流更高效，可保护整个系统；
- 不一开始就实现复杂的限流，因为当前阶段先保证核心功能可用，后续可根据需要逐步完善。

总结

网关设计采用Spring Cloud Gateway作为核心组件，通过配置驱动的路由规则，全局过滤器实现鉴权、日志、跨域，预留限流熔断扩展点。当前版本已实现路由转发、JWT鉴权、请求日志、CORS配置，限流熔断功能已预留配置和扩展能力，后续根据需要逐步完善。

07消息队列设计

7.1 RabbitMQ配置设计

- 交换机与队列绑定
- 消息持久化策略
- 消息确认机制

7.2 消息消费者设计

- 异步文件处理
- 文档索引更新
- 用户通知推送

7.3 消息可靠性设计

- 死信队列配置
- 消息重试机制
- 消息幂等性保障

一、RabbitMQ配置设计

解决了什么问题

解决了交换机与队列绑定问题，不同服务有独立的交换机和队列，避免相互干扰；解决了消息持久化问题，服务重启后消息不丢失；解决了消息传递架构问题，支持异步解耦、流量削峰。避免某个接口因为下游服务调用使得响应时间过长，例如AI接口的调用，采用异步的方式，用户无明显延迟感知。

为什么这么设计

采用TopicExchange主题交换机，支持灵活的路由键匹配；每个服务有独立的交换机和队列，服务自治，互不影响；队列和交换机都设置为持久化，保证消息可靠性；使用点分隔命名规范（如user.register.queue），清晰易读；JSON序列化消息，支持复杂对象传输。

具体怎么设计的

- 交换机与队列绑定：每个服务配置独立的TopicExchange交换机，如user.exchange、file.exchange、gateway.exchange。每个交换机绑定多个队列，使用不同的路由键区分。例如用户服务绑定用户注册队列、密码重置队列、操作日志队列，分别对应user.register、user.password.reset、user.operate.log路由键。

```
1 // 交换机队列绑定示例
2 @Bean
3 public Binding bindingUserRegisterQueue()
4 {
5     return BindingBuilder.bind
6         (userRegisterQueue()).to(userExchange
7         ()).with(USER_REGISTER_ROUTING_KEY);
8 }
```

- 消息持久化策略：所有队列和交换机都配置为持久化（durable=true），服务重启后不丢失。队列配置为非排他、非自动删除，保证多实例消费可用。消息默认使用持久化投递模式，写入磁盘。
- 消息确认机制：使用RabbitTemplate发送消息，默认开启生产者确认和消费者手动确认扩展能力。当前使用@RabbitListener注解消费消息，框架自动处理确认，后续可扩展为手动确认模式，增加可靠性。使用Jackson2JsonMessageConverter进行JSON序列化，支持对象消息传输。

为什么不采用别的方式

- 不采用FanoutExchange扇形交换机，因为不需要广播到所有队列，TopicExchange更灵活；
- 不采用DirectExchange直连交换机，因为TopicExchange支持通配符匹配，扩展性更好；
- 不采用非持久化队列，因为会导致消息丢失，可靠性不足；不使用JDK序列化，因为JSON更通用、跨语言支持更好。

二、消息消费者设计

解决了什么问题

解决了异步文件处理问题，文件上传下载等耗时操作异步执行；解决了文档索引更新问题，文件变更后异步更新搜索索引；解决了用户通知推送问题，注册、密码重置等场景异步发送通知；解决了日志记录问题，网关日志、操作日志异步处理不影响主流程。

为什么这么设计

使用@RabbitListener注解声明消费者，简洁易用；每个队列对应独立的处理方法，职责清晰；消息消费异常只记录日志，不影响主流程；支持多实例并发消费，提高处理能力；异步解耦，主流程快速返回，提升用户体验。

具体怎么设计的

- 异步文件处理：文件服务监听文件上传、下载、处理、删除队列。上传完成后发送消息，异步处理文件元数据统计、热度计算等；下载完成后发送消息，异步记录下载日志、更新下载次数；文件处理队列支持格式转换、OCR识别等异步任务；删除操作发送消息，异步清理关联索引和缓存。

```
1 // 消息消费者示例
2 @RabbitListener(queues = RabbitMQConfig.
3                 FILE_UPLOAD_QUEUE)
4 public void handleFileUploadMessage
5 (Map<String, Object> message) {
6     // 处理文件上传后的异步任务
7 }
```

- 文档索引更新：预留文档索引更新扩展点，文件内容变更后发送消息，异步更新ES或向量数据库索引，保证搜索实时性。
- 用户通知推送：用户服务监听用户注册、密码重置队列。注册成功后发送消息，异步发送欢迎邮件；密码重置发送消息，异步发送重置链接邮件；操作日志队列异步记录用户操作行为，用于审计和数据分析。
- 网关日志告警：网关服务监听日志和告警队列，记录所有请求日志，异常情况发送告警，异步处理不影响网关性能。

为什么不采用别的方式

- 不使用同步处理，因为会阻塞主流程，影响响应时间；
- 不使用多线程池代替MQ，因为无法持久化、无法削峰、可靠性差；
- 不使用Kafka，因为RabbitMQ更适合业务消息场景，功能更丰富，延迟更低；
- 不直接调用其他服务接口，因为耦合度高，一个服务故障会影响另一个服务。

三、消息可靠性设计

解决了什么问题

解决了消息丢失问题，异常消息不丢弃；解决了消息重试问题，临时故障自动重试；解决了消息重复消费问题，保证幂等性。

为什么这么设计

预留死信队列扩展点，当前先保证基础功能可用；预留消息重试机制，使用Spring Retry或手动重试；预留幂等性保障，使用消息ID或业务唯一键；架构设计上考虑了可靠性，后续可逐步完善。

具体怎么设计的

- 死信队列配置：预留死信队列（DLQ）扩展设计，当消息消费失败、过期、队列满时，将消息转发到死信交换机，通过死信队列统一处理异常消息，定期人工介入或自动分析，保证消息不丢失。
- 消息重试机制：预留消息重试配置，使用Spring的重试机制，设置最大重试次数和重试间隔，指数退避策略，避免频繁重试压垮服务。重试超过最大次数后，消息进入死信队列。
- 消息幂等性保障：预留幂等性设计，使用消息唯一ID或业务主键（如fileId、userId），消费前检查是否已处理，使用Redis记录已消费的消息ID，或数据库唯一索引防止重复处理。

为什么不采用别的方式

- 不直接丢弃失败消息，因为会导致数据不一致；
- 不使用无限重试，因为会造成资源浪费和死循环；
- 不依赖MQ的去重，因为MQ只保证至少一次投递，需要业务层实现幂等；
- 不一开始就实现所有可靠性机制，因为当前阶段先保证核心流程可用，后续根据需要逐步完善。

总结

RabbitMQ设计采用每个服务独立的TopicExchange交换机，队列和交换机持久化，JSON序列化消息。使用@RabbitListener注解消费消息，实现异步文件处理、用户通知、日志记录等功能。预留了死信队列、重试机制、幂等性保障等可靠性扩展点，当前已实现基础的消息发送和消费功能，后续根据需要逐步完善可靠性机制。

08数据库与缓存设计

8.1 MySQL设计

- 用户表、文件表、文档表结构
- 索引优化策略
- 事务与锁机制

8.2 Redis设计

- 缓存策略（会话、热点数据）
- 分布式锁实现
- 限流计数器

8.3 数据同步设计

- 缓存与数据库一致性
- 读写分离策略
- 数据备份方案

一、MySQL设计

解决了什么问题

解决了用户数据持久化问题，存储用户基本信息和登录凭证；解决了文件元数据管理问题，记录文件的位置、大小、类型等信息；解决了文档版本控制问题，支持文档历史版本回溯。

为什么这么设计

- 使用MyBatis-Plus简化开发，减少重复CRUD代码；
- 主键策略多样化，用户表自增ID，文件和文档表UUID，满足不同场景；
- 文档内容与元数据分离，内容存MinIO，元数据存MySQL，避免数据库膨胀；
- 软删除设计，数据可恢复，便于审计；JSON字段存储标签和关键词，灵活扩展。

具体怎么设计的

- 用户表、文件表、文档表结构：用户表包含id、username、password、email、phone、role、status、createTime、updateTime，使用自增主键。文件元数据表包含id、fileId、fileName、filePath、fileType、fileSize、md5、storageType等，UUID主键。文档表包含id、title、content、summary、keywords、fileId、userId、status、version、category、tags等，UUID主键，关联document_version版本表，每个文档变更都保存版本记录。
- 索引优化策略：用户表在username和email字段建立唯一索引，status字段普通索引，支持快速登录和状态查询。文件表在fileId、createBy、status字段建立索引，支持按用户和状态查询。文档表在userId、status、category字段建立索引，支持用户文档列表、分类筛选、状态查询。当前预留索引设计，后续可根据查询模式优化。
- 事务与锁机制：使用@Transactional注解管理事务，文档创建、更新、删除都开启事务，保证文档表和版本表操作的原子性。例如创建文档时，同时插入文档记录和版本记录，任一失败则整体回滚。使用数据库默认的行锁机制，保证并发安全。

```
1  // 事务使用示例
2  @Override
3  @Transactional
4  public DocumentVO create
5  (DocumentCreateDTO dto, Long userId) {
6      // 多个数据库操作，原子执行
7      documentMapper.insert(document);
8      saveVersion(document, "初始版本",
9                  content);
10 }
11
```

为什么不采用别的方式

- 不使用MyBatis而用MyBatis-Plus，因为MyBatis-Plus提供通用Mapper，开发效率更高；
- 不使用纯UUID做主键，用户表自增ID更简单，文件表UUID避免暴露文件数量；
- 不直接存储内容在数据库，因为大内容会导致数据库膨胀，备份恢复慢；
- 不使用物理删除，因为软删除可恢复，符合企业应用需求；不使用多表关联存储标签，JSON字段更灵活，查询更简单。

二、Redis设计

解决了什么问题

解决了热点数据缓存问题，减少数据库压力；解决了分布式锁问题，微服务环境下并发控制；解决了分布式限流问题，防止系统过载。

为什么这么设计

- 使用Spring Data Redis，与Spring生态无缝集成；
- JSON序列化配置，支持复杂对象存储，避免乱码；
- 连接池配置，提升性能和稳定性；
- 不同服务使用不同数据库（user用0，file用1），数据隔离；
- 预留缓存和分布式锁扩展设计，架构上支持，后续可逐步实现。

具体怎么设计的

- 缓存策略：配置RedisTemplate使用Jackson2JsonRedisSerializer序列化，key使用String序列化，value使用JSON序列化，支持对象存储。预留热点数据缓存设计，用户信息、热门文档、文件元数据可缓存。当前框架已集成@EnableCaching，后续可使用@Cacheable、@CacheEvict、@CachePut注解实现缓存管理。不同服务使用不同database隔离数据。
- 分布式锁实现：预留分布式锁扩展设计，可使用Redis的SETNX命令或Redisson框架实现，用于文件上传、文档更新等并发场景，防止重复操作。
- 限流计数器：网关配置文件中已预留rate-limit配置，可使用Redis计数器实现分布式限流，支持固定窗口或滑动窗口算法，按用户或接口限流。

```
1  // Redis配置示例
2  @Bean
3  public RedisTemplate<String, Object>
4  redisTemplate(RedisConnectionFactory
5  connectionFactory) {
6      // key使用String序列化，value使用JSON序
7      列化
8      template.setKeySerializer
9      (stringRedisSerializer);
10     template.setValueSerializer
11     (jackson2JsonRedisSerializer);
12 }
```

- 不使用本地缓存，因为微服务多实例环境下本地缓存不一致；不使用Memcached，因为Redis数据

类型更丰富，支持持久化，功能更强大；不使用JDK序列化，因为JSON更通用，跨语言支持，可读性好；不在缓存中存所有数据，只缓存热点数据，控制内存成本。

三、数据同步设计（这一部分在五月左右会把预留接口实现，因为这部分是经典八股题，优先级没有架构设计和ai高，所以暂时还没完善，面试回答可参照下面来答）

解决了什么问题

解决了缓存与数据库一致性问题，防止缓存与数据库数据不一致；解决了读写分离问题，提升数据库查询性能；解决了数据备份问题，防止数据丢失。

为什么这么设计

- 预留缓存更新策略，架构支持，后续可选择延迟双删或binlog同步；
- 预留读写分离扩展，当前单库够用，可平滑过渡；
- 预留备份方案，当前设计考虑了可靠性。

具体怎么设计的

- 缓存与数据库一致性：预留一致性方案设计，可选择先更新数据库再删除缓存的延迟双删策略，或使用阿里Canal通过binlog同步更新缓存。当前代码框架已支持，后续可根据场景实现。文档内容存储在MinIO，元数据在MySQL，通过fileId关联，保证数据一致性。
- 读写分离策略：预留读写分离扩展，当前使用单库，后续可配置主从复制，读操作走从库，写操作走主库，提升查询性能。MyBatis-Plus支持通过注解或动态数据源实现读写分离。
- 数据备份方案：预留备份方案设计，MySQL可使用定时全量备份+binlog增量备份，Redis可使用RDB+AOF持久化，MinIO可使用跨区域复制或定期备份。当前设计考虑了数据安全，后续可实施。

为什么不采用别的方式

- 不采用缓存更新后删数据库，因为会导致数据不一致；
- 不强制读写分离，因为当前阶段数据量不大，单库够用，过早优化增加复杂度；
- 不仅依赖MySQL主从备份，因为需要结合其他备份方式，保证数据安全。

总结

数据存储设计使用MySQL存储结构化数据，Redis做缓存和分布式协调，MinIO存文件内容。MyBatis-Plus简化开发，文档与版本表保证可追溯，软删除保证数据安全。Redis配置了JSON序列化，预留了缓存、分布式锁、限流扩展点。当前已实现基础数据存储功能，后续可逐步完善缓存策略、分布式锁、限流、读写分离等高级特性。


09容器化与部署设计

9.1 Docker镜像设计

- 多阶段构建优化
- 基础镜像选择
- 环境变量配置

9.2 Docker Swarm设计

- 服务副本配置
- 节点约束调度
- 网络与存储配置



一、Docker镜像设计

解决了什么问题

解决了应用环境一致性问题, 不同环境运行相同代码, 避免"在我机器上能跑"问题; 解决了微服务部署复杂度问题, 简化部署流程; 解决了镜像大小问题, 提升部署效率。

为什么这么设计

采用私有DK17基础镜像，国内访问速度快；设置亚洲/上海时区，符合国内业务需求；COPY先打包好的JAR包直接运行，流程简单；使用华为云SWR镜像仓库托管镜像，方便部署；每个服务独立镜像，独立部署升级。

具体怎么设计的

- 多阶段构建优化：当前使用简单构建模式，先在外使用Maven打包JAR包，再将JAR包COPY到镜像中。预留多阶段构建扩展，第一阶段使用Maven镜像构建JAR，第二阶段使用JRE镜像运行，可进一步减小镜像体积。
- 基础镜像选择：使用私有JDK17镜像（swr.cn-north-4.myhuaweicloud.com/***/jdk-17:latest），国内访问快，已预装JDK17运行环境。设置时区为Asia/Shanghai，避免时区问题导致日志时间不准确。
- 环境变量配置：在Dockerfile中通过CMD参数传递JVM参数（如user-service禁用MyBatis-Plus的ddl-auto参数），在docker-compose中通过environment配置Spring相关环境变量，如数据库连接、Nacos地址、Redis配置等，外部配置，无需重新构建镜像即可适配不同环境。

Dockerfile

```
1  # Dockerfile示例
2  FROM swr.cn-north-4.myhuaweicloud.com/***/jdk-17:latest
3  RUN ln -sf /usr/share/zoneinfo/Asia/
4  Shanghai /etc/localtime && echo "Asia/
5  Shanghai" > /etc/timezone
6  COPY target/user-service-1.0.0.jar /app/
7  user-service.jar
8  WORKDIR /app
9  EXPOSE 8081
10 CMD ["java", "-Dmybatis-plus.
11 global-config.db-config.ddl-auto=none",
12 "-jar", "user-service.jar"]
```

YAML

```
1  # 环境变量配置示例
2  environment:
3    SPRING_APPLICATION_NAME: user
4    SPRING_CLOUD_NACOS_DISCOVERY_SERVER-ADDR
5    : nacos:8848
6    SPRING_DATASOURCE_URL: jdbc:mysql://
7    mysql:3306/doc_ai
```

为什么不采用别的方式

- 不采用多阶段构建在Dockerfile内直接构建，因为当前项目已有外部Maven构建流程已够用，简化Dockerfile更简单；
- 不采用Alpine Linux基础镜像，因为JDK17的Alpine镜像可能兼容性问题，华为云镜像已够用；
- 不使用.env文件管理环境变量，直接在docker-compose中配置更直观，管理方便，清晰；
- 不使用Docker Secrets管理密码，当前为简化部署，后续可升级。

二、Docker Swarm设计

解决了什么问题

解决了服务高可用问题，服务多副本，单节点故障不影响；解决了容器编排问题，统一管理多个服务；解决了服务发现和网络隔离问题；解决了数据持久化问题；解决了监控问题。

为什么这么设计

- 采用Docker Swarm作为编排，轻量级，适合中小规模，学习成本比K8s低；
- 服务分拆基础设施服务（docker-compose-infra.yml基础设施、服务（docker-compose-services.yml）、监控（docker-compose-monitoring.yml），独立部署，独立管理；
- 节点约束调度，MySQL、Nacos等有状态服务固定节点；数据卷持久化，数据不丢；外部网络docai-network，服务互通隔离。

具体怎么设计的

- 服务副本配置：基础设施服务MySQL、RabbitMQ、MinIO、Nacos副本数1，有状态服务单副本避免数据致性问题；Redis副本数2，max_replicas_per_node:1，每节点1个；微服务默认1个副本，user服务在gate-user.yml中配置2个副本；node.role == worker约束在worker节点；监控服务Prometheus、Grafana单副本，node-exporter和cadvisor用global模式，每个节点部署。
- 节点约束调度：用placement.constraints配置服务节点调度，MySQL、网关、Prometheus、Grafana约束node.hostname == manager；RabbitMQ、MinIO、user、document约束node.hostname == node1；file、ai约束node.hostname == node2；Nacos约束node.hostname == node3；user服务gate-user.yml配置node.role == worker；有状态服务固定节点，无状态服务灵活调度。

- 网络与存储配置：外部网络docai-network服务间互通，隔离外部网络，跨stack网络，服务发现使用同一网络，服务名互访，如user服务访问mysql:3306；使用命名卷持久化mysql-data、redis-data、minio-data、nacos-data等，数据容器删除数据不丢；重启策略on-failure，服务故障时自动重启。

```
1  #服务配置示例
2  deploy:
3    mode: replicated
4    replicas: 2
5    placement:
6      constraints: [node.hostname == node1]
7      max_replicas_per_node: 1
8    restart_policy:
9      condition: on-failure
10 networks:
11   docai-network:
12     external: true
13 volumes:
14   mysql-data:
```

- 不采用Kubernetes，K8s过于复杂，Docker Swarm轻量级，学习成本低，够用；不采用单机Docker Compose，Swarm支持高可用；不采用主机网络模式，外部网络隔离性更好；不用本地挂载存储，命名卷更安全；不共享所有服务单副本，Redis用两个副本提高可用性，有状态服务单副本避免数据同步复杂；不同节点分布合理。

总结

Docker设计采用私有JDK17基础镜像，时区配置，外部Maven构建JAR直接COPY运行，docker-compose配置环境变量；Swarm部署，节点约束调度，分拆基础设施服务，监控服务，外部网络互通，命名卷持久化数据，重启策略故障自动恢复。当前部署简单实用，后续可优化多阶段构建、Docker Secrets等。

10 监控与Alops运维设计

10.1 日志管理设计

- 日志分级与输出
- 日志收集与分析
- 异常日志告警


10.2 指标监控设计

- Prometheus指标暴露
- Grafana可视化面板
- 自定义监控指标

10.3 健康检查设计

- 服务健康端点
- 容器健康检查
- 自动重启策略

10.4 Alops智能运维监控



一、日志管理设计

解决了什么问题

解决了系统运行状态追踪问题，通过日志记录系统行为和错误；解决了问题定位和调试问题，通过日志查找故障原因；解决了审计问题，记录用户操作和系统事件；解决了告警问题，异常日志及时通知运维人员。

为什么这么设计

- 采用SLF4J + Logback日志框架，Spring Boot默认组件，使用方便；
- 日志分级，debug调试日志，info关键信息，warn警告，error错误；
- 使用@Slf4j注解，Lombok自动注入，减少代码；
- 网关和服务都统一配置日志，统一格式；通过RabbitMQ异步发送日志和告警，不影响主流程性能。

具体怎么设计的

- 日志分级与输出：使用标准的SLF4J日志级别，trace最低，debug调试，info重要流程，warn警告，error错误；通过配置文件设置不同包的日志级别，业务包设为debug，Spring框架设为info；日志输出到控制台，通过Docker日志收集；GatewayConfig中开启gateway.health；应用yaml配置logging.level；使用Lombok的@Slf4j注解，代码里用log.info、log.debug、log.error等。
- 日志收集与分析：网关和服务都集成RabbitMQ，发送网关日志和告警；网关AuthGlobalFilter中记录请求信息，发送到gateway-log队列；用户和文件服务Listener接收处理消息；监控docker-compose中部署node-exporter和cadvisor，监控节点和容器；Prometheus配置中已有scrape_configs，采集指标；预留ELK或Loki日志收集扩展，当前通过Prometheus + Grafana监控，日志可以通过Docker日志驱动收集。
- 异常日志告警：网关日志记录中，发现未授权、无效令牌等异常，发送gateway-alert告警；AIOps的FaultDetector定时检测故障，通过InternalService.sendAlert发送告警；FaultDetector用@Scheduled每分钟执行一次，检测AI请求响应超时、错误率过高；故障创建时自动触发sendAlert，记录故障类型、消息、时间戳；告警发送异步，不影响主流程。

为什么不采用别的方式

不采用Log4j2，因为Spring Boot默认Logback已够用，无需额外切换；

不直接发送邮件告警，通过MQ异步发送，解耦更灵活；

不采集所有日志存数据库，性能影响大，日志量太大；

不强制所有服务统一日志配置，各服务可独立调整级别，主框架统一即可；

不使用复杂的日志平台，当前Prometheus + Grafana已够用，后续可加ELK。

二、指标监控设计

解决了什么问题

解决了系统性能监控问题，实时观测CPU、内存、请求量；解决了业务指标监控问题，如AI请求次数、错误率、响应时间；解决了可视化问题，直观展示监控数据；解决了预警问题，指标异常可及时发现。

为什么这么设计

- Prometheus + Grafana是云原生主流监控方案，成熟稳定；
- Prometheus pull模式采集指标，服务端主动拉取，客户端轻量；
- Grafana图表丰富，可视化友好；自定义AIOps监控服务，扩展业务指标；
- 网关集成Redis预留rate-limit，可做限流统计；预留扩展，后续可加Spring Boot Actuator和Micrometer。

具体怎么设计的

- Prometheus指标暴露：已部署Prometheus和Grafana到Docker Swarm；prometheus.yml配置scrape_configs，采集prometheus自身、node-exporter（监控节点）、cadvisor（监控容器）、docai-services（微服务）、docai-infra（基础设施）；使用DNS服务发现，tasks.service-name自动发现Swarm服务；网关配置spring.cloud.gateway.health.enabled=true，健康检查；预留集成Actuator和Micrometer，后续可暴露/actuator/prometheus端点。
- Grafana可视化面板：已部署Grafana服务，默认管理员密码admin/admin123；Grafana可以配置Prometheus为数据源，创建自定义面板；docker-compose-monitoring.yml配置Prometheus数据卷和Grafana数据卷，持久化配置和数据；Prometheus配置文件已关联卷prometheus-config，后续可定义告警规则。
- 自定义监控指标：AIOps的MonitoringService提供自定义指标；ConcurrentHashMap存储counters计数器和timers计时器；incrementCounter()计数，recordTimer()记录耗时；getTimerStats()计算统计信息，min、max、avg；Redis定时saveMetrics()存指标数据，过期24小时；/api/ai/aiops/monitor接口获取所有指标，/health健康检查，/metrics/counter

和/metrics/timer接口手动记录指标；监控AI响应时间（ai.request）、错误数（ai.errors）、总请求数（ai.requests）等。

为什么不采用别的方式

- 不采用Zabbix，更适合传统服务器监控，云原生不如Prometheus；
- 不采用InfluxDB，Prometheus生态更好，与Grafana集成更顺；
- 不强制所有服务都暴露Prometheus端点，当前AIOps已覆盖，后续可逐步完善；
- 不使用复杂的APM工具如Skywalking，当前够用，后续可加；不用Pushgateway，微服务直接暴露pull更简单。

三、健康检查设计

解决了什么问题

解决了服务可用性检测问题，判断服务是否正常运行；解决了容器健康监控问题，Docker Swarm可根据健康检查决定是否重启；解决了依赖服务检测问题，如数据库、Redis是否连接正常；解决了自动恢复问题，服务故障自动重启恢复。

为什么这么设计

- 网关开启health.enabled=true，Spring Gateway健康检查；
- Docker Swarm restart_policy配置自动重启；
- AIOps自定义healthCheck接口，集成自定义指标；
- 预留扩展，后续可加Spring Boot Actuator health端点；架构上清晰，基础设施和服务都可监控。

具体怎么设计的

- 服务健康端点：AIOpsController提供/api/ai/aiops/health接口，返回status UP、timestamp、metrics；网关配置spring.cloud.gateway.health.enabled=true；预留添加Spring Boot Actuator，暴露/actuator/health，/actuator/info等；健康检查返回自定义指标，结合业务状态。
- 容器健康检查：Docker Swarm部署服务时，可配置HEALTHCHECK（当前Dockerfile中未配置，是预留）；当前通过监控容器状态和Swarm restart_policy间接实现；node-exporter和cadvisor监控容器和节点资源状态；Grafana可以可视化容器指标。
- 自动重启策略：docker-compose配置restart_policy condition on-failure，服务失败时自动重

启；部署replicas副本，多实例提高可用性；failover通过Swarm调度器自动实现；MySQL、RabbitMQ、MinIO等有状态服务单副本固定节点部署，无状态服务可多副本灵活调度；FaultDetector检测故障可配合自动恢复。

为什么不采用别的方式

- 不采用K8s的liveness/readiness，当前Swarm已够用；
- 不强制配置复杂的依赖健康检查，当前先保证基础健康；
- 不配置太频繁的健康检查，避免给服务造成压力；
- 不手动重启服务，Swarm自动重启更可靠。

四、Alops智能运维监控

解决了什么问题

解决了故障自动检测问题，无需人工24小时值守；解决了智能分析问题，自动发现性能下降、错误率高；解决了故障记录管理问题，追踪故障时间、次数、状态；解决了自动化处理问题，故障标记和处理流程。

为什么这么设计

- AIops作为单独模块，集成在AI服务中，统一管理；
- MonitoringService和FaultDetector各司其职，监控负责指标收集，检测器负责故障发现；
- 用Redis存储历史指标，ConcurrentHashMap内存存当前数据；
- 定时检测，@Scheduled每分钟执行，及时发现；REST API暴露运维接口，可手动触发检测和处理。

具体怎么设计的

- 监控数据收集：MonitoringService收集自定义指标，支持计数器和计时器；incrementCounter计数API调用、错误数；recordTimer记录耗时，如AI请求响应时间；getAllMetrics获取所有指标；saveMetrics定时存Redis，过期24小时；内存ConcurrentHashMap，高并发安全；getTimerStats返回min/max/avg/count统计值。
- 故障自动检测：FaultDetector自动检测故障，定时@Scheduled(fixedRate 60000)每分钟执行；detectPerformanceIssues检测AI平均响应时间>5秒；detectThresholdBreaches检测错误率

>10%；createFault创建故障记录，记录首次和末次时间、计数、状态；sendAlert发送告警，通过InternalService；检测结果返回故障列表，包括ID、类型、消息、时间戳。

- 故障处理流程：故障记录status为detected；resolveFault接口标记为resolved；getAllFaults查看所有故障，支持状态筛选；故障记录持久化在内存，后续可存数据库；故障处理可集成告警通知和自动修复。
- 运维REST接口：AIOpsController提供完整运维API；GET /monitor获取指标，GET /health健康检查，POST /metrics/reset重置指标；GET /detect手动触发检测，GET /faults查看所有故障，POST /faults/{faultId}/resolve处理故障；POST /metrics/counter和timer手动记录指标；Swagger API文档，方便调用。

为什么不采用别的方式

- 不采用复杂的机器学习故障预测，当前规则检测已够用，简化实现；
- 不集成太多外部告警系统，通过MQ内部告警，后续可扩展；不把AIOps放在单独服务，放AI服务一起，减少部署复杂度；
- 不一开始就做自动修复，先做检测和告警，后续逐步加。

总结

监控运维设计采用Prometheus + Grafana主流方案，自定义AIOps模块实现指标监控和故障检测，日志通过SLF4J + MQ收集告警，健康检查预留Actuator扩展，Swarm自动重启策略保证可用性。当前架构清晰，扩展性好，后续可完善Actuator集成、ELK日志平台、Dockerfile HEALTHCHECK、自动修复等功能。

字节一面

1. 为什么文档上传、AI 任务调度要用 RabbitMQ 异步解耦？同步会有什么问题？
2. 讲讲 Spring AI 在你 DocAI 项目里的核心作用是什么？
3. 什么是 AI Skills 组件？你在项目里是怎么封装和设计的？
4. 你基于 Spring AI 封装了哪些文档 AI 能力：摘要、纠错、关键词提取，讲讲实现思路？
5. 怎么通过 Spring AI 统一调度底层大模型？做多模型兼容是怎么实现的？
6. 统一 AI 服务入口是怎么设计的？如何做到能力可插拔、易扩展？
7. AIOps 在 AI 服务里做了哪些异常管控和性能监控？监控哪些核心指标？
8. 讲讲你在 DocAI 里设计实现的企业级 RAG 知识库整体架构和完整流程？
9. 你基于 Spring AI + Redis + AI Skills 模块化封装了哪些 RAG 核心能力？

字节二面

项目相关问题

1. 在你的项目中，使用 RabbitMQ 主要解决了什么问题？
2. 你的 AI 文档处理平台中，服务可用性达99.95%，剩下的 0.05% 失败原因是什么？
3. 你在项目里微服务是怎么拆分的？依据是什么？
4. Spring Cloud Alibaba 用到了哪些组件？各自作用是什么？
5. 微服务之间调用方式用的什么？同步 RPC 还是异步 MQ？场景怎么区分？
6. 为什么文档上传、AI 任务调度要用 RabbitMQ 异步解耦？同步会有什么问题？

场景题

1. 如果微服务中一个核心模块宕机了，有什么缓解方式？
2. 如果某个特定请求因代码缺陷导致所有实例依次宕机，如何避免这种情况？
3. 除了限流，常态下如何避免一个用户打挂所有实例？

字节三面

1. 介绍一下你的MinIO的纠删码机制。
2. MinIO的集群是怎么做的扩容？
3. 整个 DocAI 平台你做过哪些性能优化？SQL、缓存、异步、AI 接口分别说下？
4. Docker、Docker Swarm 在项目里怎么实现微服务编排、集群部署、高可用？
5. 容器化部署后，配置管理、服务发现、日志监控怎么落地？
6. 你主导设计多范式 AI Agent 体系，说说整体设计思路和难点在哪？
7. RAG 知识库增量同步是怎么设计的？怎么避免全量重新向量化？
8. 封装 AI Skills 能力时，怎么做到解耦、可扩展、后续新增 AI 能力不用改核心流程？
9. 项目里遇到的最大技术难点是什么？怎么排查、怎么解决的？
10. 如果让你重构整个 DocAI 的 AI 服务和 RAG 架构，你会怎么优化？

腾讯CSIG 后台开发

1. 有没有做过 AI 相关的项目？用到了什么技术？
2. 用的什么 AI 模型？是本地部署的还是调用 API？
3. 如果文档内容太长，上下文窗口不够用，怎么处理？
4. AIOps 在你们的架构中具体承担什么职责？
5. RAG 系统中，向量生成使用的是哪种 Embedding 模型？向量检索采用什么算法（如 HNSW、IVF）？Redis 是如何支持向量存储和检索的（Redis Stack + VSS）？
6. 你说“Top-5 召回率 93%，回答准确率 82%”，这两个指标是如何定义和计算的？针对未召回或回答错误的 case，你们做了哪些优化？

淘天 AI应用开发

一、自我介绍与项目背景

1. 你做的“AI文档处理协作平台”是自己做的还是公司项目？
 2. 这个项目具体实现了哪些能力？
 3. 请挑一个技术点进行试讲（如RAG知识库、文档处理流程等）。
-

二、AI文档处理平台深入问题

1. 你提到的准确率是多少？提升了多少？如何评测的？
 2. 你用了什么模型做向量化（embedding）？有没有尝试其他模型？
 3. 如何评测“提取核心结论”这类任务的准确性？
 4. 为什么你说“skill”比“MCP”更准确？背后的原理是什么？
 5. Skill是否能替代MCP？你是怎么理解的？
-

三、React 框架与 AI 代理架构

1. 你对“React”框架（指AI中的ReAct模式）了解吗？请详细讲一下。
 2. ReAct 的优点是什么？
 3. 你对“Claude Code”泄露事件有了解吗？有什么看法？
-

四、记忆系统设计

1. 你了解AI中的记忆系统吗？如长时记忆和短时记忆？
 2. 你会如何设计长时记忆？上下文窗口限制怎么处理？你的项目中记忆系统是怎么设计的？
 3. 如果让你从设计到落地一个系统，你会考虑哪些关键指标？
-

五、系统上线与评估指标

1. 你会观察哪些指标来决定系统是否可以上线？
 2. 安全性如何保障？你听说过“安全护栏”（Guardrails）吗？
-

六、数据库与Java基础

1. MVCC是什么意思？它是如何实现的？
 2. MVCC会带来哪些挑战或开销？
 3. `synchronized` 关键字的作用和实现原理是什么？锁的升级过程？
 4. JVM 的类加载过程包括哪几步？
-

七、模型优化与微调

1. 你使用了哪些大模型？有没有对模型本身进行优化（如微调）？
 2. 微调在什么场景下会用到？你有没有做过？
-

八、前沿技术与开源项目

1. 你有没有关注哪些开源项目或前沿技术？比如GPT系列？
2. 你了解GPT的原理吗？它的训练方法叫什么？

项目的面试题

1、对接 外部AI API 时，有没有遇到过接口调用超时、限流的问题？怎么解决的？

有的，对接 AI API 时遇到了调用超时和平台限流两个核心问题，我结合项目场景做了针对性解决，保证 AI 功能的稳定性：

1. 解决接口调用超时：

- 给 AI API 调用设置超时时间（5s），并做重试机制（重试 3 次，指数退避），针对网络抖动的临时超时做自动重试；
- 用Spring Async将 AI API 调用改为异步处理，比如用户上传文档后，触发异步任务调用 AI API 做摘要，用户无需等待结果，系统通过 Redis 追踪任务进度，前端实时刷新，避免同步调用超时导致用户体验差。

2. 解决平台限流：

- 做本地限流：用 Sentinel 给 AI API 调用接口设置限流阈值（比如每秒 10 次），防止大量用户同时请求导致触发平台的限流规则；
- 做请求缓存：将 AI API 的返回结果（如文档摘要、关键词）存入 Redis，设置过期时间（1 小时），相同的文档请求直接返回缓存结果，减少重复的 API 调用，降低限流概率；
- 做降级处理：如果触发平台限流，立即返回降级提示“当前 AI 服务繁忙，请稍后再试”，并记录日志，避免服务阻塞。

2、AI 文档平台的文档版本控制和回滚是怎么设计的？

我采用「基础版本 + 增量更新」的设计方案，基于数据库 + 文件存储实现，兼顾版本管理的效率和存储空间，具体设计：

1. 数据库记录版本信息：创建文档版本表，记录每个版本的版本号、更新人、更新时间、更新描述、文档源 ID、文件存储路径，版本号采用自增方式（V1、V2、V3），方便用户识别和回滚。
2. 文件存储增量更新：首次创建文档时，存储完整的文件内容；后续更新文档时，只存储增量修改的内容（比如修改了某段文字，只存这段文字的前后对比和位置），而非存储完整的文件，大幅节省存储空间。
3. 回滚实现：用户发起回滚请求时，根据目标版本号，从版本表中查询对应的文件存储路径，将目标版本的文件内容恢复为当前文档的内容，同时生成新的版本号（比如从 V3 回滚到 V2，

生成 V4) , 保证版本记录的完整性。

- 兜底保障：针对重要文档，定期生成全量备份，存储在 MinIO 分布式文件系统中，即使增量数据丢失，也能通过全量备份恢复文档，保证数据安全。

3、高并发场景下，接口响应变慢，你怎么一步步排查问题？

我会按照从上层到底层、从应用到中间件的顺序逐步排查，定位问题根源，项目中多次用这个方法排查出问题，效率很高，具体步骤：

- 第一步：排查网关层（Gateway）：查看 Gateway 的日志，看是否有请求限流、路由转发失败、鉴权耗时过长的的问题；用监控工具看 Gateway 的 CPU、内存使用率，是否有资源瓶颈。
- 第二步：排查业务服务层：查看 SpringBoot 服务的日志，看是否有接口异常、线程阻塞、Feign 调用超时的的问题；用jstack分析线程栈，看是否有死锁、线程等待的情况；查看服务的线程池参数，是否有请求排队。
- 第三步：排查中间件层：
 - Redis：用redis-cli info查看 Redis 的运行状态，看是否有大 Key、慢查询、主从同步延迟的问题；
 - MQ：查看 RocketMQ 的消息堆积情况，看是否有消费失败、消费速度跟不上生产速度的问题；
 - 数据库：查看 MySQL 的慢查询日志，用show processlist看是否有锁等待、全表扫描的问题。
- 第四步：排查网络层：检查服务器之间的网络延迟、丢包率，看是否有网络抖动、带宽瓶颈的问题。
- 第五步：定位并解决：根据排查结果，针对性解决问题（比如加索引、优化缓存、调整线程池参数），解决后重新压测，验证接口响应速度是否恢复。

4、AI项目的功能与业务是怎么适配的？

Spring AI 结合 Prompt 工程的实现方式，以及不同文档的个性化适配

Prompt 工程与 Spring AI Prompt 模板的结合：

- 针对文档摘要、纠错、关键词提取三大核心功能，设计标准化的 Prompt 指令，明确输出格式、字数限制、核心要求；

2. 基于 Spring AI 的 PromptTemplate 实现模板化管理，通过占位符动态填充变量（如文档内容、摘要字数、关键词数量），示例：PromptTemplate.create("请提取以下文档的核心摘要，逻辑清晰且控制在{summaryLength}字内：{documentContent}");
3. 通过 PromptTemplate.create() 加载模板，调用 create(Map<String, Object> variables) 方法填充动态参数，生成最终可调用的 Prompt 对象，传递给 ChatClient。不同类型文档的个性化适配：
4. 先通过文件解析工具（iText 7/Poi）识别文档类型（PDF/Word/TXT）和篇幅，将解析结果作为 Prompt 的个性化参数；
5. 针对 PDF（多为正式专业文档）：在 Prompt 中增加“保留专业术语、按正式文档逻辑梳理”的指令；
6. 针对 Word（多为企业办公文档）：在 Prompt 中增加“侧重业务核心结论、简化冗余表述”的指令；
7. 针对长文档：在 Prompt 中增加“分段提取核心信息后聚合”的指令，适配后续的分段处理逻辑。

5、AI项目文档的处理顺序？

文档内容解析与传递核心逻辑：

1. 文件服务（file 模块）通过 iText 7（PDF）、Poi（Word）、字符流读取（TXT）将文档解析为纯文本内容，做基础的格式清洗（去除空行、特殊符号）；
2. 将清洗后的纯文本、文档 ID、处理类型（摘要 / 纠错）传入统一的 AI 服务层；
3. AI 服务层基于 PromptTemplate 填充纯文本内容，生成 Prompt 对象；
4. 调用 ChatClient.call(Prompt) 方法将请求发送给 AI 模型，获取原始响应结果。大篇幅文档的分段处理与结果聚合：
5. 分段规则：制定按字符数的拆分规则（5000 字符 / 段），对清洗后的纯文本做均匀拆分，记录每段的顺序编号；
6. 分段处理：对每一段文本单独生成 Prompt 并调用 AI 模型，生成分段处理结果，通过 Redis 记录每段的处理状态和结果；
7. 结果聚合：
 - 摘要：提取各段核心观点，按原文的段落顺序整合为完整摘要，做去重和逻辑梳理；
 - 纠错：汇总各段的错误标注、修正方案，按原文的位置顺序排序，生成完整的纠错报告；
 - 关键词：合并各段提取的关键词，按出现频次和重要性做去重排序，最终保留 5-15 个核

心关键词；

8. 整个分段 + 聚合过程通过 RabbitMQ 异步执行，保证系统响应效率。

6、AI项目是如何通过RabbitMQ去实现AI文档异步处理的架构？

采用“生产端提交任务→消息队列缓冲→消费端模型处理→结果队列回传→业务端更新”的链路设计：

1. 生产端：file/document 模块接收 AI 处理请求，生成唯一任务 ID，将任务 ID、文档 ID、处理类型、清洗后的纯文本发送到 RabbitMQ 的ai_process_queue，同时在 Redis 中初始化任务状态为“待处理”；
2. 消费端：AI 服务模块作为专属消费者，监听ai_process_queue，获取消息后调用 Spring AI 的模型处理逻辑；
3. 结果端：AI 处理完成后，将结果 + 任务 ID + 文档 ID 发送到 RabbitMQ 的 ai_result_queue，由 document 模块消费；
4. 监控层：通过 Redis 实时记录任务状态、处理进度，支持前端轮询查询。Spring AI 模型调用嵌入消费链路：消费者接收到消息后，先做任务状态校验，再通过工厂类获取具体的 AI 策略实现，调用封装好的 AI 服务方法，完成Prompt构建→ChatClient调用→原始响应解析的全流程，处理过程中实时更新 Redis 的任务进度（如“处理中：30%”）。幂等性保障：
5. 基于唯一任务 ID做全局幂等，消费前检查 Redis 中任务状态，若为“处理中 / 已完成”则直接 ACK，不重复处理；
6. 为 RabbitMQ 消息设置唯一MessageId，开启手动 ACK 机制，消费失败则有限重入队（最大 3 次）；
7. 数据库建立ai_process_task表，以任务 ID 为唯一索引，防止重复插入处理记录。结果准确回传保障：
8. 处理结果持久化到ai_process_result表，携带任务 ID、文档 ID 做关联，保证数据可追溯；
9. document 模块消费ai_result_queue时，通过文档 ID 关联更新主文档表的 AI 处理字段，更新失败则触发本地重试；
10. 设计定时补偿任务，扫描 Redis 中“处理完成但未回传”的任务，重新触发结果更新，保证最终一致性。

7、AI项目的异常处理？

项目中常见的异常类型：网络异常导致的接口调用失败、模型请求超时、云端平台限流 / 接口返回异常、本地模型服务不可用、模型响应结果格式不规范导致的解析失败。异常兜底机制：

1. 定义统一的 AI 异常处理器（@RestControllerAdvice + @ExceptionHandler），专门捕获 Spring AI 的 ModelCallException、TimeoutException 等专属异常，以及网络、解析等通用异常；
2. 实现主备模型自动切换：若主模型（如 ChatGLM-6B）调用失败，自动切换为备用模型（讯飞星火），保证业务核心功能可用；
3. 对结果格式解析异常，做兜底处理：返回默认提示信息，同时记录原始响应日志，便于后续排查；
4. 模型服务完全不可用时，将任务标记为“失败”并返回友好提示，同时将任务加入死信队列，待服务恢复后处理。重试机制：
5. 本地重试：基于 Spring Retry 实现，对网络失败、超时异常设置 3 次重试，采用指数退避策略（间隔 1s/2s/4s），避免短时间重复请求加剧服务压力；
6. 消息队列重试：RabbitMQ 消费者开启手动 ACK，消费失败则重入队，设置最大重试次数 5 次，超过则进入死信队列；
7. 定时补偿重试：设计定时任务，每天凌晨扫描数据库中“失败 / 待处理”的任务，重新触发模型调用，保证任务最终完成；
8. 云端限流重试：针对讯飞星火平台的限流异常，在 Redis 中记录调用频次，避开限流高峰后通过定时任务重试。

8、说一下你AI项目的微服务架构？

独立 AI 服务模块（ai-service）设计：将 Spring AI 相关的所有逻辑封装为独立微服务，注册到 Nacos 服务注册中心，作为系统的 AI 能力中台，仅对外暴露标准化的 RESTful 接口，内部实现模型对接、异常处理、性能优化等细节，做到高内聚、低耦合。与其他模块的通信交互：

1. file 模块：文档解析完成后，调用 ai-service 的任务提交接口，传递任务 ID、文档 ID、处理类型、纯文本内容；
2. document 模块：通过 ai-service 的结果查询接口获取 AI 处理结果，通过任务状态接口查询处理进度；
3. 所有服务间数据交互采用 JSON 格式，传输数据做严格的非空、长度校验，同时添加 Token 做服务间鉴权；
4. 通信层面设置超时时间（3s）和重试机制（2 次），保证服务间调用的稳定性。OpenFeign

的具体使用：

5. 在 file、document 模块引入spring-cloud-starter-openfeign依赖，通过@EnableFeignClients开启 Feign 功能；
6. 定义通用的 Feign 客户端接口AiServiceFeignClient，通过@FeignClient(value = "ai-service")绑定目标服务，声明任务提交、结果查询等接口方法，与 ai-service 的 RESTful 接口一一对应；
7. 配置 Feign 拦截器，为所有请求添加服务鉴权 Token、服务标识等请求头；
8. 配置 Feign 的日志级别为 DEBUG，便于排查服务间调用的问题；
9. 结合 Sentinel 为 Feign 客户端做熔断降级，当 ai-service 不可用时，返回默认的降级结果，保证调用方服务的可用性。

9、MinIO的大文件上传分片设置？

针对百兆级 PDF/Word，基于 MinIO 官方 Java SDK 实现前端分片 + 后端合并的分片上传，核心步骤和配置：

1. 前端分片：前端将大文件按5MB / 片拆分，生成唯一的上传 ID，按顺序上传分片，同时记录分片索引；
2. 后端配置：MinIO 开启分片上传支持，设置分片最小大小为 5MB，最大分片数 1000，适配超大文件；
3. 分片上传：后端接收前端的分片，通过 MinIO SDK 的putObjectPart方法，将分片上传至 MinIO，关联上传 ID 和分片索引，返回分片上传成功标识；
4. 分片合并：所有分片上传完成后，前端发起合并请求，后端通过 MinIO SDK 的completeMultipartUpload方法，根据上传 ID 合并所有分片，生成完整文件；
5. 兜底处理：设置分片上传过期时间（24 小时），未完成合并的分片自动清理；同时记录分片上传进度到 Redis，支持断点续传。

10、MinIO 存储的文档，怎么做访问权限控制？防止未授权访问？

做了MinIO 桶策略 + 业务层权限双重控制，保证只有授权用户能访问文档：

1. MinIO 桶策略：创建专属的文档存储桶，关闭公共访问权限，只允许项目微服务的访问账号通过 SDK 访问，禁止外网直接访问 MinIO 桶；
2. 业务层权限控制：① 给每个文档绑定用户 / 部门权限，数据库记录文档所有者、协作人列

表；② 用户请求下载 / 查看文档时，先通过用户服务校验权限，只有权限匹配的用户，后端才会通过 MinIO SDK 生成临时访问链接（有效期 10 分钟），前端通过临时链接访问文件，避免链接泄露导致未授权访问。

11、vibe coding开发这个项目的流程？

1. 需求分析与架构设计（人主导）

我首先明确业务需求，设计系统的整体架构、模块划分和技术选型。例如，我决定将平台拆分为 gateway、file、ai、document、user 五个微服务，选用 Spring Cloud Alibaba 作为基础框架。这个阶段 AI 无法替代，需要人的全局把控。

2. 提示词编写与代码生成（AI 辅助）

将具体功能拆解成细粒度的任务，为 AI 编写清晰的提示词。比如实现文件分片上传接口，我会描述接口参数、业务逻辑、异常处理等，让 AI 生成 Controller、Service 和工具类的骨架代码。生成后我会立即审查，确保符合设计规范。

3. 调试与集成（人主导）

AI 生成的代码可能含有小 bug 或与现有模块不兼容。我会运行单元测试，发现问题后要么手动修复，要么将错误信息反馈给 AI，让它提供修正建议。这一步保证了代码的可用性和集成质量。

4. 测试与优化（人机协作）

利用 JUnit 和压测工具验证功能与性能。对于 AI 生成的复杂逻辑（如异步消息处理），我会让 AI 补充单元测试用例，并基于测试结果建议优化点，比如缓存策略或线程池配置。最终由我决策是否采纳。

5. 持续迭代（循环）

整个开发过程是快速循环的：完成一个功能后，立即运行、测试，收集反馈，然后进入下一个功能或优化。vibe coding 强调“快速反馈、及时调整”，就像在节奏中不断前进。

12、Spring AI 在项目中具体怎么用的？与传统直接调用 AI API 相比有什么优势？

回答思路：PromptTemplate 管理 + 统一接口 + 模板化 + 易于切换模型

参考话术：

“我们用 Spring AI 封装了对 AI 模型的调用。传统直接调用 API 需要在代码里拼接 Prompt，维护成本高。Spring AI 提供了 **PromptTemplate**，可以把 Prompt 抽象成模板，通过占位符动态注入参数，代码更简洁。另外，它抽象了 ChatClient 接口，未来如果要切换模型（比如从 OpenAI 换成国产模型），只需要改配置，业务代码几乎不用动。”

13、如果 AI 返回的结果不符合预期，你们怎么处理？

回答思路：校验 + 重试 + 降级 + 日志分析

参考话术：

“我们会先对 AI 输出做基本校验，比如摘要是否为空、格式是否符合要求。如果不符合，会触发重试机制（最多 3 次）。如果重试仍失败，就走降级逻辑，比如返回一个默认提示，或者记录错误日志后人工介入。另外，我们会定期分析不符合预期的 case，优化 Prompt 或调整模型参数。”

14、RAG 的整体流程是怎样的？你们用到了哪些组件？

回答思路：文档解析 → 切分 → Embedding → 存储 → 混合检索 → 重排序 → LLM

参考话术：

“RAG 流程是：先用 iText/POI 解析文档，然后用 RecursiveCharacterTextSplitter 切分成块（chunk_size=500, overlap=100），再通过 bge-large-zh 模型生成向量，存入 Redis VectorStore。用户提问时，先混合检索 Top-100，再用交叉编码器重排序选出 Top-5，最后连同 Prompt 送给 LLM 生成答案。这样既保证检索效率，又提升答案准确率。”

15、为什么选择 Redis 作为向量库？它的优缺点是什么？

回答思路：性能 + 易用性 + 集成成本 + 优缺点分析

参考话术：

“选 Redis 主要考虑几点：一是我们已经在用 Redis 做缓存，复用组件可以减少运维成本；二是 Redis VectorStore 性能很高，支持 HNSW 索引，能满足我们的低延迟要求；三是与 Spring AI 集成很好，配置简单。缺点是它毕竟是内存数据库，海量向量存储成本较高，如果未来数据量到千万级，可能需要迁移到 Milvus 这类专用向量库。”

16、chunk_size 为什么设置为 500? overlap=100 的作用是什么?

回答思路：语义完整性 + 模型适配 + 检索粒度 + overlap 的上下文连贯作用

参考话术：

“500 字符是一个经验值，大约对应 100–200 个词，能完整覆盖一个段落，既保证语义完整，又足够细粒度便于检索。如果太大，一个块可能包含多个主题，检索精度下降；太小则语义碎片化。overlap=100 是为了让相邻块有部分重叠，避免切分边界导致的信息断裂，比如一个句子被切成两半时，重叠部分能保留上下文。”

17、如果现在文档量暴增 10 倍，系统哪些地方会成为瓶颈？你怎么扩容？

回答思路：分析各组件瓶颈 + 对应扩容方案

参考话术：

“我会从几个层面分析：

- **向量检索：**Redis 内存可能不够，可以升级集群或迁移到 Milvus。
- **AI 处理：**消息队列堆积，可以增加消费者实例，或者对 AI 任务做优先级分类。
- **文件存储：**MinIO 可以横向扩展节点。
- **数据库：**MySQL 读写分离或分库分表。

微服务架构的优势就在这里，我们可以针对瓶颈模块单独扩容，比如给 AI 服务加机器、给 RabbitMQ 加节点。”

18、你们的 RAG 系统在什么情况下会答错？怎么改进？

回答思路：召回不足 + 切分不合理 + 模型幻觉 + 改进方案

参考话术：

“主要有几种情况：

- **召回不足：**相关文档没被检索到。可以调整 chunk_size 或增加召回数量。
- **切分不合理：**关键信息被切到两个块里。可以优化 overlap 或调整分隔符。
- **模型幻觉：**LLM 自己编造答案。可以通过 Prompt 强调‘如果没找到就说不清楚’，或者引入知

识边界检测。

- **文档本身质量问题**：比如扫描件 OCR 错误。可以加强预处理。

我们会定期分析错误案例，针对性优化。”

19、为什么在你的项目中选择了 Redis？

1. **低延迟要求**：接口响应时间需控制在 200ms 内，Redis 的内存操作能稳定满足。
2. **数据量适中**：日均处理文档 500 份，向量总量在百万级以内，Redis 内存成本可控。
3. **简化技术栈**：项目已使用 Redis 做缓存，复用同一组件可降低运维复杂度。
4. **快速开发**：Spring AI 对 Redis VectorStore 有良好支持，集成便捷。
5. **混合检索需求不强**：你的场景以语义检索为主，关键词精确匹配需求较少，因此 Redis 足够。

20、为什么选择RabbitMQ而不是Kafka或RocketMQ？

选择 RabbitMQ 主要基于以下考虑：

- **业务场景**：AI任务异步处理，对消息顺序要求不高，但需要可靠确认和灵活路由。
- **功能特性**：RabbitMQ支持多种交换机类型（direct、topic），便于根据文档类型路由到不同队列；死信队列和延迟队列实现简单。
- **社区与维护**：RabbitMQ轻量，运维简单，满足日均500份文档的吞吐量（约几万条消息），不需要Kafka的超高吞吐。RocketMQ虽然性能更好，但是引入成本高；Kafka适合日志采集、大数据场景，对消息确认和重试机制不如RabbitMQ灵活。

21、异步任务失败了怎么办？有没有实现重试机制或死信队列？

实现了多层重试机制：

- **消费端重试**：配置spring.rabbitmq.listener.simple.retry.enabled=true，默认重试3次，间隔递增。
- **死信队列**：超过重试次数后，消息转入死信队列，由单独消费者记录错误并人工介入或延迟后重新投递。
- **业务补偿**：对于AI处理失败的任务，记录任务失败日志，定时任务扫描重试。

22、WebSocket和轮询各有扫描优缺点？你在项目中是如何选择的？

WebSocket：全双工通信，实时性好，适合频繁推送；但服务端需要维护长连接，增加资源开销，且部分网络环境可能不支持。

轮询：实现简单，兼容性好；但实时性差，存在无效请求，浪费宽带。

本项目选择WebSocket + 降级轮询：现代浏览器优先使用WebSocket，连接失败则每隔5秒轮询一次。WebSocket用于实时通知任务完成，轮询作为保底方案，保证所有用户都能收到结果。

23、你如何根据文档类型动态调整Prompt？有没有针对不同模型的Prompt优化经验？

动态调整 Prompt 主要通过以下方式：

- 在PromotTemplate中定义变量，如文档类型、长度、目标语言。
- 根据文档类型决定是否保留格式标记，例如对PDF提取的文本可能包含多余换行文档