

简历 · AI Agent 应用开发工程师（LLM 推理 / 多智能体方向）

> 说明：个人信息占位；技术经历基于真实落地代码《专属刷题教练 Agent》（Phase A-E，GitHub 已推送，版本 3.4.0-anomaly）。投递前替换【】内容。

基本信息

- 姓名：【姓名】 | 电话：【】 | 邮箱：【】 | 城市：【】
- 求职意向：AI Agent 应用开发工程师 / LLM 推理开发工程师
- GitHub：【链接】 | 技术博客：【】 | 作品体验：<https://www.taoxie.vip/shuati-coach.html>

技术总结

具备从 0 到 1 构建生产级 Agent 的实战能力：用 LangGraph 同构编排实现多 Agent 协作，落地 RAG 引用溯源 + 低相关拒答防幻觉，设计分层记忆与五段式上下文预算，并把 AIOps 异常检测迁移到学习场景 + 自建评测闭环。代码无外部密钥可规则降级跑通，工程规范清晰（分阶段编译+冒烟+文档即设计）。

技术栈

- 语言/框架：Python · FastAPI · asyncio · Pydantic
- Agent 编排：LangGraph（同构 StateGraph）· Supervisor 路由 · 反思节点 · 工具网关
- LLM/RAG：混元/通义基座（vLLM 私有化可选）· TF-IDF+BM25+RRF 重排 · 引用溯源 · 上下文工程
- 记忆/存储：SQLite 分层记忆（长/短）· 向量库（预留 Milvus/Redis VSS）
- 工程：Git · 单元测试/冒烟（隔离 DB）· 评测闭环 · 可观测埋点

技术沉淀（LLM 推理优化 · 已落代码 v2）

- 已做成可运行代码：`server/agent/inference.py` 实现 7 项推理优化（KV 前缀缓存 / 上下文压缩 / 投机解码 / 知识蒸馏 / continuous batching / 工具替代 / AWQ 量化），无需 GPU 即跑出量化指标，端点 `POST /api/agent/infer/optimize`、`GET /api/agent/infer/status`，版本 `3.5.0-infer-opt`。
- 量化与私有化：基座预留混元/通义 + vLLM/SGLang 私有化 + AWQ 4bit 量化路线（`QUANT\_CONFIG` 透传 `quantization=awq`），评测闭环可对比量化前后是否掉点。
- KV cache / prefix caching：五段式上下文预算中【身份】【长期画像】为稳定前缀，`KVCacheManager` 多轮复用（实测 `kv\_cache\_hit\_rate≈0.8`）；分层记忆降低 KV 占用。
- 知识蒸馏：`Distiller` 用 teacher(大模型)生成讲题/变式 → 蒸馏小模型(student)做边缘答疑，纯 Python ROUGE-N 评保真度（`run\_self\_eval` 同时评 teacher/student）。
- Agent 降本：工具替代生成（诊断/错题 0 token，实测 `tool\_substitutions` 累计）、反思节点确定性（0 额外 decode）、continuous batching 提并发吞吐（实测 `speedup≈8x`）、投机解码降首字延迟。

项目经历

专属刷题教练·Agent 升级（核心项目）

2026.07 | 个人全栈 | GitHub 已推送, v3.4.0-anomaly

把复赛刷题工具升级为定制化备考 Agent，分五个阶段落地，均为本人独立设计与实现：

- **Phase A 基础包**：单 Agent + 工具调用（诊断/错题/计划/答疑）+ 分层记忆 + `/api/agent/chat`` 入口。
- **Phase B 持久化记忆**：`MemoryStore`` 把记忆落 SQLite（agent\_profile 长期画像 + agent\_short\_term 短期对话）；设计五段式上下文预算，保证当前消息永不被裁；多会话 ``session_id`` 隔离 + 清记忆接口。
- **Phase C RAG 防幻觉**：`KnowledgeRetriever``（TF-IDF + 中文 2-gram 召回 + RRF 融合重排）；相关判据仅依赖 2-gram 真实命中，不相关则明确拒答（绝不编造）；``format_citations`` 生成 [1][2] 引用溯源。
- **Phase D 多 Agent 编排**：自研 LangGraph 同构 ``StateGraph``（add_node/add_edge/add_conditional_edges/compile/invoke + 最大步数防环）；6 节点 classify→子Agent→reflect；反思节点为确定性校验，保证每次响应有下一步动作。修复终点语义 bug（finish 节点未执行即退出）。
- **Phase E 异常检测 + 评测**：`LearningAnomalyDetector`` 把 AIOps 指标异常迁移为学习异常（正确率骤降/连续断签/错题反复），诊断即主动推送预警；``eval.py`` 评测闭环聚合 hit_rate/citation_rate/reject_rate/hallucination_rate + 分级；修复幻觉口径误判（拒答不计幻觉）。

量化验证：编译全过、无 lint；评测自评估 6 样本 hit_rate=0.667 / citation_rate=1.0 / hallucination_rate=0.0；三类学习异常均 high 级检出并主动推送；无 API Key 规则降级完整跑通。

刷题教练 复赛 Web 平台（前端 + 后端）

2026.07 | TRAE 创造力大赛复赛

- 四模块 SPA（聚合刷题/数据中心/智能推荐/AI 教练），Chart.js 可视化（掌握度雷达、正确率趋势），已部署上线。
- AI 链路：薄弱点诊断 / 按掌握度组卷 / 答案解析生成 / 备考答疑对话。

工程实践 / 亮点

- **零依赖可跑**：HAS_KEY 开关 + 规则降级，主链路不依赖外部密钥，便于演示与离线评测。
- **可观测**：工具调用留痕、评测日志持久化、语义化版本号、lifespan 建表。
- **文档即设计**：``刷题教练-Agent升级设计.md`` 记录每阶段改动/命中面试题/验证，可作为面试讲解底稿。

教育背景

- 【学校】 | 【专业】 | 【学历】 | 【时间】

自我评价

既懂 Agent 编排范式，也抠得过 RAG 相关性阈值与评测口径；相信「可信 Agent = 引用溯源 + 防幻觉 + 可量化评测」，乐于把 AIOps/可观测性等成熟工程思想迁移到 Agent 场景。